

Multimodal Görüntü Analizi ile Üveit Tanısına Yönelik Açıklanabilir Yapay Zekâ Tabanlı Modüler Karar Destek Sistemi

Recep Öztürk
Yazılım Mühendisliği Bölümü
Ankara Üniversitesi Mühendislik Fakültesi
Ankara, Türkiye
recep.ztrk.1907@gmail.com

Dr. Öğr. Üyesi İnan Kazancı
Yazılım Mühendisliği Bölümü
Ankara Üniversitesi Mühendislik Fakültesi
Ankara, Türkiye
inankazanci@ankara.edu.tr

Abstract—Üveit, farklı anatomik bölgeleri tutabilen, heterojen klinik görünümüne sahip ve kalıcı görme kaybına yol açabilen önemli bir intraoküler inflamasyon grubudur. Tanı süreci çoğu zaman slit-lamp biyomikroskopi, renkli fundus fotoğrafı, optik koherens tomografi anjiyografi, B-scan optik koherens tomografi ve anterior segment optik koherens tomografi gibi birden fazla görüntüleme modalitesinin birlikte değerlendirilmesini gerektirir. Bu çalışmada, üveit tanısını desteklemek amacıyla beş farklı oftalmolojik görüntüleme modalitesini kapsayan açıklanabilir yapay zekâ tabanlı modüler bir karar destek sistemi geliştirilmiştir. Hasta-bazlı eşleşmiş multimodal veri seti bulunmadığı için her modalite bağımsız bir uzman model olarak ele alınmış; slit-lamp, CFP, OCTA, B-scan OCT ve AS-OCT görüntüleri için ayrı derin öğrenme modelleri eğitilmiştir. Model çıktıları Grad-CAM tabanlı görsel açıklanabilirlik ile desteklenmiş, AS-OCT modalitesinde ek olarak U-Net tabanlı anatomik segmentasyon yaklaşımı kullanılmıştır. Deneysel sonuçlarda slit-lamp, CFP, B-scan OCT ve AS-OCT modellerinde yüksek F1 ve ROC AUC değerleri elde edilmiş; OCTA modeli ise retinal vasküler paternlerin üveit ayırımında tamamlayıcı bilgi sağlayabileceğini göstermiştir. Geliştirilen sistem, otomatik modalite yönlendirme ve karar destek prototipi altyapısı ile bütünleştirilmiştir. Mevcut çalışma doğrudan hasta düzeyinde multimodal füzyon gerçekleştirmemekte; bunun yerine ileride eşleşmiş klinik verilerle skor düzeyi veya karar düzeyi füzyona genişletilebilecek Faz-1 düzeyinde modüler bir altyapı sunmaktadır.

Index Terms—Üveit, derin öğrenme, multimodal tıbbi görüntüleme, açıklanabilir yapay zekâ, karar destek sistemi, Grad-CAM, optik koherens tomografi.

I. GİRİŞ

Üveit, göz içi dokuların inflamasyonu ile seyreden, klinik görünümü, anatomik yerleşimi ve etiyolojisi oldukça heterojen olan önemli bir oftalmolojik hastalık grubudur. Klasik anlamda uveal traktusu oluşturan iris, siliyer cisim ve koroid dokularının inflamasyonu olarak tanımlansa da klinik pratikte retina, vitreus, optik sinir ve retinal damar yapılarının inflamatuvar tutulumlarını da kapsayabilmektedir. Hastalık, anatomik yerleşimine göre anterior, intermediate, posterior ve panüveit olarak sınıflandırılır; bu sınıflandırma tanı, takip ve tedavi yaklaşımının belirlenmesinde temel öneme sahiptir [1]. Üveitin özellikle genç ve üretken yaş grubunu etkileyebilmesi, tekrarlayıcı veya kronik seyir gösterebilmesi ve tedavi

edilmediğinde kalıcı görme kaybına yol açabilmesi, erken ve doğru tanıyı kritik hale getirmektedir [2]–[4].

Üveit yalnızca lokal bir göz hastalığı olarak değerlendirilmemelidir. Bazı olgularda enfeksiyöz nedenlerle, bazı olgularda ise otoimmün veya sistemik inflamatuvar hastalıklarla ilişkili olarak ortaya çıkabilmektedir. Behçet hastalığı, sarkoidoz, HLA-B27 ilişkili hastalıklar, juvenil idiopatik artrit, tüberküloz, toksoplazmoz ve Vogt-Koyanagi-Harada hastalığı gibi farklı klinik tablolar üveit ile ilişkili olabilmektedir. Bu geniş etiyolojik dağılım, tanı sürecini yalnızca görüntü yorumlama probleminden çıkarıp klinik bağlam, hastalık öyküsü, sistemik bulgular ve gerektiğinde laboratuvar testleriyle birlikte değerlendirilmesi gereken çok değişkenli bir karar problemine dönüştürmektedir. Bu nedenle üveit olgularında doğru tanı yalnızca hastalığın varlığını belirlemekle sınırlı değildir; tutulum bölgesinin, aktivite düzeyinin, olası etiyolojinin ve komplikasyon riskinin de değerlendirilmesini gerektirir.

Üveit tanısı çoğu zaman tek bir klinik bulguya ya da tek bir görüntüleme yöntemine dayanarak konulamaz. Anterior segment tutulumunda slit-lamp biyomikroskopi ile ön kamara hücreleri, flare, keratik presipitatlar, hipopyon ve iris bulguları değerlendirilirken; posterior segment tutulumunda renkli fundus fotoğrafı, optik koherens tomografi (OCT), optik koherens tomografi anjiyografi (OCTA), fundus florescein anjiyografi ve gerektiğinde diğer görüntüleme yöntemleri birlikte yorumlanmaktadır. Renkli fundus fotoğrafları koryoretinal lezyonlar, retinal vaskülit bulguları ve optik disk değişiklikleri hakkında bilgi sağlarken; B-scan OCT görüntüleri retinal tabaka değişiklikleri, maküler ödem, vitreoretinal arayüz bulguları ve posterior segment inflamasyonuna ilişkin yapısal paternleri ortaya koyabilir. OCTA, retinal ve koroidal mikrovasküler yapıların non-invaziv olarak incelenmesine imkân verirken, anterior segment OCT (AS-OCT) ön segment yapılarının kesitsel değerlendirilmesi ve keratik presipitat ya da korneal opasite gibi yapısal bulguların nicel analizi açısından potansiyel taşımaktadır [5]. Dolayısıyla üveit, farklı görüntüleme modalitelerinin birbirini tamamladığı çok boyutlu bir değerlendirme süreci gerektirir.

Bu çoklu değerlendirme ihtiyacı klinik pratikte iki temel

zorluğu beraberinde getirir. Birincisi, üveit bulgularının hastadan hastaya belirgin biçimde değişebilmesi nedeniyle tanı sürecinin önemli ölçüde uzman deneyimine bağımlı olmasıdır. İkincisi ise farklı görüntüleme modalitelerinden elde edilen bilgilerin çoğu zaman ayrı ayrı değerlendirilmesi ve bu bilgilerin tek bir karar destek çerçevesi içinde sistematik olarak bütünleştirilememesidir. Özellikle kaynak kısıtlı sağlık ortamlarında deneyimli üveit uzmanına erişimin sınırlı olması, tanı gecikmesi veya eksik değerlendirme riskini artırabilir. Bu nedenle üveit gibi karmaşık ve heterojen hastalık gruplarında, klinisyenin kararını destekleyebilecek, görüntü bulgularını sistematik olarak analiz edebilecek ve gerektiğinde karar gerekçesini görsel olarak sunabilecek yapay zekâ tabanlı sistemlere ihtiyaç duyulmaktadır.

Oftalmoloji, yüksek çözünürlüklü dijital görüntülerin yoğun olarak kullanıldığı bir alan olması nedeniyle yapay zekâ ve derin öğrenme uygulamaları için uygun bir çalışma sahasıdır. Son yıllarda derin öğrenme tabanlı yaklaşımlar diyabetik retinopati, yaşa bağlı makula dejenerasyonu, glokom, retinal damar analizi ve çoklu retinal hastalık sınıflandırması gibi alanlarda dikkate değer başarılar göstermiştir [6]–[10]. Bununla birlikte, üveit alanındaki yapay zekâ çalışmaları retinal hastalıklara kıyasla daha sınırlıdır. Mevcut çalışmalar genellikle belirli bir modaliteye, belirli bir üveit alt tipine, deneysel hayvan modellerine, tek bir klinik bulguya veya klinik-demografik değişkenlerden etiyolojik tahmin yapılmasına odaklanmaktadır. Retinal hastalıklarda CFP ve OCT gibi birden fazla modalitenin birlikte kullanıldığı güncel derin öğrenme çalışmaları, multimodal görüntü birleştirmenin tek modaliteli yaklaşımlara göre daha kapsamlı tanılabilir bilgi sağlayabileceğini göstermektedir [11].

Tablo I, üveit ve oftalmik görüntüleme alanındaki seçilmiş yapay zekâ çalışmalarını bu çalışmanın kapsamı ile karşılaştırmaktadır. Literatürdeki mevcut çalışmalar üveit tanısında yapay zekânın potansiyelini göstermiş olsa da, çoğu çalışma tek modalite veya tek karar görevi ile sınırlı kalmaktadır. Bu çalışmada ise slit-lamp, renkli fundus fotoğrafı, OCTA, B-scan OCT ve AS-OCT olmak üzere beş farklı görüntüleme modalitesi için bağımsız uzman modellerin geliştirildiği ve bu modellerin açıklanabilir bir karar destek sistemi çatısı altında birleştirildiği modüller bir yaklaşım önerilmektedir.

Bu çalışmanın temel amacı, üveit tanısında kullanılan farklı oftalmolojik görüntüleme modaliteleri için derin öğrenme tabanlı uzman modeller geliştirmek ve bu modelleri açıklanabilir bir yapay zekâ karar destek sistemi çatısı altında birleştirmektir. Çalışma kapsamında slit-lamp biyomikroskopi görüntüleri, renkli fundus fotoğrafları (CFP), OCTA görüntüleri, B-scan OCT görüntüleri ve AS-OCT görüntüleri için ayrı sınıflandırma modelleri geliştirilmiştir. Ayrıca AS-OCT modalitesinde sınıflandırmaya ek olarak U-Net tabanlı segmentasyon yaklaşımı kullanılarak anatomik açıklanabilirlik desteklenmiştir. Sınıflandırıcı modellerin karar bölgeleri Grad-CAM yöntemiyle görselleştirilmiş, böylece sistem çıktılarının yalnızca olasılık değeri olarak değil, aynı zamanda görsel gerekçelerle birlikte sunulması hedeflenmiştir.

Bu çalışma, hasta-bazlı eşleşmiş beş modaliteli bir veri seti

bulunmadığı için doğrudan erken veya geç multimodal füzyon gerçekleştiren klinik bir sistem olarak tasarlanmamıştır. Bunun yerine çalışma, her görüntüleme modalitesi için ayrı bir uzman model geliştiren ve bu modellerin çıktılarının ileride hasta-bazlı eşleşmiş veriler elde edildiğinde skor düzeyi veya karar düzeyi füzyon yöntemleriyle birleştirilebileceği modüller bir Faz-1 altyapı sunmaktadır. Bu yaklaşım, mevcut veri kısıtları altında uygulanabilir bir geliştirme stratejisi sunarken, aynı zamanda gelecekte gerçek multimodal füzyon çalışmaları için teknik bir temel oluşturmaktadır.

Bu çalışmanın başlıca katkıları şu şekilde özetlenebilir:

- Üveit tanısında kullanılan beş farklı oftalmolojik görüntüleme modalitesi için bağımsız derin öğrenme tabanlı uzman modeller geliştirilmiştir.
- Her modalitenin veri yapısı ve klinik rolü dikkate alınarak farklı model mimarileri, veri artırma stratejileri ve sınıf dengesizliği yönetim yöntemleri uygulanmıştır.
- Grad-CAM ve AS-OCT için U-Net segmentasyon çıktıları kullanılarak model kararlarının görsel olarak açıklanabilir hale getirilmesi amaçlanmıştır.
- Kullanıcının modaliteyi manuel seçme zorunluluğunu azaltmak amacıyla otomatik modalite yönlendirme yapan bir router modeli geliştirilmiştir.
- Geliştirilen modeller, karar destek prototipi altyapısı içinde çalıştırılacak şekilde modüller olarak yapılandırılmış ve ileride hasta-bazlı eşleşmiş verilerle gerçek multimodal füzyona genişletilebilecek bir temel oluşturulmuştur.

Önerilen sistemin genel mimarisi Şekil 1 üzerinde gösterilmiştir.

II. MATERYAL VE YÖNTEM

A. Çalışma Tasarımı

Bu çalışma, üveit tanısını desteklemek amacıyla farklı oftalmolojik görüntüleme modaliteleri için geliştirilen açıklanabilir derin öğrenme tabanlı uzman modellerden oluşan modüller bir karar destek sistemi tasarımını sunmaktadır. Çalışmanın temel yaklaşımı, hasta-bazlı eşleşmiş multimodal veri setinin bulunmadığı mevcut veri koşullarında her görüntüleme modalitesini bağımsız bir uzman model olarak ele almak ve bu modelleri ortak bir karar destek prototipi altında birleştirmektir. Bu nedenle önerilen sistem, doğrudan hasta düzeyinde erken füzyon yapan bir multimodal model değil; ileride eşleşmiş hasta verileri elde edildiğinde skor düzeyi veya karar düzeyi füzyona genişletilebilecek Faz-1 düzeyinde modüller bir altyapı olarak tasarlanmıştır. Model geliştirme ve değerlendirme sürecinin genel akışı Şekil 2 üzerinde özetlenmiştir.

Çalışma kapsamında beş farklı görüntüleme modalitesi ele alınmıştır: slit-lamp biyomikroskopi görüntüleri, renkli fundus fotoğrafları (CFP), optik koherens tomografi anjiyografi (OCTA), B-scan optik koherens tomografi (B-scan OCT) ve anterior segment optik koherens tomografi (AS-OCT). Her modalite için veri yapısı, sınıf dağılımı, klinik kullanım amacı ve görüntü karakteristikleri dikkate alınarak ayrı model mimarileri ve eğitim stratejileri uygulanmıştır. Modellerin temel

Table I
ÜVEİT VE OFTALMIK GÖRÜNTÜLEME ALANINDAKİ YAPAY ZEKÂ ÇALIŞMALARININ KAPSAM AÇISINDAN KARŞILAŞTIRILMASI

Çalışma	Modalite / Veri	Amaç	Temel Katkı	Sınırlılık / Boşluk
Sun ve ark. [12]	Fare deneysel otoimmün üveit fundus görüntüleri	Üveit düzeylerinin sınıflandırılması	Deneyisel otoimmün üveit modelinde normal, hafif ve belirgin hastalık sınıflarının derin öğrenme ile ayrılabilirliğini göstermiştir.	İnsan klinik verisi değildir; tek modaliteye ve deneysel hayvan modeline odaklanmaktadır.
Pichi ve ark. [5]	AS-OCT görüntüleri	Uveitik keratik presipitatların otomatik ölçümü	AS-OCT ile keratik presipitat hacminin ve dağılımının nicel olarak analiz edilebileceğini göstermiştir.	Tanı sınıflandırma sistemi değildir; ön segmentte tek bir bulguya odaklanmaktadır.
Mellak ve ark. [13]	Murine OCT görüntüleri	Deneyisel üveitin sınıflandırılması ve partikül analizi	OCT görüntüleri üzerinde sınıflandırma, Grad-CAM açıklanabilirliği ve partikül segmentasyonu ile deneysel üveit nicel analizini göstermiştir.	İnsan klinik verisi değildir; deneysel hayvan modeli ve OCT partikül analizi ile sınırlıdır.
Putera ve ark. [14]	Fundus fotoğrafları ve retinal vasküler parametreler	Ocular tüberküloz, QFT-pozitif üveit ve tokso-plazmoz ayrımı	Retinal damar parametrelerinin üveit etiyojileri arasında ayırıcı tanıya katkı sağlayabileceğini göstermiştir.	Belirli etiyojilere ve fundus görüntülerine odaklıdır; multimodal karar destek mimarisi sunmamaktadır.
Jacquot ve ark. [15]	Klinik, demografik ve tamamlayıcı muayene değişkenleri	Üveitin etiyojistik tanısının tahmini	Klinik değişkenler üzerinden çok sayıda üveit etiyojisi için yapay sinir ağı tabanlı tahmin yaklaşımı geliştirmiştir.	Görüntü tabanlı multimodal analiz içermemektedir; klinik entegrasyon sınırlıdır.
Murugan ve ark. [16]	Sistemik derleme	Üveitte yapay zekâ uygulamalarının değerlendirilmesi	Üveit alanında tanı desteği, inflamasyon derecelendirme ve yönetim stratejilerinde yapay zekâ potansiyelini özetlemiştir.	Veri kalitesi, model şeffaflığı, etik sorunlar ve multimodal sistem gereksiniminin sürdürüğünü vurgulamaktadır.
Bu çalışma	Slit-lamp, CFP, OCTA, B-scan OCT ve AS-OCT	Üveit tanısına yönelik açıklanabilir modüler karar destek prototipi geliştirilmesi	Beş farklı görüntüleme modalitesi için uzman derin öğrenme modelleri, Grad-CAM / segmentasyon tabanlı açıklanabilirlik ve otomatik modalite yönlendirme altyapısı sunmaktadır.	Hasta-bazlı eşleşmiş multimodal veri ile gerçek füzyon ve prospektif klinik validasyon gelecek çalışma kapsamındadır.

çıkışı, ilgili görüntünün üveit veya üveit ile ilişkili patolojik bulgular açısından pozitif olma olasılığıdır. Bu çıktılar, Grad-CAM ve AS-OCT segmentasyonu gibi görsel açıklanabilirlik yöntemleri ile desteklenmiştir.

B. Kullanılan Veri Setleri

Çalışmada kullanılan veri kaynakları, her modalitenin klinik rolü ve veri erişilebilirliği dikkate alınarak seçilmiştir. Slit-lamp modeli ön segment fotoğraflarında üveit ile diğer ön segment hastalıklarının ayırımına; CFP modeli posterior segment ve koryoretinal bulgulara; OCTA modeli retinal mikrovasküler değişikliklere; B-scan OCT modeli retinal kesitlerde yapısal inflamasyon bulgularına; AS-OCT modeli ise anterior segment yapısal bulgularının sınıflandırılması ve segmentasyonuna odaklanmaktadır. Kullanılan veri setlerinin genel özeti Tablo II üzerinde verilmiştir.

Slit-lamp veri seti toplam 1.309 görüntüden oluşmaktadır. Orijinal veri dört sınıf içermektedir: üveit, katarakt, konjonktivit ve göz kapağı hastalıkları. Bu çalışma kapsamında üveit sınıfı pozitif sınıf, diğer üç sınıf ise non-üveit sınıfı olarak yeniden etiketlenmiştir. Böylece model yalnızca sağlıklı-hasta

ayrımı yapmak yerine, klinik pratikte görülebilecek diğer ön segment patolojileri arasından üveit bulgularını ayırt etmeye zorlanmıştır.

CFP modalitesinde iki farklı fundus veri kaynağı birleştirilmiştir. Toplam 870 renkli fundus görüntüsü kullanılmış, bu görüntülerin 63'ü üveit ile ilişkili sınıflardan, 807'si ise non-üveit retinal hastalık veya normal sınıflardan oluşmuştur. Veri setindeki belirgin sınıf dengesizliği nedeniyle eğitim sürecinde örnekleme ve kayıp fonksiyonu düzeyinde dengeleme stratejileri uygulanmıştır.

OCTA modeli için Behçet hastalığına bağlı aktif ve inaktif üveit görüntüleri ile kontrol görüntüleri kullanılmıştır. Ayrıca harici kontrol görüntüleri eklenerek modelin farklı cihazlardan gelen sağlıklı vasküler paternleri öğrenmesi desteklenmiştir. Aynı hastaya veya göze ait superficial ve deep katman görüntülerinin farklı veri bölümlerine düşmesini önlemek amacıyla grup tabanlı bölme stratejisi uygulanmıştır.

B-scan OCT modalitesi, veri kıtlığının en belirgin olduğu alanlardan biridir. Hedef görev için gerçek klinik üveit ve normal B-scan OCT görüntüleri sınırlı sayıdadır. Bu kısıtı azaltmak için retinal OCT alanında yaygın kullanılan büyük




Figure 1. Overall architecture of the proposed multimodal uveitis decision support system.

ölçekli Kermany veri seti ile alan bilgisi aktarımı yapılmış ve gerçek üveit görüntülerinden yalnızca eğitim setinde kullanılmak üzere sentetik görüntüler üretilmiştir. Sentetik görüntüler değerlendirme ve test aşamalarına dahil edilmemiştir.

AS-OCT modalitesinde MCOA veri seti sınıflandırma görevi için, AIDK veri seti ise U-Net tabanlı segmentasyon modeli için kullanılmıştır. Bu modül doğrudan insan üveit AS-OCT verisi ile eğitilmiş bir tanı modeli olarak değil, anterior segment yapısal anormalliklerinin otomatik analizi ve anatomik açıklanabilirlik sağlanması amacıyla geliştirilmiş yardımcı bir modül olarak konumlandırılmıştır. Bu ayırım, çalışmanın klinik geçerlilik sınırlarının doğru yorumlanması açısından önemlidir.

C. Veri Ön İşleme ve Bölme Stratejileri

Tüm görüntüler model eğitiminden önce standart bir ön işleme sürecinden geçirilmiştir. Görüntüler RGB formatına dönüştürülmüş, ilgili model mimarisine uygun olarak yeniden boyutlandırılmış ve ImageNet ön-eğitilmiş omurgalarla uyumlu olacak biçimde normalize edilmiştir. Sınıflandırma modellerinin büyük çoğunluğunda giriş boyutu 224×224 piksel olarak belirlenmiştir. AS-OCT segmentasyon modelinde ise U-Net mimarisinin encoder-decoder yapısına uygun olarak 256×256 piksel çözünürlük kullanılmıştır.

Veri setleri eğitim, doğrulama ve test bölümlerine ayrılırken her modalitenin veri yapısı dikkate alınmıştır. Slit-lamp ve CFP veri setlerinde sınıf oranlarının korunması amacıyla stratified sampling uygulanmıştır. OCTA veri setinde aynı hasta veya göze ait farklı görüntülerin ayrı veri bölümlerine dağılmasını önlemek için grup tabanlı bölme stratejisi tercih edilmiştir. B-scan OCT modelinde ise 5-fold çapraz doğrulama yaklaşımı kullanılmış ve her fold sonucunda elde edilen test tahminleri birleştirilerek toplu performans metrikleri hesaplanmıştır.

Eğitim sürecinde yalnızca eğitim setine veri artırma uygulanmıştır. Doğrulama ve test setlerinde yalnızca yeniden boyutlandırma ve normalizasyon işlemleri uygulanmış, böylece değerlendirme aşamasında yapay veri dönüşümleriyle metriklerin etkilenmesi önlenmiştir.

D. Veri Artırma ve Sınıf Dengesizliği Yönetimi

Oftalmolojik görüntü veri setlerinde hem veri sayısının sınırlı olması hem de pozitif sınıf oranının düşük kalması sık karşılaşılan bir problemdir. Bu nedenle çalışmada kullanılan augmentation stratejileri her modalitenin anatomik ve klinik özelliklerine göre belirlenmiştir. Slit-lamp görüntülerinde hafif döndürme, yatay çevirme ve parlaklık-kontrast değişimleri uygulanmıştır. CFP görüntülerinde anatomik yönelim bilgisini

Development Pipeline of the Multimodal Uveitis Decision Support System




Figure 2. Development pipeline of the proposed multimodal uveitis decision support system.

bozabileceği için dikey çevirme kullanılmamış; yatay çevirme, hafif döndürme, renk değişimi ve kısmi silme işlemleri tercih edilmiştir. OCTA görüntülerinde vasküler paternlerin ölçek ve yönelim değişikliklerine karşı daha dayanıklı öğrenilebilmesi için daha agresif geometrik dönüşümler uygulanmıştır. B-scan OCT modelinde sınırlı sayıdaki gerçek üveit görüntülerinden yalnızca eğitim setinde kullanılmak üzere sentetik varyasyonlar üretilmiştir.

Sınıf dengesizliği, modaliteye göre farklı yöntemlerle yönetilmiştir. Slit-lamp, OCTA, CFP ve B-scan OCT modellerinde *BCEWithLogitsLoss* kayıp fonksiyonunda pozitif sınıfa daha yüksek ağırlık verilmiştir. CFP veri setinde üveit görüntülerinin toplam veri içindeki oranı oldukça düşük olduğundan, kayıp düzeyi ağırlıklandırmaya ek olarak *WeightedRandomSampler* kullanılmıştır. Böylece eğitim batch'lerinde azınlık sınıfının model tarafından daha sık görülmesi sağlanmıştır. CFP ve OCTA modellerinde test-time augmentation (TTA) uygulanarak test görüntülerinin farklı dönüşümler altındaki tahminleri ortalananmış ve sınır olgularında daha kararlı tahminler elde edilmesi amaçlanmıştır.

E. Model Mimarileri

Her modalite için görüntü yapısına, veri miktarına ve hedef göreve uygun farklı derin öğrenme mimarileri kullanılmıştır. Model mimarilerinin genel özeti Tablo III üzerinde verilmiştir.

Slit-lamp modelinde EfficientNet-B0 omurgası kullanılmıştır [17]. EfficientNet ailesi, compound scaling yaklaşımı ile derinlik, genişlik ve giriş çözünürlüğünü dengeli biçimde ölçeklendirmesi nedeniyle sınırlı veri koşullarında parametre verimliliği sağlayan bir mimaridir. Modelin son sınıflandırıcı katmanı ikili sınıflandırma görevine uygun şekilde tek çıkışlı doğrusal katmanla değiştirilmiştir.

CFP modelinde de EfficientNet-B0 omurgası tercih edilmiştir. Fundus görüntülerindeki patolojik bulguların konum, renk ve kontrast açısından değişiklik gösterebilmesi nedeniyle eğitim sürecinde augmentation ve sınıf dengesizliği yönetimi kritik rol oynamıştır. Model çıktıları test-time augmentation ile dengelenmiş ve doğrulama seti üzerinde belirlenen optimal eşik değeri ile ikili karar üretilmiştir.

OCTA modelinde ResNet-18 omurgası kullanılmıştır [18]. Vasküler paternlerin fundus görüntülerine kıyasla daha ince yapılı ve düşük kontrastlı olması nedeniyle model eğitiminde progressive fine-tuning yaklaşımı uygulanmıştır. İlk aşamada yalnızca sınıflandırıcı başlık eğitilmiş, ardından tüm ağ daha düşük öğrenme oranıyla ince ayar sürecine alınmıştır.

B-scan OCT modelinde retinal OCT alanına daha yakın özelliklerin öğrenilmesi amacıyla Kermany retinal OCT veri seti üzerinde ön-eğitilmiş ResNet-18 omurgası kullanılmıştır [18], [19]. Bu yaklaşım, genel ImageNet özelliklerinden sonra OCT alanına özgü yapısal örüntülerin öğrenilmesini ve ardın-

Table II
ÇALIŞMADA KULLANILAN VERİ SETLERİ VE MODALİTE BAZLI GÖREV TANIMLARI

Modalite	Veri Kaynağı	Görev	Toplam Görüntü	Sınıflar	Not
Slit-lamp	Eye Diseases Classification Dataset	Üveit ve diğer ön segment hastalıklarının ikili sınıflandırılması	1.309	Üveit / Non-üveit	Üveit, katarakt, konjonktivit ve göz kapağı hastalıkları içeren dört sınıflı veri ikili probleme dönüştürülmüştür.
CFP	1000 Fundus Images ve RFMiD 2.0 alt kümeleri	Posterior segment bulgularından üveit ayrımı	870	Üveit / Non-üveit	VKH, CRS ve farklı retinal hastalık sınıflarından oluşan heterojen bir fundus veri kümesi kullanılmıştır.
OCTA	OCTOPUS Behçet OCTA veri seti ve harici kontrol görüntüleri	Retinal vasküler paternlerden üveit ayrımı	525	Üveit / Kontrol	Superficial ve deep vasküler katmanlar kullanılmış; hasta/göz bazlı sızıntıyı önlemek için grup tabanlı bölme uygulanmıştır.
B-scan OCT	Klinik üveit-normal OCT görüntüleri ve Kermany retinal OCT veri seti	Retinal OCT kesitlerinden üveit ayrımı	10.739	Üveit / Normal	Gerçek üveit görüntü sayısı sınırlı olduğundan Kermany ön-eğitimi ve yalnızca eğitim setinde kullanılan sentetik üveit görüntüleriyle desteklenmiştir.
AS-OCT	MCOA ve AIDK veri setleri	Anterior segment yapısal patoloji sınıflandırması ve anatomik segmentasyon	6.272 sınıflandırma; 1.168 segmentasyon	Normal / Anormal	AS-OCT modülü doğrudan insan üveit veri seti yerine anterior segment yapısal bulguları için proxy görev olarak ele alınmıştır.

Table III
MODALİTE BAZLI MODEL MIMARİLERİ VE EĞİTİM YAKLAŞIMLARI

Modalite	Backbone / Mimari	Ön Eğitim	Eğitim Stratejisi	Açıklanabilirlik
Slit-lamp	EfficientNet-B0	ImageNet	AdamW, BCEWithLogitsLoss, pos_weight, hafif augmentation	Grad-CAM
CFP	EfficientNet-B0	ImageNet	WeightedRandomSampler, pos_weight, TTA, optimal threshold	Grad-CAM
OCTA	ResNet-18	ImageNet	Progressive fine-tuning, label smoothing, cosine annealing, TTA	Grad-CAM
B-scan OCT	ResNet-18	ImageNet + Kermany OCT ön-eğitimi	Üç aşamalı transfer learning, sentetik eğitim verisi, 5-fold değerlendirme	Grad-CAM
AS-OCT	EfficientNet-B0 + U-Net	Noisy Student / ImageNet	Sınıflandırma ve segmentasyon görevleri	Grad-CAM + anatomik segmentasyon maskesi
Router	MobileNetV3-Small	ImageNet	Beş modaliteyi ayıran yardımcı sınıflandırıcı	Modalite yönlendirme çıktısı

dan sınırlı üveit verisine transfer edilmesini sağlamaktadır. Böylece model geliştirme süreci ImageNet ön-eğitimi, Kermany OCT ön-eğitimi ve üveit sınıflandırma görevine ince ayar olmak üzere üç katmanlı transfer learning stratejisi olarak tasarlanmıştır.

AS-OCT modülünde iki ayrı görev yer almaktadır. İlk görev, AS-OCT görüntülerinde normal ve anormal anterior segment yapısal bulgularının sınıflandırılmasıdır. Bu görev için Noisy Student ön-eğitilmiş EfficientNet-B0 modeli kullanılmıştır. İkinci görev ise anterior segment anatomik yapılarının segmentasyonudur. Bu amaçla U-Net tabanlı bir encoder-decoder mimarisi kullanılarak kornea, iris, ön kamara ve lens gibi yapıların piksel düzeyinde ayrıştırılması hedeflenmiştir [20].

Sistemde ayrıca otomatik modalite yönlendirme amacıyla MobileNetV3-Small tabanlı bir router modeli geliştirilmiştir

[21]. Router modeli, kullanıcı tarafından yüklenen görüntünün hangi modaliteye ait olduğunu tahmin ederek ilgili uzman modele yönlendirilmesini sağlar. Bununla birlikte, kullanıcı arayüzünde manuel modalite seçimi de korunmuştur. Böylece sistem hem otomatik kullanım hem de kontrollü klinik demo senaryoları için esnek hale getirilmiştir.

F. Eğitim ve Değerlendirme Metrikleri

Tüm sınıflandırma modelleri PyTorch tabanlı eğitim betikleri ile eğitilmiştir. Model eğitiminde genel olarak AdamW optimizasyon algoritması [22], ikili sınıflandırma için BCE-WithLogitsLoss, erken durdurma, öğrenme oranı zamanlaması ve checkpoint kaydetme stratejileri kullanılmıştır. Modaliteye özgü veri yapısı nedeniyle epoch sayısı, batch size, öğrenme

oranı ve scheduler tercihleri modeller arasında farklılık göstermiştir.

Model performansları doğruluk (accuracy), precision, recall, F1 skoru, ROC AUC ve confusion matrix metrikleriyle değerlendirilmiştir. Tıbbi tarama bağlamında false negative oranının düşük tutulması önemli olduğundan recall değeri özellikle dikkate alınmıştır. Bununla birlikte, sınıf dengesizliğinin yüksek olduğu CFP ve B-scan OCT gibi modalitelerde yalnızca accuracy değerine dayanmak yanıltıcı olabileceğinden F1 skoru, precision ve ROC AUC değerleri birlikte yorumlanmıştır.

G. Açıklanabilir Yapay Zekâ Yaklaşımı

Tıbbi görüntüleme tabanlı karar destek sistemlerinde modelin yalnızca sınıf etiketi üretmesi yeterli değildir. Modelin hangi görüntü bölgelerine dayanarak karar verdiğinin görselleştirilebilmesi, klinik güvenilirlik ve yorumlanabilirlik açısından önemlidir. Bu nedenle çalışmada sınıflandırıcı modeller için Grad-CAM yöntemi kullanılmıştır [23]. Grad-CAM, son konvolüsyonel katmanlardaki aktivasyonları ve gradyanları kullanarak model kararına en fazla katkı veren görüntü bölgelerini ısı haritası biçiminde göstermektedir.

Slit-lamp, CFP, OCTA ve B-scan OCT modellerinde Grad-CAM çıktıları, modelin üveit ile ilişkili bulgulara odaklanıp odaklanmadığını nitel olarak değerlendirmek amacıyla kullanılmıştır. AS-OCT modülünde ise Grad-CAM'e ek olarak U-Net segmentasyon maskeleri üretilmiştir. Bu sayede model çıktısı yalnızca anormal/normal sınıflandırmasıyla sınırlı kalmamış, aynı zamanda anterior segmentteki anatomik yapıların görsel olarak ayrıştırılmasıyla desteklenmiştir.

H. Karar Destek Prototipi Altyapısı

Geliştirilen modeller, karar destek prototipi altyapısı içinde çalıştırılacak şekilde modüler olarak bütünleştirilmiştir. Backend tarafında FastAPI kullanılmış; görüntü yükleme, modalite seçimi, otomatik modalite tespiti, model tahmini, Grad-CAM görselleştirilmesi, AS-OCT segmentasyon çıktısı ve klinik yorum üretimi gibi bileşenler prototip kapsamında tasarlanmıştır. Kullanıcı bir görüntü yüklediğinde sistem görüntüyü ilgili uzman modele yönlendirmekte, model olasılık skorunu hesaplamakta ve açıklanabilirlik çıktısını üretmektedir.

Bu prototip, çalışmanın yalnızca model geliştirme aşamasında kalmamasını ve klinik karar destek sistemi olarak nasıl kullanılabileceğinin gösterilmesini amaçlamaktadır. Ancak sistem çıktıları kesin tanı olarak değil, klinisyenin değerlendirmesini destekleyen deneysel bir ikinci görüş mekanizması olarak ele alınmalıdır. Hasta-bazlı eşleşmiş multimodal veri elde edilmesi durumunda, mevcut uzman model çıktılarının skor düzeyi veya karar düzeyi füzyon yöntemleriyle birleştirilmesi gelecek çalışma kapsamında planlanmaktadır.

III. DENEYSEL SONUÇLAR

A. Genel Performans Özeti

Geliştirilen beş uzman model, kendi modalite ve veri yapısına uygun test stratejileri ile değerlendirilmiştir. Slit-lamp, CFP, OCTA ve AS-OCT modelleri ayrılmış test setleri




Figure 3. F1 score and ROC AUC comparison of modality-specific expert models.

üzerinde; B-scan OCT modeli ise veri kıtlığı nedeniyle 5-fold çapraz doğrulama çıktılarının birleştirilmesiyle değerlendirilmiştir. Tablo IV, modalite bazlı temel performans metriklerini; Tablo V ise her modalite için kullanılan test stratejisi ve sonuçların yorumlanmasında dikkate alınması gereken deneysel notları özetlemektedir.

Modalite bazlı F1 skoru ve ROC AUC karşılaştırması Şekil 3 üzerinde verilmiştir.

Genel sonuçlar, modaliteye özgü uzman model yaklaşımının sınırlı ve heterojen veri koşullarında uygulanabilir olduğunu göstermektedir. En yüksek F1 skoru CFP modelinde elde edilmiştir (F1=0.947). Slit-lamp ve B-scan OCT modelleri F1=0.900 düzeyinde dengeli performans sergilemiştir. AS-OCT modeli F1=0.920 ile anterior segment yapısal patoloji ayrımında güçlü sonuç üretmiştir. OCTA modeli ise F1=0.780 ve AUC=0.910 değerleriyle diğer modellere göre daha düşük ancak klinik açıdan anlamlı bir ayırt etme kapasitesi göstermiştir.

Bu sonuçlar yorumlanırken veri setlerinin yapısal farklılıkları dikkate alınmalıdır. CFP ve B-scan OCT modellerinde yüksek recall değerleri elde edilmiş olsa da, pozitif sınıf örnek sayısının sınırlı olması bu metriklerin dikkatli değerlendirilmesini gerektirir. AS-OCT modülü ise doğrudan insan üveit AS-OCT verisi üzerinde değil, anterior segment yapısal anormallikleri için kullanılan proxy veri setleri üzerinde geliştirilmiştir. Bu nedenle AS-OCT sonucu, doğrudan klinik üveit tanısı değil, anterior segment yapısal analiz kapasitesi olarak değerlendirilmelidir.

B. Slit-lamp Modeli Sonuçları

Slit-lamp modeli, 1.309 görüntüden oluşan dört sınıflı ön segment veri setinin ikili sınıflandırma problemine dönüştürülmesiyle eğitilmiştir. Test seti 197 görüntüden oluşmakta olup, bu set içinde 29 üveit ve 168 non-üveit görüntüsü bulunmaktadır. EfficientNet-B0 tabanlı model test setinde 0.969 accuracy, 0.871 precision, 0.931 recall, 0.900 F1 skoru ve 0.988 ROC AUC değerlerine ulaşmıştır.

Table IV
MODALITE BAZLI UZMAN MODELLERIN TEMEL PERFORMANS METRIKLERI

Modalite	Model	Accuracy	Precision	Recall	F1	AUC
Slit-lamp	EfficientNet-B0	0.969	0.871	0.931	0.900	0.988
CFP	EfficientNet-B0 + TTA	0.992	0.900	1.000	0.947	0.998
OCTA	ResNet-18 + TTA	0.843	0.742	0.821	0.780	0.910
B-scan OCT	ResNet-18 + Kermany PT	0.999	0.818	1.000	0.900	1.000
AS-OCT	EfficientNet-B0 + U-Net	~0.940	~0.900	~0.920	0.920	0.950

Table V
MODALITE BAZLI TEST STRATEJILERI VE DENEYSEL YORUM NOTLARI

Modalite	Test Stratejisi	Temel Klinik / Teknik Rol	Yorum Notu
Slit-lamp	Ayrı test seti	Ön segment patolojileri arasında üveit ayrımı	Üveit, katarakt, konjonktivit ve göz kapağı hastalıkları gibi farklı ön segment sınıfları arasında ayırt edici performans göstermiştir.
CFP	Ayrı test seti + TTA	Posterior segment ve koryoretinal bulguların analizi	Yüksek performans elde edilmiştir; ancak veri seti belirgin biçimde dengesizdir ve pozitif test örneği sayısı sınırlıdır.
OCTA	Ayrı test seti + TTA	Retinal mikrovasküler patern analizi	Diğer modalitelere göre daha düşük F1 skoruna sahiptir; buna rağmen AUC değeri mikrovasküler bilginin tamamlayıcı değer taşıdığını göstermektedir.
B-scan OCT	5-fold aggregated test	Retinal kesitsel yapısal bulguların analizi	Gerçek üveit görüntü sayısı sınırlıdır. Sentetik üveit görüntüleri yalnızca eğitim setinde kullanılmış, test aşamasına dahil edilmemiştir.
AS-OCT	Ayrı test seti	Anterior segment yapısal sınıflandırma ve segmentasyon	Doğrudan insan üveit AS-OCT verisiyle eğitilmiş klinik tanı modeli değildir; anterior segment yapısal analizini destekleyen proxy modül olarak değerlendirilmelidir.

Confusion matrix sonuçlarına göre model 29 üveit vakasının 27'sini doğru sınıflandırmış, yalnızca 2 üveit vakasını kaçırmıştır. Non-üveit sınıfında ise 168 görüntünün 164'ü doğru sınıflandırılmış, 4 görüntü yanlış pozitif olarak değerlendirilmiştir. Bu sonuç, modelin yalnızca sağlıklı ve hasta görüntülerini ayırmadığını; katarakt, konjonktivit ve göz kapağı hastalıkları gibi diğer ön segment patolojileri arasından üveit bulgularını ayırt etmeye çalıştığını göstermesi bakımından önemlidir.

Slit-lamp modeli, precision ve recall arasında dengeli bir dağılım göstermiştir. Bu durum, modelin hem üveit vakalarını kaçırmama hem de gereksiz yanlış alarm üretmeme açısından makul bir denge kurduğunu göstermektedir. Ön segment görüntüleri üzerinden çalışan bir karar destek sistemi için bu denge klinik kullanım senaryosu açısından anlamlıdır.

C. CFP Modeli Sonuçları

CFP modeli, 870 renkli fundus görüntüsü üzerinde eğitilmiş ve test-time augmentation ile birlikte optimal eşik değeri kullanılarak değerlendirilmiştir. Veri seti 63 üveit ve 807 non-üveit görüntüsünden oluştuğu için sınıf dengesizliği bu modalitedeki temel zorluktur. Bu nedenle eğitim aşamasında *WeightedRandomSampler* ve *pos_weight* birlikte kullanılmış, değerlendirme aşamasında ise TTA ve doğrulama seti üzerinde belirlenen eşik değeri uygulanmıştır.

Model test setinde 0.992 accuracy, 0.900 precision, 1.000 recall, 0.947 F1 skoru ve 0.998 ROC AUC değerlerine ulaşmıştır.

Confusion matrix sonuçlarında test setindeki tüm üveit görüntüleri doğru sınıflandırılmış, yalnızca bir non-üveit görüntüsü yanlış pozitif olarak değerlendirilmiştir. Bu durum, modelin posterior segment görüntülerinde üveit ile ilişkili koryoretinal bulguları yakalama kapasitesinin yüksek olduğunu göstermektedir.

Bununla birlikte CFP sonuçları, test setindeki üveit görüntü sayısının düşük olması nedeniyle dikkatli yorumlanmalıdır. Yüksek recall değeri klinik tarama açısından olumlu olmakla birlikte, daha geniş ve farklı üveit alt tiplerini içeren bağımsız test setleriyle doğrulanmadan genellenebilir klinik performans iddiası taşımamalıdır.

D. OCTA Modeli Sonuçları

OCTA modeli, toplam 525 görüntüden oluşan bir veri seti üzerinde geliştirilmiştir. Veri setinde aktif ve inaktif üveit görüntüleri pozitif sınıf olarak, sağlıklı kontrol görüntüleri ise negatif sınıf olarak ele alınmıştır. Aynı hastaya veya göze ait superficial ve deep vasküler katman görüntülerinin farklı split'lere dağılmasını önlemek için grup tabanlı bölme yaklaşımı uygulanmıştır.

ResNet-18 tabanlı OCTA modeli, test-time augmentation sonrasında 0.843 accuracy, 0.742 precision, 0.821 recall, 0.780 F1 skoru ve 0.910 ROC AUC değerlerine ulaşmıştır. Diğer modalitelere kıyasla daha düşük F1 skoruna sahip olmasına rağmen, OCTA modelinin AUC değerinin 0.910 olması, retinal

mikrovasküler paternlerin üveit ile kontrol sınıfı arasında ayırt edici bilgi taşıdığını göstermektedir.

OCTA modeli, sistemin en gerçekçi zorluklarından birini temsil etmektedir. Veri setinde cihaz heterojenliği, kontrol verisinin farklı kaynaktan gelmesi, üveit olgularının ise sınırlı cihaz ve hastalık dağılımı içinde yer alması model performansını doğrudan etkilemektedir. Buna rağmen elde edilen sonuçlar, OCTA modalitesinin multimodal karar destek sistemi içinde tamamlayıcı bilgi sağlayabileceğini düşündürmektedir.

E. B-scan OCT Modeli Sonuçları

B-scan OCT modalitesi, gerçek üveit görüntü sayısının en sınırlı olduğu modalitelerden biridir. Bu nedenle model geliştirme sürecinde üç katmanlı transfer learning yaklaşımı uygulanmıştır. İlk aşamada ImageNet ön-eğitilmiş ResNet-18 omurgası kullanılmış, ikinci aşamada Kermany retinal OCT veri seti ile OCT alanına özgü özelliklerin öğrenilmesi sağlanmış, üçüncü aşamada ise hedef üveit-normal ayrımı için ince ayar yapılmıştır.

Model, 5-fold çapraz doğrulama stratejisi ile değerlendirilmiştir. Aggregated değerlendirme sonucunda 0.999 accuracy, 0.818 precision, 1.000 recall, 0.900 F1 skoru ve 1.000 ROC AUC değeri elde edilmiştir. Tüm gerçek üveit görüntülerinin doğru sınıflandırılması, modelin B-scan OCT görüntülerinde üveit ile ilişkili yapısal örüntüleri yakalayabildiğini göstermektedir.

Ancak bu sonuçlar, gerçek pozitif üveit görüntü sayısının yalnızca 27 olması nedeniyle kontrollü şekilde yorumlanmalıdır. Sentetik üveit görüntüleri yalnızca eğitim setinde kullanılmış ve test setine dahil edilmemiştir; bu durum değerlendirme bütünlüğü açısından doğru bir yaklaşımdır. Buna rağmen daha geniş, hasta-bazlı ve farklı OCT cihazlarından elde edilmiş klinik veri setleriyle harici doğrulama yapılmadan modelin klinik genellenebilirliği sınırlı kabul edilmelidir.

F. AS-OCT Modeli Sonuçları

AS-OCT modülü, sınıflandırma ve segmentasyon olmak üzere iki tamamlayıcı görevden oluşmaktadır. Sınıflandırma aşamasında MCOA veri seti üzerinde normal ve anormal anterior segment yapısal bulguları ayrıştırılmıştır. Segmentasyon aşamasında ise U-Net tabanlı model ile kornea, iris, ön kamara ve lens gibi anatomik yapıların piksel düzeyinde görselleştirilmesi hedeflenmiştir.

Sınıflandırıcı model yaklaşık 0.940 accuracy, 0.920 F1 skoru ve 0.950 ROC AUC değerlerine ulaşmıştır. Bu sonuçlar, AS-OCT görüntülerindeki yapısal anterior segment anormalliklerinin derin öğrenme ile ayırt edilebilir olduğunu göstermektedir. U-Net segmentasyon çıktıları ise model kararlarının anatomik bağlamda yorumlanabilmesine yardımcı olan ek bir açıklanabilirlik katmanı sağlamaktadır.

Bununla birlikte AS-OCT modülü, çalışmanın diğer üveit sınıflandırma modellerinden farklı olarak doğrudan insan üveit AS-OCT veri seti üzerinde eğitilmemiştir. Bu nedenle AS-OCT modeli, üveitin doğrudan tanısı için değil; anterior segment yapısal analizini destekleyen ve ileride gerçek insan AS-OCT üveit verileriyle genişletilebilecek yardımcı bir modül olarak değerlendirilmelidir.

G. Model Karşılaştırması ve Klinik Yorum

Modalite bazlı sonuçlar, üveit tanısının tek bir görüntüleme yöntemiyle sınırlı değerlendirilemeyeceğini desteklemektedir. Slit-lamp modeli anterior segment bulgularını, CFP modeli posterior segment ve koryoretinal lezyonları, OCTA modeli mikrovasküler paternleri, B-scan OCT modeli retinal kesitsel yapısal değişiklikleri, AS-OCT modeli ise anterior segmentin kesitsel ve anatomik özelliklerini analiz etmektedir. Bu nedenle her model farklı bir klinik bilgi alanına karşılık gelmektedir.

Bu çalışmada geliştirilen sistemin temel değeri, her modalite eden elde edilen model çıktısını tek bir karar destek mimarisi içinde çalıştırabilmesidir. Mevcut aşamada bu modeller hasta-bazlı eşleşmiş veriler üzerinde gerçek multimodal füzyon yapmamaktadır. Ancak her modelin olasılık skoru üretmesi, gelecekte skor düzeyi füzyon, karar düzeyi füzyon veya meta-sınıflandırıcı tabanlı geç füzyon yaklaşımlarının uygulanmasına imkân verecek bir altyapı sağlamaktadır.

Genel olarak CFP, slit-lamp, B-scan OCT ve AS-OCT modellerinde yüksek performans değerleri elde edilmiştir. OCTA modeli ise daha düşük F1 skoruna rağmen AUC açısından kabul edilebilir bir ayırt edicilik göstermiştir. Bu tablo, farklı modalitelerin farklı zorluk düzeylerine sahip olduğunu ve veri kalitesi, sınıf dağılımı, cihaz heterojenliği ve klinik etiketleme kalitesinin model performansını doğrudan etkilediğini göstermektedir.

H. Açıklanabilirlik Çıktıları

Sınıflandırıcı modellerin karar mekanizmalarını görsel olarak değerlendirmek amacıyla Grad-CAM ısı haritaları üretilmiştir. Slit-lamp, CFP, OCTA ve B-scan OCT modellerinde Grad-CAM çıktıları, modelin sınıflandırma kararına katkı veren görüntü bölgelerini vurgulamak için kullanılmıştır. AS-OCT modülünde ise Grad-CAM'e ek olarak U-Net segmentasyon maskeleri ile anatomik yapılar görselleştirilmiştir.

Açıklanabilirlik çıktıları, sistemin yalnızca sayısal olasılık üretmesini değil, aynı zamanda model kararının hangi görüntü bölgeleriyle ilişkili olabileceğini göstermesini sağlamaktadır. Modalite bazlı temsili açıklanabilirlik çıktıları Şekil 4 üzerinde gösterilmiştir. Bu durum, klinisyenin model çıktısını sorgulayabilmesi ve olası yanlış pozitif veya yanlış negatif durumlarda görsel gerekçeyi değerlendirebilmesi açısından önemlidir. Bununla birlikte Grad-CAM çıktıları kesin klinik kanıt olarak değil, model davranışını yorumlamaya yardımcı olan nitel görsel açıklamalar olarak ele alınmalıdır.

IV. TARTIŞMA

Bu çalışmada, üveit tanısına yönelik farklı oftalmolojik görüntüleme modaliteleri için bağımsız derin öğrenme tabanlı uzman modeller geliştirilmiş ve bu modeller açıklanabilir bir karar destek prototipi altında birleştirilmiştir. Elde edilen sonuçlar, slit-lamp, CFP, OCTA, B-scan OCT ve AS-OCT gibi farklı modalitelerin üveit veya üveit ile ilişkili yapısal bulgular hakkında tamamlayıcı bilgi taşıdığını göstermektedir. Bu durum, üveitin klinik doğasıyla uyumludur; çünkü üveit tek bir anatomik bölgeyle sınırlı olmayan, anterior segmentten










	Original Image	Grad-CAM / Heatmap	Segmentation Mask (AS-OCT)
A) Slit-lamp	 EfficientNet-B0		—
B) CFP	 EfficientNet-B0 + TTA		—
C) OCTA	 ResNet-18 + TTA		—
D) B-scan OCT	 ResNet-18 (Kermany pretraining)		—
E) AS-OCT (Segmentation)	 EfficientNet-B0 + U-Net	—	 - Cornea - Iris - Anterior Chamber - Lens

Figure 4. Representative Grad-CAM and AS-OCT segmentation examples for qualitative model explainability.

posterior segmente kadar farklı dokuları etkileyebilen heterojen bir inflamatuvar hastalık grubudur.

Çalışmanın temel yaklaşımı, doğrudan hasta-bazlı multimodal füzyon yapmak yerine, her modalite için ayrı bir uzman model geliştirmek ve bu modelleri ortak bir sistem mimarisi altında çalıştırmaktır. Bu tercih, mevcut veri koşullarının doğal bir sonucudur. Üveit alanında hasta-bazlı eşleşmiş ve beş farklı görüntüleme modalitesini aynı anda içeren açık erişimli veri setlerinin bulunmaması, doğrudan erken füzyon veya tam multimodal öğrenme yaklaşımlarını sınırlamaktadır. Bu nedenle bu çalışmada geliştirilen Faz-1 yapı, gerçek multimodal füzyondan önce gerekli olan modaliteye özgü uzman model katmanını oluşturmaktadır.

Literatürdeki mevcut çalışmalar incelendiğinde, üveit alanında yapay zekâ uygulamalarının çoğunlukla belirli bir modaliteye, belirli bir klinik bulguya ya da belirli bir etiyolojik probleme odaklandığı görülmektedir. Örneğin, Sun ve ark. deneysel otoimmün üveit modelinde fundus görüntüleri üzerinden derin öğrenme ile hastalık şiddeti sınıflandırması gerçekleştirmiştir [12]. Pichi ve ark. AS-OCT görüntüleri üzerinden uveitik keratik presipitatların nicel analizini yaparak anterior segmentte objektif ölçüm potansiyelini göstermiştir [5]. Putera ve ark. retinal vasküler parametreleri kullanarak ocular tüberküloz ve farklı üveit etiyolojileri arasında ayırıcı tanıya katkı sağlayabilecek bir yaklaşım sunmuştur [14]. Jacquot ve ark. ise klinik ve demografik değişkenler üzerinden

üveitin etiyolojik tanısını tahmin etmeye yönelik bir yapay sinir ağı yaklaşımı geliştirmiştir [15]. Bu çalışmalar üveitte yapay zekânın potansiyelini ortaya koysa da, çoğu çalışma tek modalite veya tek karar görevi ile sınırlıdır. Bu çalışmanın farklılaştığı nokta, üveit tanısında kullanılan birden fazla görüntüleme modalitesini tek bir modüler karar destek sistemi içinde değerlendirme hedefidir.

Ultra-widefield fundus ve fluorescein angiography görüntüleri üzerinde yapılan güncel çok hastalıklı sınıflandırma çalışmaları da fundus tabanlı derin öğrenme modellerinin geniş hastalık spektrumlarında güçlü ayırt edici performans sağlayabileceğini göstermektedir [10], [24]. Slit-lamp modelinin üveiti katarakt, konjonktivit ve göz kapağı hastalıkları gibi diğer ön segment patolojilerinden ayırmaya çalışması, görevi yalnızca sağlıklı-hasta ayırımından daha gerçekçi hale getirmiştir. CFP modelinde elde edilen yüksek recall değeri, posterior segment ve koryoretinal bulguların üveit ayrımı için güçlü görsel ipuçları taşıyabileceğini göstermektedir. Ancak CFP veri setindeki pozitif sınıf sayısının düşük olması, bu sonucun daha geniş ve bağımsız veri setlerinde doğrulanmasını gerekli kılmaktadır.

OCTA modeli diğer modalitelere kıyasla daha düşük F1 skora sahip olmasına rağmen, AUC değerinin 0.910 düzeyinde olması retinal vasküler paternlerin üveit ayrımında bilgi taşıdığını göstermektedir. Retinal damar segmentasyonu ve vasküler yapı analizine ilişkin güncel derlemeler de düşük

kontrast, ince damar yapıları, lezyon varlığı ve cihaz farklılıklarının otomatik analiz için temel zorluklar oluşturduğunu göstermektedir [25]. Bu nedenle OCTA modelinin performansı, yalnızca sayısal olarak diğer modellerden düşük olması nedeniyle başarısız olarak yorumlanmamalıdır. Aksine, OCTA modalitesi daha zor ve değişken bir görsel problem sunmakta; buna rağmen sistem içinde tamamlayıcı bilgi kaynağı olarak yer alabilecek bir ayırt edicilik göstermektedir.

B-scan OCT modelinde kullanılan üç katmanlı transfer learning stratejisi, veri kıtlığı problemini azaltmaya yönelik önemli bir teknik tercihtir. Kermany retinal OCT veri seti üzerinde ön-eğitim yapılması, modelin genel doğal görüntü özelliklerinden sonra OCT alanına özgü yapısal özellikleri öğrenmesine olanak sağlamıştır. Bunun ardından sınırlı üveit verisiyle yapılan ince ayar, modelin hedef göreve adapte edilmesini sağlamıştır. Sentetik üveit görüntülerinin yalnızca eğitim setinde kullanılması ve test setine dahil edilmemesi, değerlendirme bütünlüğü açısından doğru bir yaklaşımdır. Bununla birlikte, gerçek pozitif üveit görüntü sayısının düşük olması nedeniyle B-scan OCT sonuçları klinik genellenebilirlik açısından temkinli yorumlanmalıdır.

AS-OCT modülü, bu çalışmada diğer modalitelerden farklı bir konuma sahiptir. Bu modül doğrudan insan üveit AS-OCT veri seti üzerinde eğitilmiş bir üveit tanı modeli değildir. Bunun yerine anterior segment yapısal anormalliklerinin sınıflandırılması ve anatomik segmentasyon ile açıklanabilirliğin desteklenmesi amacıyla geliştirilmiş yardımcı bir modüldür. Bu nedenle AS-OCT sonuçları, doğrudan anterior üveit tanısı olarak değil, ileride insan AS-OCT üveit verileriyle genişletilebilecek bir anterior segment analiz altyapısı olarak değerlendirilmelidir. Bu ayrım, çalışmanın bilimsel doğruluğu açısından kritiktir.

Çalışmanın bir diğer önemli yönü açıklanabilirlik katmanıdır. Tıbbi görüntüleme tabanlı yapay zekâ sistemlerinde yalnızca sınıf etiketi veya olasılık değeri üretmek klinik açıdan yeterli değildir. Klinisyenin modelin hangi görüntü bölgelerine odaklandığını görebilmesi, model çıktısının sorgulanabilirliğini artırır. Bu çalışmada Grad-CAM kullanılarak sınıflandırıcı modellerin karar bölgeleri görselleştirilmiş, AS-OCT modülünde ise U-Net segmentasyon çıktılarıyla anatomik yapıların ayrıştırılması hedeflenmiştir. Bu yaklaşım, sistemin bir kara kutu sınıflandırıcı olarak kalmasını engellemekte ve kullanıcıya görsel gerekçe sunmaktadır. Bununla birlikte Grad-CAM çıktılarının doğrudan klinik kanıt olarak değil, model davranışını yorumlamaya yardımcı olan nitel açıklama araçları olarak değerlendirilmesi gerekir.

Bu çalışmanın sınırlılıkları açık biçimde belirtilmelidir. İlk olarak, çalışma hasta-bazlı eşleşmiş multimodal veri seti üzerinde gerçekleştirilmemiştir. Bu nedenle mevcut sistem gerçek anlamda erken füzyon veya hasta düzeyinde geç füzyon yapan bir multimodal tanı modeli değildir. İkinci olarak, veri setleri farklı kaynaklardan birleştirilmiştir ve bazı modalitelerde cihaz, hasta popülasyonu ve görüntüleme protokolü açısından heterojenlik bulunmaktadır. Üçüncü olarak, bazı modalitelerde pozitif sınıf sayısı oldukça sınırlıdır. Bu durum özellikle CFP ve B-scan OCT sonuçlarının daha geniş veri

setlerinde doğrulanmasını gerektirir. Dördüncü olarak, AS-OCT modülü doğrudan insan üveit verisi yerine proxy anterior segment veri setleriyle geliştirilmiştir. Beşinci olarak, geliştirilen modellerin prospektif klinik değerlendirmesi ve uzman hekimlerle karşılaştırmalı validasyonu henüz yapılmamıştır.

Bu sınırlılıklara rağmen çalışma, üveit gibi heterojen ve multimodal değerlendirme gerektiren bir hastalık için uygulanabilir bir yapay zekâ karar destek altyapısı ortaya koymaktadır. Özellikle farklı modaliteler için ayrı uzman modellerin geliştirilmesi, ileride hasta-bazlı eşleşmiş veriler elde edildiğinde skor düzeyi füzyon, karar düzeyi füzyon veya meta-sınıflandırıcı tabanlı geç füzyon yöntemlerinin denenmesine olanak sağlayacaktır. Böylece mevcut çalışma, nihai multimodal sistemin tamamlanmış klinik versiyonu olarak değil, bu sisteme giden teknik altyapının ilk aşaması olarak değerlendirilmelidir.

V. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışmada, üveit tanısını desteklemek amacıyla beş farklı oftalmolojik görüntüleme modalitesini kapsayan açıklanabilir yapay zekâ tabanlı modüler bir karar destek sistemi geliştirilmiştir. Slit-lamp, CFP, OCTA, B-scan OCT ve AS-OCT görüntüleri için ayrı uzman modeller eğitilmiş; bu modellerin çıktılarının ortak bir karar destek prototipi altında çalıştırılabileceği modüler bir yapı oluşturulmuştur. Her modalite için veri yapısına ve klinik kullanım amacına uygun farklı derin öğrenme mimarileri, veri ön işleme stratejileri, sınıf dengesizliği yönetimi ve değerlendirme yöntemleri uygulanmıştır.

Elde edilen deneysel sonuçlar, modaliteye özgü uzman model yaklaşımının üveit ve üveit ile ilişkili görüntü bulgularının otomatik analizinde uygulanabilir olduğunu göstermektedir. Slit-lamp, CFP, B-scan OCT ve AS-OCT modellerinde yüksek F1 ve AUC değerleri elde edilirken, OCTA modeli de retinal vasküler paternlerin üveit ayrımında tamamlayıcı bilgi sağlayabileceğini göstermiştir. Ayrıca Grad-CAM ve AS-OCT segmentasyon çıktıları ile sistemin kararlarının görsel olarak açıklanabilir hale getirilmesi hedeflenmiştir. Bu yaklaşım, tıbbi görüntüleme tabanlı karar destek sistemlerinde önemli olan yorumlanabilirlik ihtiyacına katkı sağlamaktadır.

Çalışmanın en önemli katkısı, üveit gibi heterojen ve çoklu görüntüleme gerektiren bir hastalık için tek bir model yerine modaliteye özgü uzman modellerden oluşan genişletilebilir bir sistem mimarisi sunmasıdır. Mevcut yapı, hasta-bazlı eşleşmiş multimodal veri bulunmadığı için doğrudan erken füzyon veya hasta düzeyinde gerçek multimodal sınıflandırma gerçekleştirmemektedir. Bunun yerine, ileride eşleşmiş hasta verileri elde edildiğinde uzman model çıktılarının skor düzeyi, karar düzeyi veya meta-sınıflandırıcı tabanlı geç füzyon yöntemleriyle birleştirilebileceği bir Faz-1 altyapı sağlamaktadır.

Gelecek çalışmalarda öncelikli hedef, aynı hastaya ait birden fazla görüntüleme modalitesini içeren eşleşmiş klinik veri setlerinin oluşturulmasıdır. Bu tür veri setleri elde edildiğinde, mevcut uzman modellerin ürettiği olasılık skorları ve görsel açıklama çıktıları kullanılarak gerçek multimodal füzyon stratejileri test edilebilecektir. Ayrıca modellerin farklı klinik merkezlerden, farklı cihazlardan ve farklı hasta popülasyonlarından elde edilen bağımsız veri setleri üzerinde doğrulan-

ması gerekmektedir. Bu doğrulama süreci, sistemin genellenilebilirliğini ve klinik uygulanabilirliğini değerlendirmek açısından kritik öneme sahiptir.

Bunun yanında, AS-OCT modülünün gerçek insan üveit AS-OCT verileriyle genişletilmesi, OCTA modelinin daha dengeli ve cihaz çeşitliliği içeren veri setleriyle yeniden eğitilmesi ve B-scan OCT modelinin daha fazla gerçek üveit örneğiyle doğrulanması planlanmaktadır. Açıklanabilirlik tarafında ise Grad-CAM çıktıların uzman hekimler tarafından nitel olarak değerlendirilmesi ve segmentasyon tabanlı açıklamaların klinik bulgularla ilişkilendirilmesi çalışmanın gelecekteki önemli aşamalarından biri olacaktır.

Sonuç olarak, bu çalışma üveit tanısına yönelik açıklanabilir, modüler ve genişletilebilir bir yapay zekâ karar destek sistemi için uygulanabilir bir teknik temel sunmaktadır. Geliştirilen sistem, mevcut haliyle klinisyenin kararını destekleyen deneysel bir prototip olarak değerlendirilmelidir. Ancak mimari yapısı, modaliteye özgü uzman modelleri ve açıklanabilirlik katmanı sayesinde ileride daha büyük klinik veri setleriyle güçlendirilerek gerçek multimodal üveit karar destek sistemine dönüştürülebilecek potansiyele sahiptir.

TEŞEKKÜR

Bu çalışma, TÜBİTAK 2209-A Üniversite Öğrencileri Araştırma Projeleri Destekleme Programı kapsamında desteklenen araştırma projesi doğrultusunda yürütülmüştür.

REFERENCES

- [1] Standardization of Uveitis Nomenclature (SUN) Working Group, "Classification criteria for uveitis: Standardization of uveitis nomenclature (sun) working group," *American Journal of Ophthalmology*, 2021.
- [2] D. Wakefield and J. H. Chang, "Epidemiology of uveitis," *International Ophthalmology Clinics*, vol. 45, no. 2, pp. 1–13, 2005.
- [3] T. Tsiroki, A. Dastiridou, C. Symeonidis, O. Tounakaki, I. Brazitikou, C. Kalogeropoulos, and S. Androudi, "A focus on the epidemiology of uveitis," *Ocular Immunology and Inflammation*, vol. 26, no. 1, pp. 2–16, 2018.
- [4] K. A. Joltikov and A.-M. Lobo-Chan, "Epidemiology and risk factors in non-infectious uveitis: A systematic review," *Frontiers in Medicine*, vol. 8, p. 695904, 2021.
- [5] F. Pichi, G. Ometto, A. Invernizzi, S. Hay, H. Chaudhry, S. Aljneibi, G. Montesano, F. Zicarelli, and P. Neri, "Automated quantification of uveitic keratic precipitates by use of anterior segment optical coherence tomography," *Clinical & Experimental Ophthalmology*, vol. 51, pp. 790–798, 2023.
- [6] M. D. Abramoff, M. K. Garvin, and M. Sonka, "Retinal imaging and image analysis," *IEEE Reviews in Biomedical Engineering*, vol. 3, pp. 169–208, 2010.
- [7] U. Schmidt-Erfurth, A. Sadeghipour, B. S. Gerendas, S. M. Waldstein, and H. Bogunović, "Artificial intelligence in retina," *Progress in Retinal and Eye Research*, vol. 67, pp. 1–29, 2018.
- [8] T. Oshika, "Artificial intelligence applications in ophthalmology," *JMA Journal*, vol. 8, no. 1, pp. 66–75, 2025.
- [9] H. Bilal, A. Keles, and M. Bendeche, "Advances in disease detection through retinal imaging: A systematic review," *Computers in Biology and Medicine*, vol. 194, p. 110412, 2025.
- [10] M.-M. Duan and X. Tu, "Deep learning-based classification of multiple fundus diseases using ultra-widefield images," *Frontiers in Cell and Developmental Biology*, vol. 13, p. 1630667, 2025.
- [11] X. Gu, Y. Zhou, J. Zhao, H. Zhang, X. Pan, B. Li, B. Zhang, Y. Wang, S. Xia, H. Lin, J. Wang, D. Ding, X. Li, S. Wu, J. Yang, and Y. Chen, "Diagnostic performance and generalizability of deep learning for multiple retinal diseases using bimodal imaging of fundus photography and optical coherence tomography," *Frontiers in Cell and Developmental Biology*, vol. 13, p. 1665173, 2025.
- [12] J. Sun, X. Huang, C. Egwuagu, Y. Badr, S. C. Dryden, B. T. Fowler, and S. Yousefi, "Identifying mouse autoimmune uveitis from fundus photographs using deep learning," *Translational Vision Science & Technology*, vol. 9, no. 2, p. 59, 2020.
- [13] Y. Mellak, A. Achim, A. Ward, L. Nicholson, and X. Descombes, "A machine learning framework for the quantification of experimental uveitis in murine oet," *Biomedical Optics Express*, vol. 14, no. 7, pp. 3413–3430, 2023.
- [14] I. Putera, J. D. Vargas Quiros, S. M. Rombach, W. A. Dik, P. M. van Hagen, and R. L. D. Nora, "Artificial intelligence-based uveitis diagnosis through retinal vasculature analysis: A paradigm shift in ocular tuberculosis," *Ophthalmology and Therapy*, vol. 14, pp. 717–732, 2025.
- [15] R. Jacquot, L. Ren, T. Wang, I. Mellahk, A. Duclos, L. Kodjikian, Y. Jamilloux, D. Stanescu, and P. Sève, "Neural networks for predicting etiological diagnosis of uveitis," *Eye*, vol. 39, pp. 992–1002, 2025.
- [16] S. R. B. Murugan, S. Sanjay, A. Somanath, P. Mahendradas, A. Patil, K. Kaur, and B. Gurnani, "Artificial intelligence in uveitis: Innovations in diagnosis and therapeutic strategies," *Clinical Ophthalmology*, vol. 18, pp. 3753–3766, 2024.
- [17] M. Tan and Q. V. Le, "Efficientnet: Rethinking model scaling for convolutional neural networks," in *Proceedings of the 36th International Conference on Machine Learning*, 2019, pp. 6105–6114.
- [18] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 770–778.
- [19] D. S. Kermany, M. Goldbaum, W. Cai, C. C. S. Valentim, H. Liang, S. L. Baxter, A. McKeown, G. Yang, X. Wu, F. Yan, J. Dong, M. K. Prasadha, J. Pei, M. Y. L. Ting, J. Zhu, C. Li, S. Hewett, J. Dong, I. Ziyar, A. Shi, R. Zhang, L. Zheng, R. Hou, W. Shi, X. Fu, Y. Duan, V. A. N. Huu, C. Wen, E. D. Zhang, C. L. Zhang, O. Li, X. Wang, M. A. Singer, X. Sun, J. Xu, A. Tafreshi, M. A. Lewis, H. Xia, and K. Zhang, "Identifying medical diagnoses and treatable diseases by image-based deep learning," *Cell*, vol. 172, no. 5, pp. 1122–1131.e9, 2018.
- [20] O. Ronneberger, P. Fischer, and T. Brox, "U-net: Convolutional networks for biomedical image segmentation," in *Medical Image Computing and Computer-Assisted Intervention*, 2015, pp. 234–241.
- [21] A. Howard, M. Sandler, G. Chu, L.-C. Chen, B. Chen, M. Tan, W. Wang, Y. Zhu, R. Pang, V. Vasudevan, Q. V. Le, and H. Adam, "Searching for mobilenetv3," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2019, pp. 1314–1324.
- [22] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," *International Conference on Learning Representations*, 2019.
- [23] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-cam: Visual explanations from deep networks via gradient-based localization," in *Proceedings of the IEEE International Conference on Computer Vision*, 2017, pp. 618–626.
- [24] X. Wang, H. Li, H. Zheng, G. Sun, W. Wang, Z. Yi, A. Xu, L. He, H. Wang, W. Jia, Z. Li, C. Li, M. Ye, B. Du, and C. Chen, "Automatic detection of 30 fundus diseases using ultra-widefield fluorescein angiography with deep experts aggregation," *Ophthalmology and Therapy*, vol. 13, pp. 1125–1144, 2024.
- [25] Z. Liu, M. S. Sunar, T. S. Tan, and W. H. Wan Hitam, "Deep learning for retinal vessel segmentation: A systematic review of techniques and applications," *Medical & Biological Engineering & Computing*, vol. 63, pp. 2191–2208, 2025.