

ANKARA ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
YAZILIM MÜHENDİSLİĞİ BÖLÜMÜ



BİTİRME PROJESİ RAPORU

**Multimodal Görüntü Analizi ile Üveit (Göz İçi
Tabakasının İltihabı) Tanısı için Yapay Zekâ
Tabanlı Açıklanabilir Karar Destek Sistemi**

Recep ÖZTÜRK

22290380

Dr. Öğr. Üyesi İnan KAZANCI

01 / 2026

REVİZYON GEÇMİŞİ

Versiyon No.	Tarih	Açıklama
Versiyon 1.0	11/01/2026	Ara Tasarım Raporu oluşturuldu

ÖZET

Üveit, göz içi dokuların inflamasyonu ile seyreden ve klinik sunumu heterojen olan bir hastalık grubudur. Tanı ve izlem süreci çoğunlukla tek bir bulguya dayanmayıp anterior segment muayenesi (slit-lamp), arka segment değerlendirmesi (renkli fundus fotoğrafı) ve retina katmanlarının yapısal analizi (OCT) gibi birden fazla görüntüleme kaynağının birlikte yorumlanmasını gerektirir. Bu bitirme projesi, üveit olgularında multimodal görüntü analizi yaklaşımıyla açıklanabilir yapay zekâ tabanlı bir karar destek sistemi çerçevesi geliştirmeyi hedeflemektedir. Mevcut veri koşullarında hasta bazında eşleştirilmiş multimodal örnekler bulunmadığından çalışma, aşamalı kapsam prensibiyle planlanmıştır. Faz-1’de mevcut modaliteler için unimodal baseline modeller kurulacaktır: slit-lamp havuzunda “üveit vs. üveit-dışı” ikili sınıflandırma; OCT (B-scan) havuzunda 4 sınıflı sınıflandırma (intermediate-posterior, panuveitis, normal, RRD-PVR). Fundus tarafında RFMiD verisi, üveit ile ilişkili olabilecek inflamasyon etiketlerinin (CRS, RS, VS, TV) yardımcı analiz hattı olarak ele alınacaktır. Eğitim ve değerlendirmede sınıf dengesizliği için ağırlıklı kayıp/dengeli örnekleme, OCT için k-fold çapraz doğrulama; açıklanabilirlik için Grad-CAM benzeri ısı haritaları planlanmıştır. Bu ara tasarım raporu kapsamında literatür taraması ve karşılaştırmalı çizelge oluşturulmuş, veri envanteri çıkarılmış, RFMiD inflamasyon alt kümesi nicel olarak analiz edilmiştir. Eşleştirilmiş veri sağlanması durumunda Faz-2’de multimodal fusion ve daha ileri karar destek hedefleri değerlendirilecektir.

Anahtar Kelimeler: Üveit; Multimodal görüntü analizi; Açıklanabilir yapay zekâ; Slit-lamp; Renkli fundus fotoğrafı (CFP); Retina OCT (B-scan); Transfer öğrenme; Grad-CAM.

İÇİNDEKİLER DİZİNİ

ÖZET	ii
İÇİNDEKİLER DİZİNİ.....	iii
KISALTMALAR DİZİNİ.....	v
ÇİZELGELER DİZİNİ	vii
1. GİRİŞ	1
1.1. Amaç	1
1.2. Kapsam	2
1.3. Proje Paydaşları	2
1.4. Problem Durumu.....	3
1.5. Mevcut sistemlerin analizi	3
1.6. Önerilen Çözüm Yöntemleri.....	3
1.7. Kullanılacak Teknolojiler	4
2. LİTERATÜR	5
2.1. Fundus (CFP) Tabanlı Yaklaşımlar	6
2.2. Floresein Anjiyografi ve Retinal Vaskülit Segmentasyon.....	7
2.3. Retina OCT (B-scan) Tabanlı Şiddet/Grading Yaklaşımları	7
2.4. Ön Segment (Slit-Lamp ve AS-OCT) Tabanlı Yaklaşımlar.....	7
2.5. Etiyoloji Tahmini: Görüntü Dışı (Klinik Veri) Yaklaşımlar	8
2.6. Genel Değerlendirme ve Bu Projenin Konumlanması.....	8
3. YÖNTEM	10
3.1. Genel Yaklaşım ve Proje Fazları	10
3.2. Veri Setleri ve Etiketleme Şeması	10
3.2.1. Anterior Segment Slit-Lamp Veri Havuzu (M1)	11
3.2.2. Renkli Fundus Veri Havuzları (M2)	11
3.2.3. Retina OCT (B-scan) Veri Havuzu (M3).....	12

3.3.	Veri Ön İşleme ve Standardizasyon.....	12
3.4.	Modelleme Stratejisi (Unimodal Baseline).....	13
3.5.	Eğitim Protokolü ve Sınıf Dengesizliği	13
3.6.	Değerlendirme Tasarımı ve Metrikler	14
3.7.	Açıklanabilirlik (Explainability) Katmanı	15
3.8.	Multimodal Fusion Planı (Veri Koşuluna Bağlı).....	15
3.9.	Uygulama, Deney Yönetimi ve Tekrarlanabilirlik	16
3.10.	Etik, Veri Gizliliği ve Sınırlılıklar	16
4.	GERÇEKLEŞTİRİLEN ÇALIŞMALAR VE BULGULAR.....	17
4.1.	Veri Temini ve Veri Envanteri Çıkarımı	17
4.2.	Veri Yapısı ve Etiketleme Gerçekliği	18
4.3.	Literatür Taraması Çıktısı ve Çizelge 2.1	18
4.4.	RFMiD Etiket Analizi ve “İnflamasyon” Alt Kümesi Ara Çıktıları.....	18
4.5.	Baseline Deney Tasarımının Netleştirilmesi	20
4.6.	Açıklanabilirlik ve Multimodal Genişleme İçin Uygulanabilirlik Değerlendirmesi	20
4.7.	Bölüm Özeti	21
5.	PROJE YÖNETİMİ VE ÇALIŞMA TAKVİMİ	22
5.1.	Proje Yönetimi Yaklaşımı.....	22
5.2.	İş Paketleri ve Sorumluluklar.....	22
5.3.	Çalışma Takvimi ve Kilometre Taşları.....	23
5.4.	Risk Yönetimi ve Önlemler	24
5.5.	Kalite Güvence ve Doğrulama Stratejisi.....	25
5.6.	İletişim ve İzleme.....	26
6.	GELECEK ÇALIŞMALAR	27
7.	SONUÇ.....	29
	KAYNAKLAR	30

KISALTMALAR DİZİNİ

AI: Artificial Intelligence (Yapay Zekâ)

AS-OCT: Anterior Segment Optical Coherence Tomography (Ön Segment Optik Koherens Tomografi)

AUC: Area Under the Curve (Eğri Altı Alan)

BCE: Binary Cross-Entropy (İkili Çapraz Entropi)

CAD: Computer-Aided Diagnosis (Bilgisayar Destekli Tanı)

CFP: Color Fundus Photography (Renkli Fundus Fotoğrafı)

CNN: Convolutional Neural Network (Evrişimli Sinir Ağı)

CRS: Chorioretinitis (Koryoretinit) (RFMiD etiket kısaltması)

DL: Deep Learning (Derin Öğrenme)

FA: Fluorescein Angiography (Flöresein Anjiyografi)

FUS: Fuchs' Uveitis Syndrome (Fuchs Üveit Sendromu)

Grad-CAM: Gradient-weighted Class Activation Mapping (Gradyan Ağırlıklı Sınıf Aktivasyon Haritalama)

K-fold CV: k-fold Cross-Validation (k-katlı Çapraz Doğrulama)

KP: Keratic Precipitates (Keratik Presipitatlar)

ML: Machine Learning (Makine Öğrenmesi)

MLP: Multi-Layer Perceptron (Çok Katmanlı Algılayıcı)

OCT: Optical Coherence Tomography (Optik Koherens Tomografi)

OCT-A: Optical Coherence Tomography Angiography (Optik Koherens Tomografi Anjiyografi)

PVR: Proliferative Vitreoretinopathy (Proliferatif Vitreoretinopati)

RFMiD: Retinal Fundus Multi-Disease Image Dataset (Retinal Fundus Çoklu Hastalık Görüntü Veri Seti)

RRD: Rhegmatogenous Retinal Detachment (Regmatojen Retina Dekolmanı)

ROC-AUC: Receiver Operating Characteristic – Area Under the Curve (ROC Eğrisi – Eğri Altı Alan)

RS: Retinitis (Retinit) (RFMiD etiket kısaltması)

SUN: Standardization of Uveitis Nomenclature (Üveit Adlandırmasının Standardizasyonu)

TB: Tuberculosis (Tüberküloz)

TV: Tortuous Vessels (Tortiyöz Damarlar) (RFMiD etiket kısaltması)

VKH: Vogt–Koyanagi–Harada (Vogt–Koyanagi–Harada sendromu)

VS: Vasculitis (Vaskülit) (RFMiD etiket kısaltması)

WP: Work Package (İş Paketi)

YZ: Yapay Zekâ

YSA: Yapay Sinir Ağları

ÇİZELGELER DİZİNİ

Çizelge 2.1 Üveit tanısında yapay zekâ ile ilgili seçili çalışmaların karşılaştırması ve proje ile kıyaslaması.....	5
Çizelge 4.1 RFMiD_2’de inflamasyonla ilişkili etiketlerin (CRS, RS, VS, TV) dağılımı.....	19
Çizelge 4.2 RFMiD_2’de inflamasyonla ilişkili etiketlerin split bazında oranları (n ve %) ...	19
Çizelge 5.1 İş paketleri, planlanan dönem ve çıktılar	24
Çizelge 5.2 Riskler ve azaltım planı	25

1. GİRİŞ

Üveit, göz içi dokuların inflamasyonu ile seyreden ve klinik sunumu değişkenlik gösteren bir hastalık grubudur. Klinik karar süreci çoğu zaman tek bir bulguya dayanmaz; ön segment muayenesi (slit-lamp), retina değerlendirmesi (renkli fundus), retina katmanlarının yapısal analizi (OCT) ve uygun durumlarda damar yapısının incelenmesi (OCT-A) gibi birden fazla kaynaktan gelen kanıt birlikte yorumlanır. Bu çok kaynaklı yapı, tanı ve izlemde standardizasyon ihtiyacını artırırken, literatürdeki pek çok yapay zekâ çalışmasının tek modalite–tek görev düzeyinde kalması, multimodal entegrasyon ve açıklanabilirlik açısından bir boşluk doğurabilmektedir [1].

Bu bitirme projesi, üveit karar destek problemine çok kipli (multimodal) görüntü analizi perspektifiyle yaklaşmayı hedefler. Proje; farklı modalitelerden gelen bilgiyi bir araya getirebilen ve kararını açıklanabilir çıktılarla destekleyen bir sistem çerçevesi tasarlamayı amaçlar. Bununla birlikte, mevcut veri koşullarında bazı modaliteler için veri bulunmaması ve eldeki veri havuzlarının aynı hastaya ait eşleştirilmiş multimodal setler şeklinde olmaması nedeniyle proje aşamalı yürütülecektir: önce unimodal temel modeller (single-modality experts), veri genişledikçe multimodal fusion aşamasına geçiş.

Aşağıdaki alt bölümlerde projenin amacı, kapsamı, paydaşları, problem tanımı, mevcut sistemlerin analizi, önerilen çözüm yaklaşımı ve kullanılacak teknolojiler sunulmaktadır.

1.1. Amaç

Bu bitirme projesinin temel amacı; seçilen göz görüntüleme modalitelerinden yararlanarak üveit olgularında yapay zekâ tabanlı ve açıklanabilir bir karar destek yaklaşımı geliştirmektir. Proje önerisi ve araştırma önerisi metinlerinde tanımlandığı şekilde hedef; tanıda gecikmeyi azaltmaya katkı sağlamak, anatomik alt tip ayrımı için destek üretmek ve veri/etiket temin edilirse daha ileri aşamada izlemde risk öngörüsüne zemin hazırlamaktır. Proje çıktısının klinik açıdan denetlenebilir olması için model kararlarının görsel açıklamalarla (ör. ısı haritaları) desteklenmesi hedeflenmektedir [1].

1.2. Kapsam

Proje beş temel görüntü modalitesi etrafında kurgulanmıştır:

- M1: Anterior Segment Slit-Lamp Fotoğrafı
- M2: Renkli Fundus Fotoğrafı (CFP)
- M3: Retina OCT (B-scan)
- M4: OCT-A (hedeflenen; veri temini sürmektedir)
- M5: Anterior Segment OCT / AS-OCT (hedeflenen; veri temini sürmektedir)

Bu rapor sürümünde M1–M3 için mevcut veri havuzları bulunmaktadır. Mevcut veri durumu özetle şöyledir:

- M1 (Slit-lamp): Üveit 224, normal 650, diğer hastalıklar 1430 olmak üzere toplam 2304 görüntü (JPG/JPEG, değişken çözünürlük).
- M2 (Fundus): RFMiD (train/val/test ayrımlı) ve ek “1000images” havuzu (1000 görüntü; VKH 14, normal 39, kalan farklı hastalıklar).
- M3 (OCT B-scan): Intermediate–posterior üveit 12, panuveitis 16, normal 28, RRD–PVR 19 olmak üzere toplam 75 görüntü.

Veri havuzlarının aynı hastaya ait eşleştirilmiş multimodal setler olmaması nedeniyle, mevcut aşamada öncelik unimodal baseline modellerin kurulmasıdır. Multimodal fusion, eşleştirilmiş veri sağlandığında uygulanacak hedef yaklaşım olarak konumlandırılacaktır. Etiyoloji (Behçet, tüberküloz vb.) gibi hedefler için gerekli etiketler sağlanmadığı sürece bu raporda ana hedef olmayacak; uygun veri bulunursa “gelecek çalışmalar” kapsamında ele alınacaktır.

1.3. Proje Paydaşları

- Proje yürütücüsü (öğrenci): Veri havuzlarını oluşturma, model geliştirme, değerlendirme ve raporlama.
- Danışman öğretim üyesi: Akademik yönlendirme, yöntem ve rapor formatının doğrulanması.
- Klinik paydaşlar (dolaylı): Çıktıların klinik anlamlılığı ve açıklanabilirlik beklentileri açısından referans.

- Veri sağlayıcıları/dataset sahipleri: Veri erişim koşulları ve veri genişletme imkanlarını belirleyen aktörler.
- Dolaylı nihai faydalanıcı: Hastalar; standardizasyon ve karar desteği üzerinden dolaylı yarar potansiyeli [3].

1.4. Problem Durumu

Üveit değerlendirmesinde temel güçlük; hastalığın heterojen doğası ve kararın çoğu zaman birden fazla modaliteden gelen kanıtlarla verilmesidir. Anatomik sınıflandırma (anterior/intermediate/posterior/panuveitis) klinik raporlama için temel bir çerçeve sunsa da tek başına tüm olguları açıklamakta yetersiz kalabilir [2]. Ayrıca görüntülerin kalite/cihaz farkları, klinisyenler arası yorum değişkenliği ve açıklanabilirlik ihtiyacı, karar destek sistemlerinde standardizasyonu zorunlu kılar [1]. Bu proje, mevcut veri kısıtlarını açıkça yöneterek önce unimodal baselineler üretmeyi, ardından veri uygun oldukça multimodal entegrasyona geçmeyi hedefler.

1.5. Mevcut sistemlerin analizi

Klinik uygulamada üveit, anamnez ve muayene bulgularının yanı sıra slit-lamp, fundus ve OCT/OCT-A gibi görüntüleme sonuçlarının birlikte değerlendirilmesi ile yönetilir. Bu yaklaşım hekim uzmanlığını merkez alır; ancak standardizasyon ve tekrar üretilebilirlik açısından sınırlılıklar barındırabilir. Literatürde yapay zekâ çalışmaları artsa da üveit özelinde veri kısıtı ve multimodal eşleştirme gereksinimi, çalışmaların önemli bir kısmının tek modalite odaklı kalmasına yol açmaktadır [1]. Bu nedenle, bu projede unimodal modellerle başlanması ve eşleştirilmiş veri sağlanınca fusion'a geçilmesi gerçekçi bir stratejidir.

1.6. Önerilen Çözüm Yöntemleri

Önerilen çözüm, modüler ve aşamalı bir mimariye dayanır:

1. Veri hazırlama ve standardizasyon: format/çözünürlük normalizasyonu, temel kalite kontrolleri ve etiket şemasının netleştirilmesi.
2. Unimodal baseline geliştirme (Faz-1): Her modalite için ayrı temel modellerin kurulması. İlk baseline hedefi, slit-lamp görüntülerinde Üveit vs Diğerleri ikili sınıflandırmasıdır (pozitif: 224 üveit; negatif: normal+diğer hastalıklar).
3. Açıklanabilirlik: Unimodal modellerin kararlarını görsel açıklamalarla desteklemek (örn. ısı haritası tabanlı yöntemler) [1].
4. Multimodal fusion (Faz-2): Eşleştirilmiş veri sağlandığında unimodal temsiller/çıktılar üzerinden multimodal entegrasyonun uygulanması.

1.7. Kullanılacak Teknolojiler

Proje, yeniden üretilebilir ve literatürde yaygın kullanılan bir teknoloji yığını ile yürütülecektir:

- Python
- PyTorch (torch/torchvision; transfer learning)
- OpenCV (ön işleme)
- NumPy, pandas (veri işleme)
- Albumentations (gereklikçe augmentasyon)
- Scikit-learn (metrikler ve doğrulama yardımcıları)
- Grad-CAM benzeri açıklanabilirlik yöntemleri (PyTorch tabanlı) [1]

Raporun organizasyonu: 2. bölümde literatür taraması, 3. bölümde yöntem ve sistem mimarisi, 4. bölümde gerçekleştirilen çalışmalar ve bulgular, 5. bölümde proje yönetimi ve takvim; ardından gelecek çalışmalar ve sonuç bölümleri sunulacaktır.

2. LİTERATÜR

Bu bölümde, üveit alanında görüntüleme temelli yapay zekâ (YZ) çalışmalarının güncel eğilimleri ve projemizin bu literatür içerisindeki konumu özetlenmektedir. Çizelge 2.1’de seçilen çalışmalar; kullanılan modalite, hedef görev (tanı/şiddet sınıflama, segmentasyon, nicel ölçüm), model yaklaşımı, veri gerçekliği ve açıklanabilirlik boyutları açısından karşılaştırmalı olarak sunulmuştur.

Çizelge 2.1 Üveit tanısında yapay zekâ ile ilgili seçili çalışmaların karşılaştırması ve proje ile kıyaslaması

Çalışma (Yıl) – Kaynak	Modalite	Yöntem/Model	Veri Seti (boyut/kaynak)	Başarı Oranı (Ölçüt)	Açıklanabilirlik	Proje ile Kıyas (Eksik Yön)
Putera ve ark. (2025) DOI:10.1007/s40123-025-01103-4 [4]	Fundus foto (CFP)	Damar segmentasyonu + ML analizi (Retanalysis paketi)	~100 göz, tek merkez (Endonezya)	AUC 0.75–0.80 (TB üveit vs diğerleri)	Parametrik (tortuozite skoru ile) – <i>açıklanabilir</i>	Tek modalite (fundus); sadece TB ve benzeri etiyoloji – <i>multimodal kapsam yok.</i>
Sun ve ark. (2020) DOI:10.1167/tvst.9.2.59 [5]	Fundus foto (deneysel)	CNN (ResNet türevi, 3 sınıflı)	1500 görüntü (EAU hayvan modeli)	AUC ~0.98 (hastalık şiddeti)	Grad-CAM ısı haritaları – <i>açıklanabilir</i>	Hayvan modeli; insan üveitine doğrudan uygulanmadı – <i>genel tıbbi kullanım için genişletilmeli.</i>
Dhirachaikulpanich ve ark. (2024) PMID:38261457 [6]	Floresein Angio (UWFFA)	Segmentasyon (DeepLabv3+, U-Net vs)	463 görüntü, 82 hasta (çok merkezli)	Dice 0.63 (sızıntı), 0.70 (tıkanma)	Segmentasyon çıktısı – <i>doğrudan görsel açıklama</i>	Yalnızca FA ve vaskülit; tanısal sınıflama değil – <i>genel üveit tanısı yerine alt bulgu analizi.</i>
Haggag ve ark. (2021) DOI:10.3390/s21165457 [7]	Retina OCT (B-scan)	U-Net + özdevinimli MLP	200 B-scan (Mansoura Üni. + Louisville)	Dice 0.99 (vitreus segm.) Doğruluk 86% (grade 0-3)	CDF tabanlı özellik – yorumlanabilir	Sadece vitreus hazi; sınırlı sınıflandırma – <i>multimodal tam tanı yok.</i>
Oshika (2025) – derleme DOI:10.31662/jmaj.2024-0139 [8]	Çeşitli (genel)	Derin öğrenme uygulamaları	N/A (derleme çalışması)	Örn: Retina hast. Tanısı %90+ doğruluk	Genel bakış – örnek ısı haritaları var	Üveit özelinde değil; genel eğilim özeti.
Zhang ve ark. (2021) DOI:10.3389/fcell.2021.684522 [9]	Ant. segment foto (slit-lamp)	CNN (SET-ResNeXt50, attention)	2000 foto (872 FUS, 1128 diğer) Çin	Doğruluk %93, AUC 0.977 (Fuchs tanısı)	Grad-CAM heatmap – <i>açıklanabilir</i>	Tek hastalık (Fuchs); tek modalite – <i>geniş üveit spektrumu yok.</i>
Pichi ve ark. (2023) DOI:10.1111/ceo.14296 [10]	AS-OCT (Ant. segment)	Görüntü işleme algoritması	20 hasta, 3 zaman noktası (prospektif)	KP hacim ölçümü: aktif 0.17 mm ³ → sakin 0.11 mm ³ (p=0.03)	En face 3B haritalama – <i>görsel, anlaşılır</i>	YZ kullanılmadı (klasik algoritma); sadece KP analizi – <i>tam otomatik tanı yok.</i>
Jacquot ve ark. (2024) DOI:10.1038/s41433-024-03530-2 [11]	Klinik veri (görsel değil)	MLP (çok katmanlı perseptron)	375 hasta (25 etiyoloji, Fransa)	İlk tahminde %78, Top-2’de %93 doğruluk	Değişken önem analizi (muhtemelen)	Görüntü kullanılmadı; laboratuvar ve klinik veri – <i>multimodal görsel analiz dışında.</i>

Çizelge 2.1, üveit alanında YZ çalışmalarının ağırlıklı olarak tek modalite ve tek hedef görev etrafında kümелendiğini göstermektedir. Ayrıca açıklanabilirlik yaklaşımlarının (parametrik özellikler, segmentasyon çıktıları, Grad-CAM) klinik yorumlanabilirliği güçlendirdiği; buna karşın multimodal entegrasyonun çoğunlukla veri eşleştirme gereksinimi nedeniyle sınırlı kaldığı görülmektedir.

Literatürün genel resmi, üveitte YZ uygulamalarının çoğunlukla tek modalite–tek görev düzeyinde güçlü sonuçlar üretebildiğini; buna karşın klinik pratikteki “multimodal karar” yapısını yansıtan multimodal fusion, genellenebilirlik ve klinik açıklanabilirlik katmanlarının hâlen temel araştırma alanları olduğunu göstermektedir [4] – [11].

2.1. Fundus (CFP) Tabanlı Yaklaşımlar

Renkli fundus fotoğrafları (CFP), retina yüzeyi, optik disk ve damar yapısı gibi arka segment bulgularını görünür kıldığı için üveitte önemli bir kanıt kaynağıdır. Literatürde CFP üzerinden iki ana yaklaşım öne çıkmaktadır:

1. Görüntü tabanlı sınıflandırma: Sun ve arkadaşları, deneysel (hayvan modeli) otoimmün üveitte fundus fotoğraflarından CNN tabanlı yaklaşımla üveit şiddetini sınıflandırmayı ele almış ve Grad-CAM gibi açıklanabilirlik çıktıları ile model kararını görsel olarak desteklemiştir [5]. Bu tür çalışmalar, fundus görüntüsünde üveite ilişkin örüntülerin YZ tarafından yakalanabildiğini göstermesi açısından değerlidir; ancak hayvan modeli olması ve klinik üveit spektrumunu bütünüyle temsil etmemesi, doğrudan genelleme açısından sınırlılık yaratır [5].
2. Parametrik damar analizi (açıklanabilir özellikler): Putera ve arkadaşları, oküler tüberküloz bağlamında retinal vaskülatür analizi ve damar özellikleri (ör. tortuozite temelli parametrik skorlar) üzerinden ayırım yapmayı ele almıştır [4]. Bu yaklaşımın güçlü tarafı, çıktının klinik açıdan daha “yorumlanabilir” (parametrik özellik) olmasıdır. Bununla birlikte, çalışma odağının belirli bir etiyoloji (TB) etrafında şekillenmesi ve “genel üveit spektrumunu kapsayan multimodal karar desteği” düzeyine doğrudan taşınamaması önemli bir sınırlılıktır [4].

Bu iki çizgi birlikte değerlendirildiğinde, CFP'nin üveitte değerli bir modalite olduğu; ancak klinik gerçekliğe yakın karar desteğinin çoğu zaman OCT/FA/ön segment bulguları ile tamamlanmasının rasyonel olduğu görülmektedir.

2.2. Floresein Anjiyografi ve Retinal Vaskülit Segmentasyon

Retinal vaskülit gibi alt bulguların değerlendirilmesinde flöresein anjiyografi (FA), sızıntı ve damar tıkanıklığı gibi bulguları daha görünür kılan bir modalitedir. Dhirachaikulpanich ve arkadaşları, retinal vaskülitte sızıntı ve oklüzyon alanlarının segmentasyonu için DeepLabv3+ ve U-Net benzeri derin öğrenme tabanlı segmentasyon yaklaşımlarını kullanmış; böylece “tanı etiketi”nden bağımsız olarak klinik açıdan doğrudan yorumlanabilir bir ara çıktı (segmentasyon maskesi) üretmiştir [6]. Bu yaklaşım, üveitte YZ'nin yalnızca sınıflandırma değil, bulgu analizi/kanıt üretimi yönünde de güçlü bir rol oynayabileceğini göstermektedir. Ancak bu tür çalışmalar genellikle belirli bir alt probleme (vaskülit bulguları) odaklanır ve “genel üveit tanısı/alt tip ayrımı” gibi daha geniş hedefleri tek başına karşılamaz [6].

2.3. Retina OCT (B-scan) Tabanlı Şiddet/Grading Yaklaşımları

OCT, retina katmanlarını yapısal olarak ortaya koyduğu için inflamasyonla ilişkili değişimlerin ve komplikasyonların (örn. maküler ödem benzeri yapısal etkiler) daha objektif değerlendirilmesine zemin sağlar. Haggag ve arkadaşları, OCT görüntülerinden üveit şiddet derecelendirmesine yönelik bir CAD yaklaşımı önermiş; segmentasyon tabanlı bir yapı (U-Net) ve sınıflandırma/karar katmanı kombinasyonu ile grading problemine odaklanmıştır [7]. Bu tür çalışmaların güçlü tarafı, OCT'nin “yapısal” bilgi taşıması nedeniyle klinik izleme daha yakın bir hedefle (derecelendirme/aktivite) ilişkilendirilebilmesidir. Buna karşın, bu yaklaşım da çoğunlukla tek modaliteye dayanır; multimodal karar ihtiyacını doğrudan çözmez ve farklı merkez/cihaz dağılımlarında genellenebilirlik ayrıca değerlendirilmelidir [7].

2.4. Ön Segment (Slit-Lamp ve AS-OCT) Tabanlı Yaklaşımlar

Ön segment görüntüleri, üveitin özellikle anterior bulgularını taşıdığı için pratikte önemli bir kanıt kaynağıdır. Zhang ve arkadaşları, slit-lamp görüntülerinden Fuchs' uveitis syndrome tespitini derin CNN tabanlı bir yaklaşımla ele almış; Grad-CAM benzeri açıklanabilirlik çıktıları ile model kararını yorumlanabilir kılmaya çalışmıştır [9]. Bu çalışma, slit-lamp verisinin yeterli ölçek ve etiketle, belirli bir antite için güçlü performans üretebileceğini destekler. Bununla birlikte “tek hastalık–tek modalite” kurgusu, geniş üveit spektrumuna genelleme açısından sınırlılık taşır [9].

AS-OCT tarafında Pichi ve arkadaşları, uveitik keratik presipitatların otomatik nicellenmesine odaklanmıştır [10]. Buradaki kritik değer, YZ/otomasyonun “tanı etiketi”nden bağımsız olarak nicel ve izlenebilir bir ölçüm üretmeye yönelmesidir. Bu tarz ölçüm üretimi, klinik izlem ve standardizasyon açısından raporlanabilirlik avantajı sağlar; ancak tek başına “tam otomatik üveit tanısı” problemine eşdeğer değildir [10].

2.5. Etiyoloji Tahmini: Görüntü Dışı (Klinik Veri) Yaklaşımlar

Üveitte en zor hedeflerden biri, görüntüden doğrudan “etioloji” (Behçet, TB vb.) tahminidir; çünkü etiyoloji çoğu zaman görüntüden tek başına değil, klinik öykü, laboratuvar ve sistemik bulgularla birlikte belirlenir. Jacquot ve arkadaşları, etiyolojik tanıyı tahmin etmeye yönelik olarak görüntü yerine klinik/laboratuvar temelli verilerle MLP tabanlı bir yaklaşım sunmuştur [11]. Bu tür çalışmalar, etiyoloji tahmininin genellikle multimodal (görüntü + klinik veri) doğaya sahip olduğunu ve etiket/ground-truth ihtiyacının yüksek olduğunu göstermesi açısından önemlidir. Bu nedenle, mevcut proje veri havuzlarında etiyoloji etiketlerinin bulunmaması durumunda, etiyoloji tahmini hedefi “gelecek çalışma” olarak konumlandırılmalıdır.

2.6. Genel Değerlendirme ve Bu Projenin Konumlanması

Çizelge 2.1’de özetlenen çalışmalar birlikte değerlendirildiğinde üç ana sonuç öne çıkmaktadır:

1. Tek modalite–tek görev yoğunluğu: Fundus sınıflandırma [5], damar temelli ayrım [4], FA segmentasyon [6], OCT grading [7] ve slit-lamp antite tespiti [9] gibi çalışmalar

genellikle belirli bir modalitede belirli bir hedefe odaklanır. Bu, üveitte YZ'nin uygulanabilir olduğunu gösterirken aynı zamanda multimodal karar desteğe giden yolun “modüler” biçimde kurulması gerektiğini işaret eder.

2. Açıklanabilirlik ve kanıt üretimi önemi: Parametrik damar özellikleri [4], segmentasyon maskeleri [6] ve Grad-CAM tabanlı açıklamalar [5], [9] gibi yaklaşımlar, klinik kabul açısından “model neden böyle dedi?” sorusuna yanıt üretmeyi kolaylaştırır. Bu proje de unimodal baselinelerde dahi açıklanabilirlik çıktıları üreterek raporlanabilirliği artırmayı hedeflemektedir.
3. Etiyoloji ve tam multimodal fusion için veri bariyeri: Etiyoloji tahmini gibi ileri hedefler çoğunlukla klinik veri ile ele alınır [11]. Multimodal fusion ise eşleştirilmiş hasta düzeyinde veri gerektirir. Bu nedenle projenin mevcut aşamasında en rasyonel strateji; her modalite için unimodal modelleri geliştirmek, veri genişledikçe modaliteleri artırmak ve eşleştirilmiş veri sağlanırsa fusion aşamasına geçmektir.

Bu literatür çerçevesi, projenin “unimodal baseline → veri genişletme → multimodal fusion” yol haritasını bilimsel olarak gerekçelendirmektedir. Ayrıca oftalmolojide YZ uygulamalarının genel eğilimlerini özetleyen derleme çalışmalar, bu alanda açıklanabilirlik, standardizasyon ve veri kalitesi gibi başlıkların yaygın biçimde vurgulandığını göstermektedir [8].

3. YÖNTEM

Bu bölümde, proje kapsamında geliştirilecek karar destek yaklaşımının veri işleme hattı, unimodal temel modeller (baseline), eğitim–doğrulama protokolü, değerlendirme metrikleri, açıklanabilirlik katmanı ve veri uygun olduğunda uygulanacak multimodal entegrasyon (fusion) planı sunulmaktadır. Proje, klinik pratikte multimodal okumanın yaygın olmasına rağmen mevcut aşamada verilerin hasta bazında eşleştirilmemiş ve bazı modaliteler için eksik olması nedeniyle, gerçekçi ve kademeli bir strateji ile yürütülmektedir: önce modalite bazlı unimodal modeller, ardından veri genişledikçe multimodal genişleme.

3.1. Genel Yaklaşım ve Proje Fazları

Proje yöntemi iki ana faza ayrılmıştır:

Faz-1 (Mevcut veri ile unimodal baseline):

Her görüntü modalitesi için ayrı bir “uzman model” eğitilir ve değerlendirilir. Bu fazın amacı; kısa vadede ölçülebilir performansı olan bir temel sistem kurmak ve her modalitede hangi tür ön işleme/modelleme kararlarının daha stabil çalıştığını belirlemektir.

Faz-2 (Veri eşleşmesi veya yeni modalite verisi sağlanırsa multimodal genişleme):

OCT-A ve/veya AS-OCT gibi modaliteler temin edilirse ve ideal olarak aynı hastaya ait eşleştirilmiş multimodal veri sağlanırsa, unimodal temsil/çıktılar üzerinden multimodal fusion uygulanır. Eşleştirme olmadığı sürece fusion, “klinik anlamda gerçek” bir multimodal sistem iddiası taşımayacak; bu nedenle Faz-2, veri koşuluna bağlı olarak planlanmıştır.

3.2. Veri Setleri ve Etiketleme Şeması

Bu projede kullanılan veriler ayrı havuzlardır; aynı hastaya ait multimodal eşleştirme (patient-ID) bulunmamaktadır. Bu nedenle değerlendirme, modalite bazında yapılacaktır.

3.2.1. Anterior Segment Slit-Lamp Veri Havuzu (M1)

- Üveit: 224
- Normal: 650
- Diğer hastalıklar: 1430
- Toplam: 2304 (JPG/JPEG, değişken çözünürlük)

Baseline görev tanımı (Faz-1):

- İkili sınıflandırma: Üveit vs Üveit dışı (Normal + Diğer hastalıklar).
Bu tercih bilinçlidir: veri dengesizliği ve “diğer hastalıklar” sınıfının heterojenliği nedeniyle ilk aşamada hedefi sade tutmak, daha güvenilir bir baseline üretir.

3.2.2. Renkli Fundus Veri Havuzları (M2)

(A) RFMiD (train/val/test ayrımlı, çoklu etiketli):

RFMiD_2 etiket dosyaları (train/val/test) doğrudan kullanılır. Bu veri seti çoklu patoloji etiketleri içerir ve bir görüntü birden fazla etikete sahip olabilir. Üveit ile doğrudan “tek etiket” bulunmadığı için, Faz-1’de iki ayrı değerlendirme yolu tanımlanır:

- Yaklaşım-1 (İnflamatuvar etiket altkütmesi): RFMiD içindeki inflamasyonla ilişkili etiketler (CRS, RS, VS) “hedef etiket altkütmesi” olarak ele alınır ve çoklu etiket sınıflandırma problemi kurulur. Bu altkümede veri sayısı sınırlı olduğu için modelin amacı, güçlü bir klinik iddia değil; inflamasyonla ilişkili örüntülerin yakalanabilirliğini test eden yardımcı bir baseline üretmektir.
- Yaklaşım-2 (Çok hastalıklı triage): RFMiD’in çoklu etiket yapısı, “üveit” hedefi dışında da genel retina patoloji ayrımı için kullanılabilir. Ancak bu projenin ana hedefi üveit olduğundan, RFMiD faz-1’de “yardımcı/ikincil” rol taşır.

(B) “1000images” fundus havuzu (1000 görüntü):

- VKH: 14
- Normal: 39

- Diğer hastalıklar: kalan

Bu havuzda VKH sayısı çok düşük olduğundan, Faz-1’de bu veri tek başına güçlü bir VKH sınıflandırma iddiası için kullanılmayacaktır. Bu veri daha çok (i) ön işleme/standardizasyon testleri, (ii) veri artırma stratejilerinin davranışı, (iii) gerekiyorsa “anormallik tespiti/triage” gibi daha temkinli hedefler için değerlendirilir.

3.2.3. Retina OCT (B-scan) Veri Havuzu (M3)

- Intermediate–posterior üveit: 12
- Panuveitis: 16
- Normal: 28
- RRD–PVR: 19
- Toplam: 75 (JPEG)

Baseline görev tanımı (Faz-1):

- Çok sınıflı sınıflandırma (4 sınıf): {intermediate–posterior, panuveitis, normal, RRD–PVR}

Bu kurgu, veri etiketleriyle doğrudan uyumludur. Veri sayısı düşük olduğu için değerlendirme stratejisi (k-fold) kritik olacaktır (Bkz. 3.6).

3.3. Veri Ön İşleme ve Standardizasyon

Tüm modaliteler için ortak bir ön işleme yaklaşımı uygulanacaktır:

1. Format/kanal standardizasyonu: Görüntüler RGB formatına dönüştürülür; boyutlar modele girecek şekilde yeniden ölçeklenir.
2. Kırpma ve içerik hizalama (gerektiğinde):
 - Slit-lamp: göz bölgesini merkeze alan kırpma/yeniden boyutlandırma; aşırı arka planın etkisini azaltmak.
 - Fundus: siyah kenarlar/çerçeveler varsa kırpma; görüntü merkezinin korunması.

- OCT: B-scan alanını koruyacak şekilde yeniden boyutlandırma; metin/çerçeve artefaktlarını azaltma (varsa).
3. Kalite kontrol (minimum seviye): aşırı bulanık, aşırı parlaklık/yanma, çok düşük kontrast gibi örnekler tespit edilirse raporlanır; veri dışlama kararı otomatik değil, kontrollü şekilde verilir (veri az olduğu için agresif eleme yapılmaz).
 4. Veri artırma (augmentasyon): Faz-1’de, özellikle sınıf dengesizliğini ve cihaz/ışık değişkenliğini kısmen yönetmek için temel artırmalar kullanılır (ör. küçük döndürme, yatay çevirme uygun modalitelerde, parlaklık/kontrast jitter). Artırma politikaları modaliteye göre farklılaştırılır (ör. OCT’de anatomiyi bozacak aşırı dönüşlerden kaçınılır).

3.4. Modelleme Stratejisi (Unimodal Baseline)

Faz-1’de her modalite için ayrı bir sınıflandırma modeli kurulacaktır. Veri miktarı ve etiket güvenilirliği dikkate alınarak transfer learning tercih edilir: genel görüntü veri setlerinde ön-eğitilmiş omurga (backbone) kullanılıp, son katmanlar hedef sınıflara göre yeniden eğitilir.

- Slit-lamp (ikili sınıflandırma): CNN tabanlı bir backbone + ikili sınıflandırma başlığı (sigmoid).
- OCT (4 sınıf): CNN tabanlı backbone + softmax çok sınıflı başlık.
- RFMiD inflamasyon altkütmesi (çoklu etiket): CNN tabanlı backbone + çoklu etiket başlığı (sigmoid, BCE tabanlı kayıp).

Bu yaklaşım; literatürde unimodal görevlerde kullanılan temel çizgiyle uyumludur ve küçük veri rejiminde “sıfırdan eğitim”e göre daha gerçekçidir [7], [9].

3.5. Eğitim Protokolü ve Sınıf Dengesizliği

Eğitim protokolü (genel):

- Eğitim/validasyon stratejisi veri büyüklüğüne göre seçilir (Bkz. 3.6).
- Kayıp fonksiyonu:
 - İkili sınıflandırma: BCE tabanlı kayıp

- Çok sınıflı: Cross-Entropy
- Çoklu etiket: BCEWithLogits
- Sınıf dengesizliği yönetimi:
 - Slit-lamp verisinde “üveit” sınıfı azınlık olduğu için sınıf ağırlığı (weighted loss) ve/veya dengeli örnekleme (sampler) uygulanır.
 - RFMiD inflamasyon altkütlesinde pozitif örnek sayısı çok düşük olduğundan, aşırı iddialı hedeflerden kaçınılır ve sonuçlar “yardımcı baseline” olarak raporlanır.

Aşırı uyumu (overfitting) sınırlama:

Küçük veri rejiminde overfitting beklenen bir risktir. Bu nedenle erken durdurma (early stopping), uygun regularizasyon ve sadece gerekli ölçüde veri artırma kullanılır. Hiperparametre araması “geniş tarama” şeklinde değil, sınırlı ve kontrollü şekilde yapılır; çünkü veri az olduğunda agresif arama yalancı iyileşmelere neden olabilir.

3.6. Değerlendirme Tasarımı ve Metrikler

Bu projede patient-ID olmadığı için “hasta bazlı ayırım” yapılamamaktadır; bu bir sınırlılıktır. Bu nedenle veri sızıntısını azaltmak için aynı görüntünün kopyaları/çok benzer varyantları varsa ayırımın aynı bölmede kalmasına dikkat edilir (mümkün olduğu ölçüde).

Slit-lamp (N=2304):

- Stratified train/val/test ayırımı uygulanır (örn. 70/15/15 gibi).
- Raporlanacak metrikler: doğruluk, duyarlılık (recall), özgüllük, F1, ROC-AUC ve karışıklık matrisi.
- Ek olarak, sınıf dengesizliği nedeniyle özellikle F1 ve ROC-AUC temel metrikler olarak öne alınır.

OCT (N=75):

- Veri az olduğu için Stratified k-fold cross-validation (örn. 5-fold) uygulanır ve metrikler ortalama $\pm$ standart sapma olarak raporlanır.

- Raporlanacak metrikler: macro-F1, balanced accuracy, sınıf bazlı recall ve karışıklık matrisi.

RFMiD inflamasyon altkümüsi (çoklu etiket):

- RFMiD’in resmi train/val/test ayrımı korunur.
- Raporlanacak metrikler: etiket bazlı ROC-AUC, micro/macro F1.
- Bu deneyin yorumu temkinli yapılır; amaç ana sistemi “kanıtlamak” değil, fundus üzerinde inflamasyonla ilişkili etiketlerin modelle yakalanabilirliğini incelemektir.

3.7. Açıklanabilirlik (Explainability) Katmanı

Klinik kabul ve raporlanabilirlik açısından model kararının görsel kanıtla desteklenmesi hedeflenmektedir. Bu kapsamda:

- CNN tabanlı modellerde Grad-CAM benzeri ısı haritaları üretilerek modelin hangi bölgeleri karar için kullandığı görselleştirilecektir.
- Segmentasyon temelli ara çıktı üretimi (FA/OCT gibi) bu rapor sürümünde ana hedef değildir; ancak ilerleyen aşamalarda veri uygunluğu oluşursa, belirli alt bulgular için segmentasyon tabanlı kanıt üretimi değerlendirilebilir (Çizelge 2.1’deki segmentasyon çizgisi ile tutarlı) [6], [7].

Açıklanabilirlik çıktıları, raporda örnek vaka görselleriyle sunulacak; bu çıktılar “modelin kararının klinik olarak mantıklı görünüp görünmediğini” tartışmak için kullanılacaktır [4] – [10].

3.8. Multimodal Fusion Planı (Veri Koşuluna Bağlı)

Bu aşamada veri havuzları aynı hastaya ait olmadığı için gerçek multimodal fusion uygulanamayacaktır. Faz-2 için plan şu şekildedir:

- Eğer aynı hastaya ait en az iki modalite (ör. fundus + OCT) eşleştirilmiş olarak temin edilirse:

- Late fusion: unimodal model olasılıklarının ağırlıklı birleşimi,
- Veya feature-level fusion: unimodal omurgalardan alınan özellik vektörlerinin birleştirilmesi

Yaklaşımlarından biri uygulanacaktır.

Eşleştirilmiş veri olmadan fusion yapılması, klinik açıdan yanlış bir iddia üretme riski taşıyacağı için bu raporda “hedef/gelecek adım” olarak konumlandırılmaktadır.

3.9. Uygulama, Deney Yönetimi ve Tekrarlanabilirlik

- Uygulama dili: Python
- Derin öğrenme: PyTorch
- Ön işleme: OpenCV / PIL
- Veri artırma: Albumentations
- Metrikler ve raporlama: scikit-learn

Tekrarlanabilirlik için rastgelelik tohumları (seed) sabitlenecek, eğitim konfigürasyonları (model, giriş boyutu, öğrenme oranı, epoch sayısı, augmentasyon politikası, split bilgisi) yapılandırılmış dosyalarla kayıt altına alınacaktır. Amaç, aynı veri ve aynı konfigürasyonla aynı deneyin yeniden üretilebilmesidir.

3.10. Etik, Veri Gizliliği ve Sınırlılıklar

Bu proje, kimliksizleştirilmiş/açık araştırma verileri üzerinden yürütülen bir araştırma prototipidir. Mevcut veri havuzlarında patient-ID bulunmaması, hasta bazlı ayırım yapmayı engellediği için genellenebilirlik tartışması bu sınırlılık gözetilerek yapılacaktır. Ayrıca bazı hedeflerin (özellikle etiyoloji tahmini) görüntü dışında klinik/laboratuvar verisi gerektirdiği; bu veri olmadan etiyolojiye yönelik güçlü iddia kurulamayacağı literatürde de görülmektedir [11]. Bu nedenle proje hedefleri, veri gerçekliğiyle uyumlu şekilde aşamalı planlanmıştır.

4. GERÇEKLEŞTİRİLEN ÇALIŞMALAR VE BULGULAR

Bu bölümde, Yöntem kısmında tanımlanan aşamalı yaklaşım doğrultusunda şu ana kadar gerçekleştirilen çalışmalar ve elde edilen ara çıktılar sunulmaktadır. Bu rapor sürümü itibarıyla odak; (i) veri temini ve envanter çıkarımı, (ii) etiket/sınıf dağılım analizi, (iii) literatür çizelgesi ve problem konumlandırma çıktısı, (iv) unimodal baseline deney tasarımının netleştirilmesi ve (v) multimodal genişleme için uygulanabilirlik değerlendirmesidir. Model eğitime dayalı nihai performans sonuçları, deneyler tamamlandığında ilgili metrikler ve görselleştirmelerle birlikte rapora eklenecektir.

4.1. Veri Temini ve Veri Envanteri Çıkarımı

Proje başlangıç hedefi beş modaliteli bir karar destek çerçevesi olmakla birlikte, mevcut aşamada kullanılabilir veri havuzları üç modalitede toplanmıştır:

- M1 – Anterior Segment Slit-Lamp: Üveit (224), normal (650), diğer hastalıklar (1430) olmak üzere toplam 2304 görüntü (JPG/JPEG, değişken çözünürlük).
- M2 – Renkli Fundus:
 - RFMiD_2: train/validation/test ayrımlı, çoklu etiketli (train 509, validation 177, test 174; toplam 860 kayıt).
 - Ek fundus havuzu (“1000images”): toplam 1000 görüntü; VKH 14, normal 39, kalan farklı hastalık etiketleri.
- M3 – Retina OCT (B-scan): Intermediate–posterior üveit 12, panuveitis 16, normal 28, RRD–PVR 19 olmak üzere toplam 75 görüntü.

OCT-A (M4) ve AS-OCT (M5) için veri teminine yönelik iletişimler daha önce başlatılmıştır; ancak bu rapor sürümü itibarıyla ek veri temini henüz sonuçlanmadığından M4–M5 modaliteleri “Faz-2 / veri geldikçe genişleme” kapsamında ele alınmaktadır. Ayrıca mevcut veri havuzları aynı hastaya ait eşleştirilmiş multimodal veri içermemektedir; bu nedenle kısa vadede gerçek multimodal fusion yerine unimodal baselinelerin oluşturulması tercih edilmiştir.

4.2. Veri Yapısı ve Etiketleme Gerçekliği

- Mevcut veri havuzlarının ortak özelliği, format ve çözünürlük heterojenliği ve (özellikle fundus verilerinde) etiket şemasının veri setine özgü olmasıdır. Bu nedenle ön işleme tarafında aşağıdaki ihtiyaçlar netleşmiştir:
- Format/kanal standardizasyonu (RGB, tek tip giriş boyutu)
- Görüntü içeriğini merkeze alan kırpma/yeniden ölçekleme (özellikle fundus ve slit-lamp)
- Veri azlığı nedeniyle agresif elemeden kaçınarak, minimum kalite kontrolleri ve raporlama

Bu değerlendirme, Yöntem bölümünde tanımlanan “standardizasyon + kontrollü augmentasyon + transfer learning” yaklaşımını doğrudan desteklemektedir.

4.3. Literatür Taraması Çıktısı ve Çizelge 2.1

Literatür bölümünde, üveitte YZ çalışmalarını karşılaştırmalı şekilde özetleyen Çizelge 2.1 oluşturulmuştur. Bu çizelge üzerinden elde edilen ana çıkarımlar şunlardır:

- Çalışmaların önemli bir kısmı tek modalite–tek görev ekseninde ilerlemektedir (ör. fundus sınıflandırma, OCT grading, slit-lamp ile belirli antite tespiti, FA ile segmentasyon).
- Açıklanabilirliğin pratik değer taşıdığı; Grad-CAM, segmentasyon maskesi veya parametrik damar özellikleri gibi “kanıt üretimi” yaklaşımlarının klinik yorumlanabilirliği güçlendirdiği görülmektedir.
- Multimodal fusion fikri literatürde yer alsa da çoğunlukla hasta bazında eşleştirilmiş veri gereksinimi nedeniyle uygulama kapsamı sınırlı kalmaktadır.

Bu literatür çıktısı, projenin kısa vadede unimodal baselineler ile ilerlemesini ve veri koşulu oluştuğunda multimodal entegrasyona genişlemesini gerekçelendiren temel referanstır.

4.4. RFMiD Etiket Analizi ve “İnflamasyon” Alt Kümesi Ara Çıktıları

RFMiD_2 veri seti çoklu etiketli yapıya sahiptir; bir görüntüde birden fazla patoloji etiketi bulunabilir. Projenin üveit odağı nedeniyle RFMiD, bu rapor sürümünde “doğrudan üveit tanısı” yerine inflamasyonla ilişkili olabilecek etiketlerin (CRS, RS, VS, TV) yardımcı bir analiz hattı olarak incelenmesi amacıyla kullanılmıştır.

Bu kapsamda RFMiD_2 etiket dosyaları üzerinden yapılan sayım sonuçları aşağıdaki gibidir:

Çizelge 4.1 RFMiD_2’de inflamasyonla ilişkili etiketlerin (CRS, RS, VS, TV) dağılımı

Bölüm (Split)	N	CRS	RS	VS	TV	En az 1 pozitif (CRS/RS/VS/TV)
Training	509	25	5	4	9	43
Validation	177	7	2	1	3	13
Testing	174	9	1	2	6	18
Toplam	860	41	8	7	18	74

Not: “En az 1 pozitif” sütunu, ilgili split içinde CRS/RS/VS/TV etiketlerinden en az birinin pozitif olduğu görüntü sayısını göstermektedir.

Çizelge 4.2 RFMiD_2’de inflamasyonla ilişkili etiketlerin split bazında oranları (n ve %)

Bölüm (Split)	N	CRS n (%)	RS n (%)	VS n (%)	TV n (%)	En az 1 pozitif n (%)
Training	509	25 (4.9%)	5 (1.0%)	4 (0.8%)	9 (1.8%)	43 (8.4%)
Validation	177	7 (4.0%)	2 (1.1%)	1 (0.6%)	3 (1.7%)	13 (7.3%)
Testing	174	9 (5.2%)	1 (0.6%)	2 (1.1%)	6 (3.4%)	18 (10.3%)
Toplam	860	41 (4.8%)	8 (0.9%)	7 (0.8%)	18 (2.1%)	74 (8.6%)

Not: Yüzdelere, her split içindeki N değerine göre hesaplanmıştır.

Ara bulgu: Bu raporda CRS/RS/VS/TV etiketleri için tekil dağılım raporlanmıştır; etiketlerin birlikte-görülme (co-occurrence) analizi sonraki aşamada ayrıca değerlendirilecektir. Bu

durum, RFMiD tarafındaki denemelerin “çoklu etiket bağımlılığı”ndan ziyade etiketlerin ayrı ayrı tespit edilebilirliğini ölçen bir yardımcı baseline olarak konumlanmasını daha rasyonel kılmaktadır.

4.5. Baseline Deney Tasarımının Netleştirilmesi

Yöntem bölümünde tanımlanan Faz-1 kapsamında, mevcut veri koşullarına uygun şekilde aşağıdaki baseline görevleri netleştirilmiştir:

- M1 Slit-lamp: Üveit vs Üveit-dışı (normal + diğer hastalıklar) ikili sınıflandırma.
- M3 OCT (B-scan): 4 sınıflı sınıflandırma (intermediate-posterior, panuveitis, normal, RRD-PVR).
- M2 Fundus (RFMiD yardımcı): CRS/RS/VS/TV etiketleri için çoklu etiket sınıflandırma (yardımcı/ikincil).

Ayrıca değerlendirme protokolü, veri büyüklüğüne göre şu şekilde planlanmıştır:

- Slit-lamp havuzu için stratified train/validation/test ayrımı; sınıf dengesizliği nedeniyle F1 ve ROC-AUC odaklı raporlama.
- OCT havuzu düşük örnek sayısına sahip olduğundan stratified k-fold cross-validation ve metriklerin ortalama $\pm$ standart sapma ile raporlanması.
- RFMiD için veri setinin kendi train/val/test ayrımının korunması ve çoklu etiket metrikleri (micro/macro F1, etiket bazlı ROC-AUC) ile değerlendirme.

Bu rapor sürümü itibarıyla, deneylerin “hangi görevde, hangi protokolle, hangi metriklerle” yürütüleceği netleştirilmiş; nihai eğitim çalışmaları tamamlandığında performans tabloları, karışıklık matrisleri ve açıklanabilirlik çıktıları ilgili alt başlıklarda sunulacaktır.

4.6. Açıklanabilirlik ve Multimodal Genişleme İçin Uygulanabilirlik Değerlendirmesi

Proje, klinik karar desteği hedeflediği için açıklanabilirlik (modelin hangi görsel ipuçlarına dayanarak karar verdiğinin gösterimi) kritik bir gereksinim olarak ele alınmaktadır. Bu nedenle

unimodal baselinelerin deęerlendirme ıktılarında Grad-CAM benzeri grselleřtirmelerin rapora eklenmesi planlanmaktadır.

Multimodal fusion tarafında ise mevcut ařamada temel sınırlılık, veri havuzlarının aynı hastaya ait eřleřtirilmiř rnekler iermemesidir. Bu nedenle gerek multimodal fusion, yalnızca eřleřtirilmiř veri saęlanabildięi durumda devreye alınacak Faz-2 ıktısı olarak korunmaktadır.

4.7. Blm zeti

Bu rapor srmnde tamamlanan alıřmalar; veri envanterinin ıkarılması, literatrdeki seili alıřmaların izelge 2.1 ile sistematik zetlenmesi, RFMiD_2 etiket alt kmesinin nicel analizi (izelge 4.1) ve Faz-1 unimodal baseline grevlerinin deneysel olarak netleřtirilmesidir. Bir sonraki adım, tanımlanan protokollerle unimodal modellerin eęitimi ve deęerlendirilmesi; ardından performans metrikleri ve aıklanabilirlik rneklerinin rapora eklenmesidir.

5. PROJE YÖNETİMİ VE ÇALIŞMA TAKVİMİ

Bu bölümde projenin yönetim yaklaşımı, iş paketleri, zaman planı, risk yönetimi ve kalite güvencesi çerçevesi sunulmaktadır. Projenin temel kısıtı; multimodal veri havuzlarının hasta bazında eşleştirilmemiş olması ve bazı hedef modaliteler (OCT-A, AS-OCT) için veri temininin henüz sonuçlanmamış olmasıdır. Bu nedenle yönetim yaklaşımı, aşamalı kapsam prensibiyle kurgulanmıştır: önce unimodal baselinelerin tamamlanması, veri geldikçe kapsamın genişletilmesi.

5.1. Proje Yönetimi Yaklaşımı

Proje, iki seviyeli bir yönetim mantığıyla yürütülmektedir:

- Kapsam yönetimi (scope control): Teslim edilebilir çekirdek çıktılar, Faz-1 unimodal baseline'lar olarak sabitlenmiştir. Multimodal fusion ve etiyoloji tahmini gibi ileri hedefler, veri koşuluna bağlı “Faz-2 / gelecek çalışma” olarak planlanmıştır.
- Artımlı geliştirme (iteratif geliştirme): Çalışmalar kısa döngüler halinde ilerletilecektir. Her döngü sonunda “çalışan bir çıktı” üretme hedefi vardır (ör. veri ön işleme hattının tamamlanması, tek bir modalitede baseline modelin eğitilmesi, açıklanabilirlik çıktılarının alınması).

Araçlar ve disiplin:

- Sürüm kontrol: Git tabanlı depo yapısı (kod, konfigürasyon, deney notları)
- Deney izleme: eğitim konfigürasyonlarının (split, seed, giriş boyutu, hiperparametreler) kayıt altına alınması
- Tekrarlanabilirlik: sabit seed, versiyonlanan veri listeleri (train/val/test dosya listeleri), model checkpoint'leri

5.2. İş Paketleri ve Sorumluluklar

Projede tek yürütücü (öğrenci) bulunduğu için görev dağılımı “rol bazlı” tanımlanmıştır. Danışman öğretim üyesi, kritik karar noktalarında (kapsam, metrik seçimi, rapor formatı, etik/sınırlılıklar) doğrulama ve yönlendirme rolüne sahiptir.

İş Paketi (WP) yapısı:

- WP1 – Veri temini ve envanter: veri kaynakları, format/etiket analizi, veri kısıtlarının dokümantasyonu
- WP2 – Veri ön işleme ve standardizasyon: modalite bazlı ön işleme hattı, kalite kontrolleri, augmentasyon politikaları
- WP3 – Unimodal baseline modeller: slit-lamp ikili sınıflandırma, OCT çok sınıflı sınıflandırma, RFMiD yardımcı çoklu etiket deneyi
- WP4 – Değerlendirme ve hata analizi: metrikler, k-fold uygulaması (OCT), dengesizlik yönetimi, karışıklık matrisi/ROC analizleri
- WP5 – Açıklanabilirlik çıktıları: Grad-CAM benzeri ısı haritaları, örnek vaka görselleştirmeleri
- WP6 – Raporlama ve sunum: raporun bölümlerinin tamamlanması, çizelge/şekillerin nihai düzeni, savunma sunumu
- WP7 – Faz-2 genişleme (veri koşuluna bağlı): OCT-A/AS-OCT temini, yeni unimodal modeller, eşleşme varsa fusion denemeleri

5.3. Çalışma Takvimi ve Kilometre Taşları

Aşağıdaki takvim, mevcut durumda tamamlanmış işlerle birlikte ileriye dönük adımları ve çıktıları tanımlar. Tarihler akademik takvime göre güncellenebilir; ancak sıralama ve bağımlılıklar sabittir.

Tamamlanan kilometre taşları:

- Proje öneri raporu tamamlandı (Kasım 2025).
- TÜBİTAK araştırma önerisi tamamlandı (Kasım 2025).
- Literatür taraması ve tablolı literatür değerlendirmesi tamamlandı (Aralık 2025).
- RFMiD etiket analizi ve Çizelge 4.1–4.2 oluşturuldu (Ocak 2026).

Planlanan kilometre taşları (Faz-1 çekirdek):

- Slit-lamp veri hattı + baseline eğitim ve ilk metrik raporu
- OCT (B-scan) 4 sınıf için k-fold değerlendirme ve raporlanabilir sonuç seti
- Açıklanabilirlik görsellerinin (ısı haritaları) örneklerle rapora eklenmesi
- Nihai raporun teknik kısımlarının (yöntem, bulgular, sınırlılıklar) tamamlanması

Çizelge 5.1 İş paketleri, planlanan dönem ve çıktılar

İş Paketi	Planlanan Dönem	Başlıca Çıktı(lar)	Bağımlılık
WP2 (Ön işleme)	Ocak–Şubat 2026	Modalite bazlı standardizasyon hattı; veri listeleri	WP1
WP3 (Unimodal baselineler)	Şubat–Mart 2026	Eğitilmiş modeller; checkpoint’ler, ilk metrik raporu	WP2
WP4 (Değerlendirme)	Mart 2026	K-fold sonuçları (OCT); ROC/F1 tabloları; hata analizi	WP3
WP5 (Açıklanabilirlik)	Mart–Nisan 2026	Isı haritaları; örnek vaka görselleri	WP3
WP6 (Raporlama)	Nisan–Mayıs 2026	Raporun nihai sürümü; sunum dosyası	WP1–WP5
WP7 (Faz-2 genişleme)	Koşullu (Nisan–Haziran 2026)	OCT-A/AS-OCT unimodal; eşleşme varsa fusion denemeleri	Veri temini

Not: WP7, veri temini/eşleştirilmiş multimodal veri bulunmasına bağlı olarak yürütülecektir.

5.4. Risk Yönetimi ve Önlemler

Proje riskleri, gerçekleşme olasılığı ve etkisine göre izlenecek; kritik riskler için önleyici tedbirler uygulanacaktır.

Çizelge 5.2 Riskler ve azaltım planı

Risk	Etkisi	Önlem / Azaltım
OCT-A ve AS-OCT verisi temin edilememesi	Fusion hedefinin gecikmesi	Faz-1 unimodal çıktıları çekirdek teslim olarak sabitleme; Faz-2'yi “gelecek çalışma”ya çekme
Hasta bazlı eşleştirme olmaması	Gerçek multimodal fusion yapılamaması	Fusion iddiasını veri koşuluna bağlama; unimodal sonuçlarla ilerleme
Sınıf dengesizliği (özellikle üveit azınlık)	Yanlı model ve düşük recall	Weighted loss, dengeli örnekleme, eşik ayarı; F1/ROC-AUC odaklı raporlama
OCT veri sayısının çok az olması	Overfitting ve yüksek varyans	K-fold değerlendirme; transfer learning, erken durdurma; düzenleme
Cihaz/kalite heterojenliği	Genellenebilirlik düşüşü	Standardizasyon; kontrollü augmentasyon, hata analizi ve sınırlılıkların açık yazımı
Zaman kısıtı (bitirme takvimi)	İşlerin yetişmemesi	Önceliklendirme: M1+M3 baselinlar ve rapor; RFMiD yardımcı rol

Not: Riskler dönemsel olarak gözden geçirilecek; kritik risklerde (veri temini, zaman) kapsam yönetimi uygulanacaktır.

5.5. Kalite Güvence ve Doğrulama Stratejisi

Proje çıktılarının güvenilirliği için aşağıdaki kalite güvencesi adımları izlenecektir:

- Veri doğrulama: etiket dağılımı ve sınıf sayımları raporlanacak; veri sızıntısı riskine karşı split listeleri versiyonlanacaktır.
- Deney doğrulama: her deney konfigürasyonu (seed, split, hiperparametreler) kayıt altına alınacak; OCT için k-fold sonuçları ortalama $\pm$ standart sapma ile raporlanacaktır.
- Model doğrulama: sınıf dengesizliği nedeniyle tek metrik yerine metrik seti (F1, ROC-AUC, recall, karışıklık matrisi) birlikte yorumlanacaktır.
- Açıklanabilirlik: seçili örneklerde ısı haritaları ile modelin karar bölgeleri raporlanacak; klinik olarak “mantıksız odaklanma” gözlenirse hata analizi bölümünde belirtilecektir.

5.6. İletişim ve İzleme

- Danışman ile düzenli görüşme ve karar kaydı: kapsam değişiklikleri, veri temini durumları, rapor revizyonları
- Ara çıktı kontrol noktaları: her iş paketinin sonunda “raporlanabilir çıktılar” (tablo/şekil/metrik) üretme
- Rapor ilerleme disiplini: her bölüm tamamlandıkça şablon formatına uygun numaralandırma ve çizelge/şekil listeleri güncellenecektir

6. GELECEK ÇALIŞMALAR

Bu proje, klinik pratikte multimodal görüntülemenin rolünü hedefleyen bir karar destek çerçevesi sunmakla birlikte, mevcut aşamada veri gerçekliği (modalitelerin hasta bazında eşleştirilmemiş olması, bazı modalitelerin eksikliği ve sınıf dengesizliği) nedeniyle kapsam, Faz-1 unimodal baselinelar üzerinden yapılandırılmıştır. Bu bölümde, projenin sürdürülebilir biçimde genişletilebilmesi için uygulanabilir ve somut gelecek adımları sunulmaktadır.

1) Veri temini ve veri zenginleştirme (kritik öncelik)

OCT-A ve AS-OCT gibi hedef modaliteler için veri temini girişimlerinin sürdürülmesi; veri sahipleriyle yeniden iletişim kurulması ve kamuya açık veri havuzlarının sistematik taranması.

Mümkün olması durumunda, aynı hastaya ait en az iki modaliteyi içeren eşleştirilmiş (patient-level matched) veri setlerinin temin edilmesi. Bu sağlanmadan yapılacak multimodal fusion denemeleri, klinik gerçekliği temsil etmeyeceği için “araştırma deneyi” düzeyinde tutulmalıdır.

Üveit etiyojisi (Behçet, tüberküloz vb.) hedefleniyorsa, görüntü verisi yanında klinik öykü, laboratuvar ve/veya sistemik bulgular gibi yapılandırılmış değişkenlerin toplanması gerekmektedir. Mevcut veri havuzlarında etiyojisi etiketi bulunmadığı için bu hedef, ancak yeni veri stratejisiyle mümkündür.

2) Veri standardizasyonu ve kalite kontrolünün güçlendirilmesi

Modaliteler arası ve modalite içi heterojenlik (çözünürlük, aydınlatma, cihaz/merkez farkı) için standardizasyon adımlarının iyileştirilmesi (ör. renk/kontrast normalizasyonu, artefakt temizliği).

Veri kalite kontrol süreçlerinin daha sistematik hale getirilmesi (ör. bulanıklık/yanma tespiti, alan dışı görüntülerin işaretlenmesi) ve bu süreçlerin raporda şeffaf biçimde belgelenmesi.

3) Unimodal modellerin geliştirilmesi ve iyileştirilmesi

Faz-1 unimodal modeller tamamlandıktan sonra hata analizi sonuçlarına göre sınıf dengesizliği ve overfitting riskini azaltan iyileştirmelerin uygulanması (ör. sınıf ağırlıkları, dengeli örnekleme, uygun eşik ayarı, erken durdurma, daha kontrollü augmentasyon).

Veri miktarı düşük modalitelerde (özellikle OCT) k-fold değerlendirme protokolü korunarak, performansın varyansını azaltmaya yönelik düzenleme (regularization) ve transfer learning stratejilerinin sistematik karşılaştırılması.

Açıklanabilirlik çıktılarının (ısı haritaları) klinik mantıkla tutarlılığının değerlendirilmesi; “yanlış bölgeye odaklanma” gibi risklerin raporlanması ve gerektiğinde model/ön işleme revizyonu.

4) Multimodal fusion (veri koşuluna bağlı genişleme)

Eşleştirilmiş veri sağlanabildiği takdirde multimodal fusion iki aşamalı bir planla ele alınabilir:

Geç (late) fusion: unimodal modellerin olasılık çıktılarının ağırlıklı birleştirilmesi (basit, hızlı ve raporlanabilir bir başlangıç).

Özellik (feature-level) fusion: unimodal omurgalardan alınan özellik vektörlerinin birleştirilmesi ile daha zengin temsil üretimi.

Bu aşamada eksik modalite senaryoları (her hastada her modalite yok) gerçekçi olduğundan, “eksik modaliteye dayanıklı” fusion stratejileri ayrıca ele alınmalıdır.

5) Dış doğrulama ve genellenebilirlik

Modellerin yalnızca tek bir veri kaynağı üzerinde değil, mümkünse farklı veri havuzları arasında (cross-dataset) test edilmesi; performans düşüşlerinin ve domain shift etkisinin raporlanması.

Genellenebilirlik hedefi doğrultusunda, model kalibrasyonu ve güven skorlarının (confidence) değerlendirilmesi; klinik kullanımda yanlış güven riskinin azaltılması.

6) Klinik karar desteğe yakınlaştırma ve raporlanabilirlik

Üretilen çıktılar için “vaka kartı” formatı (girdi görüntü, tahmin, ısı haritası, model güveni, temel açıklama) geliştirilerek rapor ve sunumda örnek vakalarla gösterim.

Uzun vadede, klinik akışa uyumlu bir prototip arayüz tasarımı ve kullanıcı gereksinimleri (doktor görüşü) doğrultusunda iyileştirme.

7. SONUÇ

Bu bitirme projesi, üveit tanı ve değerlendirme süreçlerinde görüntüleme verilerinin artan rolünü dikkate alarak, yapay zekâ tabanlı ve aşamalı olarak genişletilebilir bir karar destek yaklaşımı geliştirmeyi hedeflemektedir. Klinik pratikte multimodal görüntüleme yaygın olmakla birlikte, bu rapor sürümü itibarıyla veri gerçekliği (modalitelerin hasta bazında eşleştirilmemiş olması ve bazı hedef modalitelerde veri eksikliği) proje kapsamının kademeli biçimde yapılandırılmasını gerekli kılmıştır. Bu doğrultuda, çekirdek teslim hedefi Faz-1 unimodal baselineler olarak belirlenmiş; multimodal fusion ve etiyoloji tahmini gibi ileri hedefler ise veri koşuluna bağlı Faz-2 kapsamında konumlandırılmıştır.

Bu rapor kapsamında; proje önerisi ve araştırma metni temelli hedefler netleştirilmiş, üveit alanındaki seçili yapay zekâ çalışmaları sistematik biçimde taranmış ve Çizelge 2.1 ile karşılaştırmalı bir literatür çerçevesi oluşturulmuştur. Ayrıca mevcut veri havuzları envanterlenmiş, RFMiD veri seti için inflamasyonla ilişkili etiketlerin dağılımı nicel olarak analiz edilerek Çizelge 4.1 ve Çizelge 4.2 üretilmiştir. Yöntem bölümünde; unimodal baselinelerin görev tanımları, ön işleme/standardizasyon ihtiyaçları, eğitim ve değerlendirme protokolleri (özellikle k-fold gereksinimi) ile açıklanabilirlik yaklaşımı gerçekçi biçimde belirlenmiştir. Proje yönetimi açısından iş paketleri, takvim ve risk azaltım planı Çizelge 5.1 ve Çizelge 5.2 ile raporlanmıştır.

Bu aşamada projenin temel katkısı; veri kısıtlarını açıkça görünür kılan, buna rağmen teslim edilebilir çıktıları garanti altına alan ve veri genişledikçe multimodal karar desteğe ölçeklenebilecek modüler bir yol haritası sunmasıdır. Bununla birlikte, hasta bazında eşleştirilmiş multimodal veri eksikliği ve etiyoloji etiketlerinin bulunmaması, multimodal fusion ve etiyoloji tahmini hedeflerinin bu rapor sürümünde doğrudan uygulanmasını sınırlamaktadır.

Bir sonraki aşamada, belirlenen Faz-1 unimodal baselinelerin eğitimi ve değerlendirmesi tamamlanacak; performans metrikleri, karışıklık matrisleri ve açıklanabilirlik görselleri rapora eklenecektir. Veri temini sürecinin başarıya ulaşması durumunda, Faz-2 kapsamında multimodal fusion denemeleri ve daha ileri klinik karar destek hedefleri kademeli biçimde devreye alınacaktır.

KAYNAKLAR

- [1] T. Tsirouki, A. Dastiridou, K. Symeonidis, D. Tounakaki, D. Brazitikou, A. Kalogeropoulos, and I. Androudi, “A Focus on the Epidemiology of Uveitis,” *Ocul. Immunol. Inflamm.*, vol. 26, no. 1, pp. 2–16, 2018, doi: 10.1080/09273948.2016.1196713.
- [2] D. A. Jabs, R. B. Nussenblatt, and J. T. Rosenbaum, “Standardization of uveitis nomenclature for reporting clinical data. Results of the First International Workshop,” *Am. J. Ophthalmol.*, vol. 140, no. 3, pp. 509–516, 2005, doi: 10.1016/j.ajo.2005.03.057.
- [3] I. Putera, J. D. V. Quiros, S. M. Rombach, et al., “Artificial Intelligence-Based Uveitis Diagnosis Through Retinal Vasculature Analysis: A Paradigm Shift in Ocular Tuberculosis,” *Ophthalmol. Ther.*, vol. 14, pp. 717–732, 2025, doi: 10.1007/s40123-025-01103-4.
- [4] J. Sun, X. Huang, C. E. Egbuagu, et al., “Identifying Mouse Autoimmune Uveitis from Fundus Photographs Using Deep Learning,” *Transl. Vis. Sci. Technol.*, vol. 9, no. 2, Art. no. 59, pp. 1–10, 2020, doi: 10.1167/tvst.9.2.59.
- [5] D. Dhirachaikulpanich, J. Xie, X. Chen, X. Li, S. Madhusudhan, Y. Zheng, and N. A. V. Beare, “Using Deep Learning to Segment Retinal Vascular Leakage and Occlusion in Retinal Vasculitis,” *Ocul. Immunol. Inflamm.*, vol. 32, no. 10, pp. 1–8, 2024, doi: 10.1080/09273948.2024.2305185.
- [6] S. Haggag, F. Khalifa, H. Abdeltawab, et al., “An Automated CAD System for Accurate Grading of Uveitis Using Optical Coherence Tomography Images,” *Sensors*, vol. 21, no. 16, Art. no. 5457, 2021, doi: 10.3390/s21165457.
- [7] S. R. B. Murugan, S. Sanjay, A. Somanath, et al., “Artificial Intelligence in Uveitis: Innovations in Diagnosis and Therapeutic Strategies,” *Clin. Ophthalmol.*, vol. 18, pp. 3753–3766, 2024, doi: 10.2147/OPTH.S495307.
- [8] T. Oshika, “Artificial Intelligence Applications in Ophthalmology,” *JMA J.*, vol. 8, no. 1, pp. 66–75, 2025, doi: 10.31662/jmaj.2024-0139.

- [9] W. Zhang, Z. Chen, H. Zhang, et al., “Detection of Fuchs’ Uveitis Syndrome From Slit-Lamp Images Using Deep Convolutional Neural Networks in a Chinese Population,” *Front. Cell Dev. Biol.*, vol. 9, Art. no. 684522, 2021, doi: 10.3389/fcell.2021.684522.
- [10] F. Pichi, G. Ometto, A. Invernizzi, et al., “Automated quantification of uveitic keratic precipitates by use of anterior segment optical coherence tomography,” *Clin. Exp. Ophthalmol.*, vol. 51, no. 8, pp. 790–798, 2023, doi: 10.1111/ceo.14296.
- [11] R. Jacquot, L. Ren, T. Wang, et al., “Neural networks for predicting etiological diagnosis of uveitis,” *Eye*, vol. 39, pp. 992–1002, 2025, doi: 10.1038/s41433-024-03530-2.
- [12] L. F. Nakayama, L. Z. Ribeiro, R. G. Dychiao, et al., “Artificial intelligence in uveitis: A comprehensive review,” *Surv. Ophthalmol.*, vol. 68, no. 4, pp. 669–677, 2023, doi: 10.1016/j.survophthal.2023.02.007.