

Literatür

Üveit, göz içi inflamasyonla seyreden, etiyojisi heterojen ve tanı süreci karmaşık bir hastalık grubudur. Klinik değerlendirme çoğu zaman tek bir bulguya dayanmaz; anterior segment muayenesi, fundus incelemesi, optik koherens tomografi (OCT), gerektiğinde anjiyografik yöntemler ve klinik/laboratuvar verilerin birlikte yorumlanmasını gerektirir. Bu nedenle üveit, hem önemli bir görme kaybı nedeni olması hem de çok boyutlu değerlendirme gerektirmesi nedeniyle yapay zekâ destekli sistemler için dikkat çekici bir çalışma alanıdır [1], [2].

Oftalmolojide yapay zekâ uygulamaları özellikle diyabetik retinopati, yaşa bağlı makula dejenerasyonu ve glokom gibi hastalıklarda başarılı sonuçlar vermiştir. Ancak üveitte aynı düzeyde standartlaşmış ve yaygınlaşmış çözümler henüz oluşmamıştır. Bunun başlıca nedenleri; üveitin tek bir hastalık olmaması, çok sayıda anatomik ve etiyojik alt tipe sahip olması, veri setlerinin küçük ve heterojen yapıda bulunması ve geliştirilen modellerin dış doğrulama ile yeterince desteklenmemesidir. Murugan ve ark.'nın derlemesinde, üveitte yapay zekâ çalışmalarının tanısallık destek, tarama, inflamasyon derecelendirme ve yönetim başlıklarında toplandığı; buna karşılık veri kalitesi, açıklanabilirlik ve multimodal entegrasyon eksikliğinin temel sınırlılıklar olarak sürdüğü belirtilmiştir [3].

Fundus görüntüleme temelli araştırmalar, üveitte retinal damar yapısı ve arka segment inflamatuvar değişikliklerin nicel olarak analiz edilebileceğini göstermektedir. Putera ve ark., oküler tüberkülozun diğer bazı üveit tablolarından ayırımında fundus fotoğraflarından çıkarılan retinal vasküler parametreleri kullanmış ve özellikle venöz tortüozitenin ayırt edici olabileceğini göstermiştir [4]. Bu yaklaşım, yalnızca sınıflandırma değil, biyobelirteç çıkarımı açısından da önemlidir. Bununla birlikte çalışma belirli etiyojilerle sınırlıdır ve genel üveit tanısına doğrudan genellenemez. Benzer biçimde, Sun ve ark. deneysel otoimmün üveit modelinde fundus görüntülerinden derin öğrenme ile başarılı sınıflandırma bildirmiştir; ancak bu sonuçların insan verisine aktarımı sınırlıdır [5]. Retinal vaskülit özelinde Dhirachakulpanich ve ark. ise ultra-geniş alan florescein anjiyografi görüntülerinde sızıntı ve tıkanıklık segmentasyonu yaparak inflamatuvar bulguların otomatik tespitinin mümkün olduğunu göstermiştir [6]. Bu çalışmalar umut verici olsa da çoğu belirli bulgular veya belirli alt gruplar üzerine odaklanmaktadır.

OCT tabanlı çalışmalar ise daha çok inflamasyon şiddetinin nesnel değerlendirilmesine yönelmiştir. Haggag ve ark. tarafından geliştirilen OCT tabanlı sistem, vitreus segmentasyonu ve sınıflandırmayı birleştirerek üveit derecelendirmesinde güçlü performans göstermiştir [7]. Bu bulgu, özellikle vitreus bulanıklığı gibi klinikte daha

subjektif değeriendirilen parametrelerin görüntü tabanlı biçimde nesnelleştirilebileceğini göstermektedir. Benzer şekilde Pichi ve ark., AS-OCT kullanarak üveitik keratik presipitatların otomatik hacimsel nicelleştirilmesini gerçekleştirmiş ve aktif-sakin dönemler arasında anlamlı fark saptamıştır [8]. Bu sonuçlar, ön segment ve vitreoretinal inflamasyonun ölçülebilir biyobelirteçlere dönüştürülebileceğini göstermektedir. Bununla birlikte bu çalışmaların büyük kısmı genel tanı veya etiyoloji ayırımından çok, belirli inflamatuvar bulguların ölçümüne odaklanmaktadır.

Ön segment görüntülerine dayalı derin öğrenme çalışmaları da literatürde yer almaktadır. Zhang ve ark., slit-lamp görüntülerinden Fuchs üveit sendromunun saptanması için geliştirdikleri derin öğrenme modelinde yüksek doğruluk ve AUC değeri bildirmiştir [9]. Ayrıca dikkat haritalarıyla model kararlarının görselleştirilmesi, klinik güven ve açıklanabilirlik açısından önemlidir [9]. Bununla birlikte bu tür çalışmalar genellikle tek hastalık, tek modalite ve kontrollü veri koşullarıyla sınırlıdır. Gerçek klinik ortamda cihaz farkları, ışık koşulları, görüntü kalitesi ve etiketleme standardizasyonu gibi sorunlar genellenebilirliği zorlaştırmaktadır [3], [8], [9].

Üveitte karar verme yalnızca görüntüye dayanmadığından, bazı araştırmalar klinik-demografik verilerden etiyoloji tahminine yönelmiştir. Jacquot ve ark., 375 hasta ve 25 farklı üveit nedenini içeren kohortta, klinik ve tamamlayıcı

test verileriyle geliştirdikleri çok katmanlı algılayıcı modelinde ilk tahminde %77.8, ilk iki tahminde ise %93 doğruluk bildirmiştir [10]. Bu sonuç, üveit etiyolojisinin görüntü dışı klinik bilgilerden güçlü biçimde etkilendiğini göstermektedir. Ancak görüntü ve klinik veriyi hasta bazında bütünleştiren, açıklanabilir ve doğrulanmış multimodal sistemler hâlâ sınırlıdır [3], [10].

Mevcut literatür birlikte değerlendirildiğinde, üveitte yapay zekâ uygulamalarının önemli potansiyel taşıdığı; ancak alanın büyük ölçüde tek modalite–tek görev düzeyinde kaldığı görülmektedir. Oysa klinik pratikte üveit tanısı çoğunlukla çoklu görüntüleme ve klinik bağlamın birlikte değerlendirilmesini gerektirir [2], [3]. Bu nedenle literatürdeki temel boşluk; açıklanabilirliği yüksek, doğrulanabilir ve mümkün olduğunda multimodal yapıdaki karar destek sistemlerinin yetersizliğidir. Bu çalışma, söz konusu boşluğu mevcut veri gerçekliğini göz önünde bulundurarak ele almaktadır. Hasta bazında eşleştirilmiş multimodal veri sınırlı olduğundan, ilk aşamada slit-lamp ve OCT gibi erişilebilir modalitelerde açıklanabilir unimodal baseline modeller geliştirmek daha gerçekçi bir yaklaşımdır. Böylece çalışma, mevcut parçalı literatür ile gelecekte geliştirilebilecek daha kapsamlı multimodal sistemler arasında uygulanabilir bir ara basamak sunmayı amaçlamaktadır [3], [7], [10].

Kaynaklar

- [1] T. Tsirouki, A. Dastiridou, K. Symeonidis, D. Tounakaki, I. Brazitikou, C. Kalogeropoulos ve I. Androudi, "A Focus on the Epidemiology of Uveitis," *Ocular Immunology and Inflammation*, c. 26, s. 1, ss. 2–16, 2018.
- [2] J. H.-M. Chang ve D. Wakefield, "Uveitis: a global perspective," *Ocular Immunology and Inflammation*, c. 10, s. 4, ss. 263–279, 2002.
- [3] S. R. B. Murugan, S. Sanjay, A. Somanath ve ark., "Artificial Intelligence in Uveitis: Innovations in Diagnosis and Therapeutic Strategies," *Clinical Ophthalmology*, c. 18, ss. 3753–3766, 2024.
- [4] I. Putera, J. D. V. Quiros, S. M. Rombach ve ark., "Artificial Intelligence-Based Uveitis Diagnosis Through Retinal Vasculature Analysis: A Paradigm Shift in Ocular Tuberculosis," *Ophthalmology and Therapy*, c. 14, ss. 717–732, 2025.
- [5] J. Sun, X. Huang, C. E. Egbuagu ve ark., "Identifying Mouse Autoimmune Uveitis from Fundus Photographs Using Deep Learning," *Translational Vision Science & Technology*, c. 9, s. 2, md. 59, 2020.
- [6] D. Dhirachaikulpanich, J. Xie, X. Chen, X. Li, S. Madhusudhan, Y. Zheng ve N. A. V. Beare, "Using Deep Learning to Segment Retinal Vascular Leakage and Occlusion in Retinal Vasculitis," *Ocular Immunology and Inflammation*, c. 32, s. 10, 2024.
- [7] S. Haggag, F. Khalifa, H. Abdeltawab ve ark., "An Automated CAD System for Accurate Grading of Uveitis Using Optical Coherence Tomography Images," *Sensors*, c. 21, s. 16, md. 5457, 2021.
- [8] F. Pichi, G. Ometto, A. Invernizzi ve ark., "Automated Quantification of Uveitic Keratic Precipitates by Use of Anterior Segment Optical Coherence Tomography," *Clinical and Experimental Ophthalmology*, c. 51, s. 8, ss. 790–798, 2023.
- [9] W. Zhang, Z. Chen, H. Zhang ve ark., "Detection of Fuchs' Uveitis Syndrome From Slit-Lamp Images Using Deep Convolutional Neural Networks in a Chinese Population," *Frontiers in Cell and Developmental Biology*, c. 9, md. 684522, 2021.
- [10] R. Jacquot, L. Ren, T. Wang ve ark., "Neural Networks for Predicting Etiological Diagnosis of Uveitis," *Eye*, c. 39, ss. 992–1002, 2025.