



TÜBİTAK 2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI

Başvuru formunun Arial 9 yazı tipinde, her bir konu başlığı altında verilen açıklamalar göz önünde bulundurularak hazırlanması ve ekler hariç toplam 20 sayfayı geçmemesi beklenir (Alt sınır bulunmamaktadır). Değerlendirme araştırma önerisinin bilimsel niteliği, yöntemi, proje yönetimi ve yaygın etkisi başlıkları üzerinden yapılacaktır.

ARAŞTIRMA ÖNERİSİ FORMU

2025 Yılı

1. Dönem Başvurusu

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI

ARAŞTIRMA ÖNERİSİ FORMU

A. GENEL BİLGİLER

Başvuru Sahibinin Adı Soyadı: Recep Öztürk
Araştırma Önerisinin Başlığı: Multimodal Görüntü Analizi ile Üveit (Göz İçi Tabakasının İltihabı) Tanısı için Yapay Zekâ Tabanlı Açıklanabilir Karar Destek Sistemi
Danışmanın Adı Soyadı: İnan Kazancı
Araştırmanın Yürütüleceği Kurum/Kuruluş: Ankara Üniversitesi

ÖZET

Araştırma önerisi özetinin (1) bilimsel nitelik; (2) yöntem; (3) proje yönetimi ve (4) yaygın etki hakkında bilgileri kapsamı beklenir. Bu bölümün en son yazılması önerilir.

Bu proje, üveit ve benzeri arka segment hastalıklarında hem tanı/alt tip ayrımını hem de 3–6 ay içindeki nöks riskini aynı yapay zekâ modeliyle öngörmeyi hedefliyor. Literatürde çoğu çalışma yalnızca tek bir görüntüleme türüne (fundus veya OCT/OCTA gibi) ve sadece tanısal sınıflamaya odaklanırken, burada fundus, anterior segment ve OCT/OCTA verileri birlikte kullanılıyor ve sonuçlar kalibre edilmiş nöks olasılığı ile destekleniyor. Model çıktılarının ısı haritaları ve vaka kartlarıyla görsel olarak açıklanması da projeyi, klasik “kara kutu” yaklaşımlardan ayıran özgün bir yön olarak öne çıkarıyor.

Yöntem tarafında çalışma, tamamen açık erişimli ve kimliksizleştirilmiş göz görüntüleri üzerinde yürütülen retrospektif, yazılım temelli bir yapay zekâ projesi olarak tasarlandı. Önce uygun fundus, anterior segment ve OCT/OCTA veri setleri seçilerek ortak bir etiket sözlüğü altında “Üveit Veri Havuzu v1” oluşturulacak. Ardından modaliteye özgü ön işleme ve kalite kontrol adımları tamamlanacak, her kip için CNN tabanlı tek-modelli derin öğrenme modelleri eğitilecek ve bu modellerin encoder çıktıları orta seviyede birleştirilerek tanı/alt tip sınıflaması ile 3–6 aylık nöks olasılığını aynı anda üreten çok görevli bir füzyon mimarisi kurulacak. Performans, AUC, F1, C-index ve Brier skoru gibi ölçütlerle değerlendirilecek; Grad-CAM gibi yöntemlerle üretilecek ısı haritaları, seçilmiş olgular için vaka kartlarıyla birlikte yorumlanacak.

Proje yönetimi, lisans düzeyinde bir yürütücü ve danışman öğretim üyesi iş birliğiyle yaklaşık sekiz aylık bir takvimde planlandı. İlk iki ay literatür taraması, veri setlerinin seçimi ve veri havuzunun oluşturulmasına; üçüncü ve dördüncü ay ön işleme hattının kurulması ve tek-modelli modellerin geliştirilmesine ayrılacak. Beşinci ve altıncı aylarda çok kipli füzyon mimarisi ve nöks modülü üzerinde çalışılacak, son iki ayda ise açıklanabilirlik analizleri, kod ve deney ayarlarının dokümantasyonu, sonuç raporu ve olası bildiri taslakları hazırlanacak. Bu süreçte öğrenci günlük teknik işleri üstlenirken, danışman yöntem seçimi ve sonuçların yorumlanması konularında yönlendirici rol oynayacak.

Yaygın etki açısından proje, üveit alanında çok kipli ve açıklanabilir yapay zekâ temelli yerli bir karar destek prototipinin geliştirilmesine katkı sunmayı hedefliyor. İyi belgelenmiş “Üveit Veri Havuzu v1” ve Python/PyTorch tabanlı kod deposu, ileride yürütülecek klinik iş birlikleri ve daha kapsamlı projeler için tekrar kullanılabilir bir altyapı sağlayacak. Aynı zamanda proje, yürütücünün veri hazırlama, model kurma, değerlendirme ve raporlama basamaklarını uçtan uca deneyimlemesine imkân vererek lisans düzeyinde araştırma ve yazılım geliştirme becerilerini güçlendirecek.

Anahtar Kelimeler: Yapay zekâ, derin öğrenme, tıbbi görüntü işleme, multimodal görüntü analizi, üveit tanısı.

1. ARAŞTIRMA ÖNERİSİNİN BİLİMSEL NİTELİĞİ

1.1. Konunun Önemi ve Araştırma Önerisinin Bilimsel Niteliği

Araştırma önerisinde ele alınan konunun kapsamı, sınırları ve önemi ortaya konulur. Araştırma önerisi kapsamında yapılacak çalışmalarla literatürdeki hangi eksikliğin nasıl giderileceği veya hangi soruna nasıl bir çözüm getirileceği ilgili literatüre atıfla açıklanarak araştırma önerisinin bilimsel niteliği ortaya konulur. Araştırma sorusu ve varsa hipotez(ler)i tanımlanır.

Projenin konusu, 12. Kalkınma Planı ve 2030 Sanayi ve Teknoloji Stratejisi’nde yer alan kritik teknoloji alanları ile öncelikli Ar-Ge ve yenilik konuları ile ilişkili ise, ilişkilendirilme sebebi ve ilgili alana sağlayacağı yararlar açıklanmalıdır.

Üveit, üvea tabakalarını (iris, siliyer cisim, koroid) odağa alan ancak çoğu zaman retina ve vitreusu da sürece katan, son derece heterojen bir intraoküler inflamasyon grubudur. Farklı ülkelerden gelen geniş ölçekli epidemiyolojik veriler, üveitin erişkin yaş grubunda önlenemez görme kaybı ve körlüğün önde gelen nedenlerinden biri olduğunu; insidans ve prevalans değerlerinin coğrafyaya göre geniş bir aralıkta değiştiğini göstermektedir [1–

3]. Özellikle çalışma çağındaki bireylerde hastalığın kronik seyri, sık nüks etmesi ve uzun süreli tedavi gerektirmesi, görme kaybının ötesinde ciddi bir sosyal ve ekonomik yük doğurmaktadır [1–3]. Buna rağmen, güncel sınıflama şemaları anterior, intermediyer, posterior ve panuveit alt tiplerini tanımlasa da, büyük serilerde bile olguların kayda değer bir kısmının hâlâ “idiyopatik” başlığı altında toplanması, etiyolojik ayrımın önemli ölçüde klinik deneyime ve merkeze özgü yaklaşımlara dayandığını göstermektedir [1,2]. Hastalığın kronikleşme ve nüks etme eğilimi, sadece görme keskinliği üzerindeki etkiler nedeniyle değil, uzun süreli tedavi gereksinimi, sık kontrollere ihtiyaç duyulması ve eşlik eden sistemik hastalıklarla ilişkisi nedeniyle de hasta ve sağlık sistemi üzerine kayda değer bir yük bindirmektedir [2,3]. Günlük pratikte hekimler, nüks olasılığını çoğu zaman klinik deneyim, önceki atak sayısı ve eşlik eden laboratuvar bulgularına dayanarak nitel biçimde tahmin etmekte; belirli bir zaman dilimi için sayısal, kalibre edilmiş bir risk skoru sunan standart araçlar bulunmamaktadır. Tanı ve alt tip ayrımında benzer bir durum söz konusudur: Geniş bir etiyolojik yelpaze içinde hastayı doğru gruba yerleştirmek çoğu kez güç olmakta, karar süreçleri bireysel yorumlara bağımlı kalmaktadır [3].

Son yıllarda görüntüleme teknolojilerindeki gelişmeler, üveit pratiğini kökten değiştirmiş durumdadır. Fundus fotoğrafı ve fundus floresin anjiyografi; retina ve koroidi yüksek çözünürlüklü olarak gösteren optik koherens tomografi (OCT); mikrovasküler yapıyı damar içi boya kullanmadan ortaya koyan OCT anjiyografi (OCTA) ve ön segment optik koherens tomografi (AS-OCT) sayesinde üveit hastalarından her muayenede büyük hacimde dijital veri elde edilmektedir. Bu veriler, keratik presipitat yükü, vitreus bulanıklığı, makula kalınlığı, retina ve koroid damar yoğunluğu, foveal avasküler zon (FAZ) alanı gibi çok sayıda nicel parametreye dönüştürülebilmektedir. Örneğin Pichi ve arkadaşları, AS-OCT görüntülerinden keratik presipitatların otomatik nicel ölçümünü sağlayan bir yöntem tanımlayarak kornea arka yüzündeki inflamasyonun sayısallaştırılabileceğini göstermiştir [4]. Benzer şekilde Mellak ve arkadaşları, murin üveit modelinde OCT görüntülerini kullanarak inflamasyon derecesini makine öğrenmesi ile skorlayan bir çerçeve önermiş ve deneysel çalışmalar için objektif bir değerlendirme aracı geliştirmiştir [5]. Bu tür çalışmalar, üveit alanında da görüntü temelli ölçümlerin yalnızca nitel gözlemlerle sınırlı kalmaması gerektiğini açıkça ortaya koymaktadır.

Retina hastalıkları özelinde derin öğrenmeye dayalı yaklaşımlar çok daha olgun bir noktaya gelmiştir. Ultra geniş alan fundus floresin anjiyografi kullanılarak 30 farklı fundus hastalığının otomatik saptanmasını hedefleyen derin uzman topluluğu (deep experts aggregation) modelinin yüksek doğruluk ve genellenebilirlik düzeylerine ulaştığı bildirilmiştir [6]. Öte yandan, TCDDU-Net gibi transformer ve evrimsel katmanları birleştiren hibrit mimariler, retinal damar segmentasyonunda ince kılcal damarların ve düşük kontrastlı bölgelerin daha başarılı biçimde yakalanmasını sağlayarak alandaki performans sınırlarını ötelemektedir [7]. Bu iki örnek, fundus ve OCT/OCTA görüntülerinin derin öğrenme modelleriyle işlenmesinin teknik olarak mümkün olmanın ötesinde, klinik karar süreçlerine somut katkı sunabilecek olgunluğa ulaştığını göstermektedir [6,7,9]. Abràmoff ve arkadaşlarının retinal görüntüleme ve görüntü analizi alanına ilişkin klasik çalışması da göz fotoğraflarının sadece tanı koymak için değil, aynı zamanda hastalık yükünü ve tedavi yanıtını nicel olarak izlemek için kullanılabileceğini ayrıntılı biçimde ortaya koymaktadır [9].

Üveit özelinde yapay zekâ kullanımı ise nispeten yeni bir araştırma alanıdır ve mevcut literatür daha çok belirli niş problemlere odaklanmıştır. Kapsamlı bir derleme, anterior segment OCT ile keratik presipitat ve ön kamara hücre yükünün otomatik hesaplanması, OCT üzerinden vitreus bulanıklığının derecelendirilmesi ve farklı görüntüleme teknikleri yardımıyla inflamasyonun objektif skorlanması gibi uygulamaları bir araya getirmektedir [8]. Yine son yıllarda, retinal damar yapısından yola çıkarak tüberküloz ilişkili üveit tanısının desteklenmesine yönelik modellerin geliştirildiği; bazı çalışmalarda da klinik ve görüntü verilerini kullanarak etiyolojik tanı olasılıklarını tahmin eden sinir ağı tabanlı yaklaşımlar önerildiği bildirilmektedir [5,8]. Ancak bu çalışmalar çoğunlukla tek bir görüntüleme kipine (yalnız fundus, yalnız OCT ya da yalnız ön segment) ve tek bir çıktıya –örneğin sadece tanısal sınıflamaya– odaklanmakta; nüks riski, zaman içindeki hastalık seyrinin modellenmesi ve model çıktılarının klinik açıdan yorumlanabilirliği görece arka planda kalmaktadır [4,5,8]. Çalışmaların büyük bölümünün tek merkezli, görece küçük örneklemle dayanması, geliştirilen modellerin farklı cihazlar, merkezler ve hasta topluluklarına ne ölçüde genellenebildiği, risk tahminlerinin ne kadar iyi kalibre edildiği ve klinisyen tarafından ne kadar güvenle kullanılabileceği gibi önemli soruları da açık bırakmaktadır [1,8].

Bu araştırma önerisi, tam da bu noktada ortaya çıkan boşluğu hedeflemektedir. Temel soru şudur: Fundus, anterior segment ve OCT/OCTA görüntülerini, mevcut olduğunda temel klinik bilgilerle birlikte kullanan, açıklanabilir ve kalibrasyonu yapılmış bir derin öğrenme modeli, üveit olgularında hem tanı/alt tip ayrımını hem de 3–6 aylık nüks olasılığını güvenilir biçimde öngörebilir mi? Çalışmada bu soruya yanıt aramak için; her bir görüntüleme modalitesi için ayrı özellik çıkarıcı ağlar kurulacak, bu ağlardan elde edilen temsil vektörleri çok kipli bir füzyon katmanında birleştirilecek ve ortaya çıkan ortak temsil üzerinden hem tanı/alt tip sınıflaması hem de kısa dönem nüks olasılığı için çok görevli (multi-task) bir model tasarlanacaktır. Model çıktıları yalnızca olasılık skorları olarak bırakılmayacak; Grad-CAM benzeri yöntemlerle üretilen ısı haritaları ve değişken katkı analizleri ile hangi damar bölgelerinin, makula yapılarının ya da klinik göstergelerin karara ne ölçüde etki ettiği görsel ve sayısal olarak ortaya konacaktır.

Bu yaklaşımın mevcut literatüre göre üç temel katkısı hedeflenmektedir:

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI ARAŞTIRMA ÖNERİSİ FORMU

1. Tek modalite yerine çok kipli veri kullanımı: Fundus, anterior segment ve OCT/OCTA verilerinin aynı model altında bütünleştirilmesi, tek kipli modellere kıyasla tanısallık duyarlılığı artırma potansiyeli taşımaktadır [4–7].
2. Tanı ve prognozun birlikte modellenmesi: Hem tanı/alt tip ayrımı hem de belirli bir zaman ufku riskinin aynı mimari içinde ele alınması, klinisyenlere “bu hastanın nasıl bir üveit tablosu var ve yakın dönemde yeniden alevlenme ihtimali ne kadar?” sorularına tek bir araç üzerinden yanıt verebilme imkânı sağlayacaktır.
3. Açıklanabilirlik ve kalibrasyona özel vurgu: Modelin yalnızca yüksek doğruluk sağlaması yeterli görülmeyecek; olasılık tahminlerinin istatistiksel kalibrasyonu ve görsel açıklamaların uzman hekimlerce ne kadar ikna edici bulunduğu da sistematik olarak değerlendirilecektir [5,8,9].

Bu yönleriyle proje, 12. Kalkınma Planı ve Türkiye Ulusal Yapay Zekâ Stratejisi’nde vurgulanan “sağlıkta dijital dönüşüm”, “yapay zekâ temelli klinik karar destek sistemleri” ve “yerli yapay zekâ çözümlerinin geliştirilmesi” hedefleriyle doğrudan örtüşmektedir. Multimodal ve açıklanabilir bir model çerçevesinin geliştirilmesi; uzun vadede ulusal göz görüntüleme altyapısıyla bütünleşebilecek yerli karar destek sistemleri için somut bir teknik temel sunarken, kronik inflamatuvar göz hastalıklarının bireyselleştirilmiş izlemi konusunda da ulusal literatüre özgün ve sürdürülebilir bir katkı sağlamayı amaçlamaktadır.

1.2. Amaç ve Hedefler

Araştırma önerisinin amacı ve hedefleri açık, ölçülebilir, gerçekçi ve ulaşılabilir nitelikte olacak şekilde yazılır.

Bu araştırmanın genel amacı, üveitli hastalarda hem tanı ve alt tip ayrımındaki belirsizliği azaltmak hem de kısa dönem (3–6 ay) nüks riskini sayısal olarak öngörebilmek için, fundus, anterior segment ve OCT/OCTA görüntülerini – mevcut olduğunda temel klinik verilerle birlikte – derin öğrenme tabanlı, açıklanabilir bir karar destek modeli altında bir araya getirmektir. Böyle bir modelin, klinisyenin kararını tek başına belirleyen bir “otomatik teşhis” aracı olmasından ziyade, kendi öngörüsünü sayısal ve görsel kanıtlarla birlikte sunan, denetlenebilir bir araştırma amaçlı prototip olması hedeflenmektedir.

Literatürde üveite yönelik yapay zekâ çalışmalarının çoğu, tek bir görüntüleme modalitesine odaklanan ve genellikle yalnızca tanısallık sınıfı yapma amaçlı sınırlıdır [4], [5], [8]. Nüks riskinin kalibre edilmiş olasılık biçiminde modellenmesi, farklı modalitelerin aynı model altında birleştirilmesi ve model çıktılarının klinik açıdan anlamlı açıklamalarla desteklenmesi alanında belirgin bir boşluk bulunmaktadır. Bu proje, söz konusu boşluğu, lisans düzeyinde yürütülen ancak metodolojik olarak titiz bir çalışma ile doldurmayı amaçlamaktadır.

Projede geliştirilecek sistem, tedavi kararı veren bir tıbbi cihaz olarak değil, geriye dönük görüntü ve sınırlı klinik veriler üzerinde çalışan, ürettiği sonuçları hipotez üretimi ve yöntem geliştirme amaçlı sunan bir kanıt-ofis prototipi (proof of concept) şeklinde tasarlanacaktır. Çalışma kapsamı erişkin üveit olgularıyla sınırlandırılacak; renkli fundus, anterior segment fotoğrafı/AS-OCT ve OCT/OCTA temel görüntü modaliteleri olarak ele alınacaktır. Veri setlerinde yer aldığı ölçüde yaş, cinsiyet ve temel sistemik tanılar gibi az sayıda klinik değişken modele dahil edilecektir. Nüks öngörüsü 3–6 aylık bir zaman ufkuyla sınırlanacak; prospektif hasta takibi, ilaç doz ayarı veya uzun dönem (>1 yıl) prognoz modellemesi bu projenin kapsamı dışında bırakılacaktır.

Bu genel çerçeve doğrultusunda araştırmanın özel hedefleri aşağıdaki gibi yapılandırılmıştır:

1. Üveit odaklı çok kipli bir veri havuzu oluşturmak

Açık erişimli fundus, anterior segment ve OCT/OCTA veri setlerinden üveit ve karşılaştırma gruplarına (diğer retinal hastalıklar, sağlıklı kontroller vb.) ait kayıtları seçmek; farklı veri setlerindeki tanı ve etiketleri mümkün olduğunca ortak bir taksonomi altında yeniden adlandırmak; görüntüleri boyut, kontrast ve parlaklık bakımından standardize ederek “Üveit Veri Havuzu v1” adıyla düzenlenmiş bir çalışma seti oluşturmak. Bu havuz, ileride yapılacak benzer projeler için de yeniden kullanılabilir bir temel sağlayacaktır.

2. Tek kipli (fundus / anterior segment / OCT/OCTA) temel modelleri geliştirmek

Her bir görüntü modalitesi için, retina ve üveit görüntüleri üzerinde daha önce denenmiş derin öğrenme mimarilerini (örneğin ResNet/EfficientNet türevleri, U-Net benzeri yapılar) kullanarak ayrı ayrı tanı/alt tip

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

sınıflandırma modelleri eğitmek. Bu modellerde ROC eğrisi altında kalan alan (AUC), F1 skoru, duyarlılık ve seçicilik gibi ölçütlerle en az “kabul edilebilir” düzeyde (örneğin $AUC \geq 0.75$ bandında) bir temel performans elde etmek ve bu sonuçları çok kipli modelle yapılacak karşılaştırmalar için referans kabul etmek.

3. Çok kipli füzyon modelini tasarlamak ve tek kipli modellerle karşılaştırmak

Fundus, anterior segment ve OCT/OCTA görüntülerinden elde edilen kip-içi temsilleri orta seviyede birleştiren bir derin öğrenme mimarisi tasarlamak. Her bir modaliteye ait encoder çıktılarının ortak bir özellik uzayında füzyonunu sağlayarak, tanı/alt tip sınıflandırması için çok kipli bir model eğitmek. Aynı eğitim/doğrulama/test bölünmesi üzerinde tek kipli modellerle kıyaslama yaparak, çok kipli yapının tanınal performansı ne ölçüde iyileştirdiğini nicel olarak göstermek; bu iyileşmenin istatistiksel açıdan anlamlı olup olmadığını test etmek.

4. Nüks riskini kalibre edilmiş olasılık biçiminde modellemek

Nüks bilgisi mevcut olan alt kümede, 3–6 aylık nüks için zaman bağımlı bir risk modeli kurmak. Bu amaçla, çok görevli (multi-task) bir yapı içinde nüks başlığını ayrı bir çıktı katmanı olarak tanımlamak; gereksinim duyulursa kalibrasyon için Platt ölçekleme veya isotonic regression gibi yöntemler kullanmak. Model çıktısını “yüksek / orta / düşük risk” gibi kaba sınıflar yerine, klinisyenin yorumlayabileceği kalibre edilmiş olasılık değerleri olarak raporlamak; C-index, Brier skoru ve kalibrasyon eğrileri ile ayırt edicilik ve kalibrasyon düzeyini değerlendirmek.

5. Model çıktılarının açıklanabilirliğini sağlamak ve vaka kartları oluşturmak

Geliştirilen tek ve çok kipli modeller için Grad-CAM veya benzeri görsel açıklama yöntemleri kullanarak, modelin karar verirken görüntü üzerinde hangi bölgelere odaklandığını gösteren ısı haritaları üretmek. Uygun veri setlerinde mevcutsa, FAZ alanı, damar yoğunluğu veya makula kalınlığı gibi nicel parametrelerle model skorları arasındaki ilişkiyi inceleyerek öznitelik katkı özetleri hazırlamak. En az 20 temsil edici hasta için tanı/alt tip skoru, 3–6 aylık nüks olasılığı ve buna eşlik eden açıklama görsellerini bir araya getiren “vaka kartları” tasarlamak ve bu kartları, danışılan göz hekimlerinden alınacak nitel geri bildirimlerle klinik açıdan değerlendirmek.

6. Dayanıklılık ve yeniden üretilebilirlik için asgari standartları sağlamak

Eksik modalite senaryolarında (yalnız fundus, yalnız OCT/OCTA veya fundus + OCT gibi kısmi kombinasyonlar mevcutken) model performansını test ederek, sistemin gerçek hayatta sık karşılaşılan “tam olmayan veri” durumlarına ne ölçüde uyum sağlayabildiğini göstermek. Farklı çözünürlük, cihaz türü veya görüntü kalitesi düzeylerinde modelin duyarlılığını sınamak. Kullanılan kodları, eğitim ayarlarını, veri sözlüğünü ve ön işleme adımlarını bir sürüm kontrol sistemi altında belgeleyerek, daha sonra aynı deneylerin yeniden çalıştırılmasına imkân verecek asgari şeffaflığı sağlamak.

7. Bilimsel rapor ve çıktıların hazırlanmasını sağlamak

Elde edilen bulguları yöntem, deneyler ve sınırlılıklar bölümleriyle birlikte ayrıntılı bir teknik rapor hâline getirmek. Sonuçları özetleyen ve yöntemin ana hatlarını açıklayan bir kısa bildiri/özet metin hazırlayarak en az bir ulusal kongre ya da sempozyumda sunulabilecek bir çıktı üretmek. Proje sürecinde yürütülen veri toplama, model geliştirme, değerlendirme ve raporlama adımlarını, lisans düzeyinde araştırma yetkinliğini güçlendirecek biçimde sistematik olarak belgelemek.


Bu hedefler bir arada değerlendirildiğinde, çalışma hem üveit alanında çok kipli ve açıklanabilir bir yapay zekâ prototipinin ilk örneklerinden birini ortaya koymayı, hem de lisans bitirme projesi kapsamında uçtan uca bir araştırma sürecinin –literatür taraması, veri hazırlama, modelleme, değerlendirme ve bilimsel raporlama– deneyimlenmesini amaçlamaktadır.

2. YÖNTEM

Araştırmada uygulanacak yöntem ve araştırma tekniklerinin, amaç ve hedeflere ulaşmaya ne düzeyde elverişli olduğu ilgili literatüre atıf yapılarak ortaya konulur.

Yöntem bölümünün; araştırma tasarımı, bağımlı ve bağımsız değişkenler, istatistiksel yöntemler vb. unsurları içermesi gerekir. Araştırma önerisinde herhangi bir ön çalışma veya fizibilite yapıldıysa bunların sunulması beklenir. Araştırma önerisinde sunulan yöntemlerin çalışma takvimi ile ilişkilendirilmesi gerekir.

Bu proje, temelde bir yazılım geliştirme çalışması olarak kurgulanmıştır. Çalışmanın odağında, üveit ve benzeri arka segment patolojilerini içeren çok kipli göz görüntülerinden (fundus, anterior segment, OCT/OCTA) yararlanarak hem tanı/alt tip sınıflandırması hem de 3–6 aylık nüks riskinin öngörülmesi yer almaktadır.




Şekil 1. Göz görüntüleme verilerinin veri füzyonu, tanısal tahmin, nüks tahmini ve açıklanabilirlik adımlarından geçerek kalibre edilmiş karar destek çıktısına dönüşmesi gösterilmektedir.

Tasarım, klinikte yeni veri toplamaya veya hastaya müdahaleye dayanmayan, retrospektif, gözlemsel ve sekonder veri analizi niteliğindedir. Kullanılan tüm görüntüler, kimliksizleştirilmiş ve araştırma kullanımına açık veri setlerinden sağlanacak; proje, etik açıdan yalnızca ikincil veri işleme sınırları içinde kalacaktır. Geliştirilen kodlar ve modeller, yeniden üretilebilirlik ilkesi gereği, sürüm kontrolü altında (Git) tutulacak ve modüler bir depo yapısı içinde organize edilecektir.

Yöntem, yazılım ve veri akışı açısından beş ana aşamaya ayrılmıştır:

1. Açık veri kaynaklarından Üveit Veri Havuzu v1'in oluşturulması,
2. Her görüntü modalitesi için tek-modelli (unimodal) temel modellerin eğitilmesi,
3. Bu kiplerin çok kipli bir füzyon mimarisinde birleştirilmesi,
4. 3–6 aylık nüks riskinin kalibre edilmiş olasılık olarak modellenmesi,
5. Çıktıların açıklanabilirlik araçları ve vaka kartları ile klinik dile çevrilmesi.

Rapor ekinde yer alan genel akış şeması ve 1–5. aşama diyagramları, bu süreci yazılım modülleri ve veri akışları üzerinden görsel olarak desteklemektedir.



Şekil 2. Projenin genel yöntem akışı: veri kaynaklarından çok kipli model çıktısına giden süreç gösterilmektedir.

2.1. Çalışmanın Tasarımı ve Yazılım Mimarisine Genel Bakış

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI ARAŞTIRMA ÖNERİSİ FORMU

Proje; veri yönetimi, modelleme ve değerlendirme bileşenlerinden oluşan, modüler bir Python/PyTorch mimarisiyle yürütülecektir. Depo yapısı kabaca şu dizinlere ayrılacaktır:

- data/: ham veri bağlantıları, indirme betikleri ve meta-veri dosyaları,
- preprocessing/: ön işleme, kalite kontrol ve veri artırma kodları,
- models/: tek-modelli CNN mimarileri, çok kipli füzyon ağı ve nüks alt modülü,
- training/: eğitim döngüleri, kayıt (logging) ve model kaydetme betikleri,
- evaluation/: metrik hesaplama, istatistiksel karşılaştırmalar ve görselleştirme,
- configs/: deney konfigürasyon dosyaları (öğrenme oranı, batch büyüklüğü, veri bölünmesi vb.),
- docs/: teknik rapor, deney günlüğü ve diyagramlar.

Her deney, ilgili config dosyası üzerinden yürütülecek; böylece yapılan her değişiklik hem yazılım hem de metodoloji açısından izlenebilir olacaktır. Kodun makineye bağlı kalmadan tekrar çalıştırılabilmesi için, kullanılan kütüphane sürümleri environment.yml veya eşdeğer bir dosyada sabitlenecektir.


2.2. Veri Kaynakları ve “Üveit Veri Havuzu v1”

Veri kaynağı olarak iki ana grup hedeflenmektedir:

1. Üveit ve benzeri patolojileri içeren veri setleri
 - İnflamatuvar vitreoretinal hastalıklara (örneğin proliferatif vitreoretinopati ve üveit) ait OCT hacimlerini ve normal gözleri içeren açık veri setleri,
 - Slit-lamba/ön segment görüntülerinden oluşan ve üveit bulgularını barındıran küçük koleksiyonlar.
2. Retina mikrovasküler yapıyı ayrıntılı incelemeye imkân veren OCTA veri setleri
 - İlk büyük OCTA damar segmentasyon veri kümelerinden biri olan ROSE (Retinal OCT-Angiography Vessel Segmentation Dataset), 229 OCTA görüntüsü ve ayrıntılı damar/FAZ anotasyonları içermektedir [10].
 - 500 hastadan elde edilmiş OCT/OCTA hacimleri, çok alanlı projeksiyonlar ve zengin etiketlerle OCTA-500 veri seti, çok kapsamlı bir damar ve hastalık etiketlemesi sunmaktadır [11].

Bu veri setleri hem üveitli olgulara ilişkin örnekler hem de retina damar mimarisini derinlemesine modellemeye uygun OCTA görüntüleri sağlamaktadır. Literatürde son yıllarda, fundus ve OCT gibi çoklu modaliteleri birlikte kullanan MultiEYE gibi çalışmaların, hastalık tanısında tek bir modaliteye göre daha yüksek doğruluk elde ettiği gösterilmiştir [12]. Bu nedenle projemizde de benzer biçimde, farklı görüntü türlerinin tek bir veri havuzu altında birleştirilmesi hedeflenmektedir.

Her kayıt için; modalite (fundus, anterior segment, OCT, OCTA), temel tanı, cihaz türü, çözünürlük, görüntü alanı (fovea/parafovea vb.) ve varsa takip süresini içeren bir meta-veri şeması oluşturulacaktır. Tüm bu bilgiler, “Üveit Veri Havuzu v1” başlığı altında tek bir tablo yapısında birleştirilecek; böylece yazılım tarafında hem filtreleme hem de istatistiksel alt analizler kolaylaşacaktır.



Şekil 3. Üveit Veri Havuzu v1'in oluşturulmasına ilişkin veri seçimi ve etiketleme akışı gösterilmektedir.

Dahil etme ölçütleri erişkin yaş grubuna ait kayıtlar, en az bir fundus veya OCT/OCTA görüntüsünün bulunması, tanı/etiket bilgisinin mevcut olması ve görüntü kalitesinin belirlenen eşik değer üzerinde olması şeklinde tanımlanacaktır. Belirgin bulanıklık, ağır hareket artefaktı, çocuk olgular ve lisans/etik koşulları belirsiz veri setleri havuza alınmayacaktır.

2.3. Değişkenler, Etiketleme ve Veri Bölünmesi

Çalışmanın iki ana çıktısı vardır:

1. Tanı / alt tip sınıfı

- Üst düzeyde "Üveit / diğer retinal hastalık / sağlıklı" sınıfları,
- Uygun veri bulunduğu durumlarda üveit için anatomik alt tipler (anterior, intermediyer, posterior, panuveit) ve etiyolojik ayırım (enfeksiyöz / non-enfeksiyöz).

2. Kısa dönem nüks durumu

- 3–6 aylık izlem ufku içinde nüks gelişip gelişmediği (evet/hayır),
- Mümkünse nüks kadar geçen süre (gün/ay cinsinden).

Bağımsız değişkenler üç düzeyde ele alınacaktır:

- Görüntü düzeyi: Fundus, anterior segment, OCT ve OCTA görüntüleri (ham piksel matrisleri).

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI ARAŞTIRMA ÖNERİSİ FORMU

- Türetilmiş nicel özetler: FAZ alanı, kapiller yoğunluk, damar kalınlık histogramları, tabaka kalınlık profilleri gibi özellikler; ROSE ve OCTA-500 çalışmalarında kullanılan damar ve FAZ metrikleri bu açıdan yol gösterici olacaktır [10], [11].
- Klinik/demografik değişkenler: Yaş, cinsiyet ve eşlik eden temel sistemik tanılar (örneğin otoimmün hastalık varlığı) gibi, veri setlerinde mevcut olduğu ölçüde elde edilebilen alanlar.


Farklı veri setlerinde kullanılan etiket adları, proje için tanımlanacak ortak bir etiket sözlüğüne dönüştürülecektir. Bu sözlük, klinik üveit sınıflama şemalarıyla uyumlu tutulacak; örneğin “tüberküloz ilişkili posterior üveit” gibi özel tanılar hem etiyolojik hem de anatomik kategoriye bağlanabilecektir.

Veri bölünmesi hasta düzeyinde yapılacaktır; aynı hastaya ait çoklu görüntülerin farklı kümelere dağılması engellenecek, böylece bilgi sızıntısı (data leakage) riski azaltılacaktır. Genel hedef, %60–70 eğitim, %15–20 doğrulama ve %15–20 test oranını sağlamak; örnek sayısının sınırlı olduğu alt gruplarda ise k-katlı çapraz doğrulama kullanılmaktadır.

2.4. Ön İşleme, Kalite Kontrol Boru Hattı ve Veri Artırma

Farklı merkez ve cihazlardan gelen görüntülerin doğrudan aynı modele verilmesi, yoğun gürültü ve ölçek farkları sebebiyle performansı düşürebilir. Bu nedenle, rapor ekinde “2. Aşama” diyagramı ile gösterilen ön işleme ve kalite kontrol boru hattı uygulanacaktır.

- Genel adımlar: Tüm görüntüler ortak bir hedef çözünürlüğe (örneğin 512×512 veya 640×640) yeniden ölçeklenecek, kanal sayısına göre normalize edilecek ve temel gürültü azaltma filtreleri (örneğin hafif Gauss bulanıklaştırma) uygulanacaktır.
- Fundus için özel adımlar: Arka plan aydınlatmasının dengelenmesi, renk/kontrast standardizasyonu, optik disk ve fovea etrafının hizalanması sağlanacaktır. Basit bir kalite skoru ile ağır bulanık veya aşırı karanlık görüntüler otomatik olarak dışlanacaktır.
- Anterior segment için özel adımlar: Kornea ve ön kamara bölgesine odaklanacak şekilde otomatik kırpmaya, yarık lamba kaynaklı parlak yansımaların maskeleye ya da eşikleme ile bastırılması planlanmaktadır.
- OCT/OCTA için özel adımlar: Tabaka sınırlarının hizalanması, hareket artefaktlarının azaltılması ve maküla ile FAZ çevresini içeren en-face projeksiyonların çıkarılması yapılacaktır. ROSE ve OCTA-500 çalışmalarında önerilen segmentasyon ve projeksiyon stratejileri, hangi kesitlerin analizde kullanılacağına ilişkin teknik bir referans noktası sağlayacaktır [10], [11].



Şekil 4. Görüntülerin ön işleme, kalite kontrol ve veri artırma adımlarını içeren boru hattı gösterilmektedir.

Eğitim aşamasında, sınıf dengesizliği ve aşırı uyum riskini azaltmak için veri artırma (data augmentation) uygulanacaktır. Bunun için küçük açısız döndürme, yatay/dikey çevirme, sınırlı parlaklık-kontrast değişiklikleri, hafif Gauss gürültüsü ve gerektiğinde küçük ölçekli rastgele kırpmaya gibi, klinik anlamı bozmayacak dönüşümler tercih edilecektir.

2.5. Tek-Modelli (Unimodal) Temel Modellerin Geliştirilmesi

Ön işleme adımlarının ardından, her görüntü modalitesi için ayrı birer temel derin öğrenme modeli eğitilecektir. Amaç, fundus, anterior segment ve OCT/OCTA'nın tek başına tanı/alt tip ayrımında ne kadar ayırt edici olduğunu görmek ve daha sonra kurulacak çok kipli mimarinin katkısını bu "baseline" sonuçlara göre değerlendirmektir.

Her modalite için parametre sayısı makul düzeyde olan CNN tabanlı mimariler (örneğin ResNet, DenseNet veya EfficientNet ailesinden bir üye) kullanılacaktır. Göz görüntülerinin, diğer tıbbi görüntülere göre daha sınırlı boyutta veri içermesi nedeniyle, modeller ön-eğitilmiş (pretrained) ağırlıklarla başlatılıp transfer öğrenme yaklaşımıyla yeniden eğitilecektir. OCT görüntüleri üzerinde derin öğrenmenin tanısallık doğruluğu belirgin biçimde artırabildiği ve özellikle makula patolojilerinde insan uzman performansına yaklaşılabildiği son yıllardaki kapsamlı derlemelerde vurgulanmaktadır [13].

Kayıp fonksiyonu, sınıf dengesizliği söz konusuysa ağırlıklı çapraz entropi olarak tanımlanacak; öğrenme oranı, batch büyüklüğü ve epoch sayısı doğrulama kümesi üzerinden ayarlanacaktır. Aşırı uyumu engellemek için erken durdurma, L2 cezası ve dropout gibi tekniklerden yararlanılacaktır. Her modalite için AUC, F1, duyarlılık ve seçicilik değerleri hesaplanacak; bu değerler, çok kipli mimarinin "tek modaliteye göre kazancını" göstermek açısından referans noktası olacaktır.

2.6. Çok Kipli Füzyon Mimarisi

Çalışmanın özgün noktası, farklı modalitelerden gelen bilgiyi orta seviyede birleştiren çok kipli füzyon modelidir. Literatürde fundus ve OCT'nin birlikte kullanıldığı MultiEYE gibi çalışmaların, yalnızca fundus veya yalnız OCT kullanan modellere göre daha yüksek tanısallık performansı ve daha dengeli hata profili sunduğu gösterilmiştir [12]. Bu projede benzer bir mantık, fundus–anterior segment–OCT/OCTA üçlüsüne uyarlanacaktır.

Tek-modelli aşamada eğitilen CNN'lerin sınıflandırma katmanları çıkarılacak, yalnızca encoder bölümleri kullanılacaktır. Böylece her kip için sabit boyutlu bir özellik vektörü elde edilecektir. Bu vektörler:

1. Ortak bir boyuta projekte edilecek,
2. Orta seviye füzyon katmanında bir araya getirilecektir. İlk aşamada basit bir birleştirme (concatenation) yaklaşımı kullanılacak; doğrulama performansı yetersiz kalırsa, literatürde önerilen dikkat (attention) tabanlı füzyon mekanizmalarından yararlanılacaktır [12], [14].

Füzyon katmanından çıkan ortak temsil, iki ayrı çıktı başlığına bağlanacaktır:

- Çok sınıflı tanı/alt tip başlığı: Üveit/diğer/sağlıklı ve uygun olduğunda anatomik–etiyolojik alt tipleri tahmin eden bir softmax katmanı,
- Nüks başlığı: 3–6 aylık nüks riskini olasılık olarak veren bir sigmoid ya da zaman-dilimli lojistik çıktı.

Gerçek hayatta her hastada tüm modalitelerin mevcut olmaması sık rastlanan bir durumdur. Bunun için ağ mimarisinde eksik modalite maskeleyesi uygulanacaktır. Örneğin yalnız fundus görüntüsü mevcutsa, anterior segment ve OCT/OCTA için encoder çıktıları sıfır vektörü ve ilgili maske bilgisi ile temsil edilecek; ağ, eğitimi sırasında bu durumlarla da karşılaştığı için, sadece mevcut görüntüler üzerinden makul bir tahmin üretebilecektir.



Şekil 5. Tek-modelli encoder'lerden çok kipli füzyon katmanına ve çıktı başlıklarına giden model mimarisi gösterilmektedir.

2.7. Nüks Riskinin Modellenmesi ve Kalibrasyonu

Nüks bilgisi bulunan alt veri kümesi üzerinde, 3–6 aylık nüks için zaman-bağımlı fakat pratikte uygulanabilir bir model kurulacaktır. Takip süreleri görece homojen ise sabit bir ufuk (örneğin 6 ay) seçilecek; her hasta için "6 ay

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

içinde nüks etti/etmedi" biçiminde ikili bir etiket oluşturulacaktır. Çok kipli modelin nüks başlığı, bu ikili etiketi tahmin eden bir lojistik regresyon katmanı gibi çalışacak; çıktı, Platt skalası veya izotonik regresyon kullanılarak kalibre edilecektir.

Takip sürelerinin heterojen olduğu durumlarda ise, basitleştirilmiş zaman-dilimli lojistik yaklaşımlarına başvurulacaktır. Amaç, klinisyen tarafından "bu hastanın önümüzdeki 3–6 ay içinde nüks etme olasılığı yaklaşık %x" şeklinde okunabilecek hem ayırt ediciliği hem de kalibrasyonu kabul edilebilir bir risk skoru üretmektir. Bu tür olasılık temelli risk skorlarının klinik karar desteğindeki rolü, özellikle kronik hastalıklar için giderek daha fazla tartışılmaktadır [13].

2.8. Açıklanabilirlik, Isı Haritaları ve Vaka Kartları


Derin öğrenme modellerinin klinik uygulamaya yaklaşabilmesi için, yalnızca yüksek doğruluk sağlaması yeterli değildir; hangi görsel ipuçlarına dayanarak karar verdiklerini de göstermeleri beklenmektedir. Bu nedenle, projede açıklanabilirlik temel bir bileşen olarak ele alınmaktadır.

Tanı/alt tip ve nüks çıktı başlıkları için, modelin son evrişim katmanlarından elde edilen aktivasyonlar kullanılarak Grad-CAM (Gradient-weighted Class Activation Mapping) tabanlı ısı haritaları üretilecektir [15]. Grad-CAM'in CNN tabanlı modeller için karar odaklı bölgeleri oldukça anlaşılır biçimde ortaya koyabildiği ve klinik görüntülerde hatalı veya önyargılı örüntüleri tespit etmeye yardımcı olduğu bilinmektedir.

Projede şu adımlar izlenecektir:

- Her hasta için, tanı/alt tip ve nüks tahmini alınırken eş zamanlı olarak ilgili Grad-CAM ısı haritaları üretilecek; fundus görüntülerinde damar yapısı ve maküla çevresi, anterior segmentte keratik presipitat odakları, OCTA'da FAZ ve kapiller ağ bölgeleri özellikle incelenecektir.
- En az 20 temsil edici olgu seçilerek, ham görüntüler, model olasılıkları, nüks skoru ve ısı haritaları "vaka kartı" biçiminde bir araya getirilecektir. Bu kartlar, danışman göz hekimi ile birlikte nitel olarak değerlendirilecek; modelin odaklandığı bölgelerin klinik beklentiyle ne ölçüde uyumlu olduğu tartışılacaktır.

Bu sayede yazılım, yalnızca "sayısal bir kara kutu" olmaktan çıkıp, ürettiği kararların görsel gerekçelerini de paylaştan bir karar destek aracı haline getirilecektir.



Şekil 6. Nüks riskinin kalibre edilmesi, açıklanabilirlik çıktıları ve vaka kartları akışı gösterilmektedir.

2.9. Performans Değerlendirmesi, Yazılım Geliştirme Süreci ve Yeniden Üretilbilirlik

Tanı/alt tip sınıflandırması için ROC eğrisi altında kalan alan (AUC), F1 skoru, duyarlılık ve seçicilik; nüks modeli için ise C-index ve Brier skoru başlıca değerlendirme ölçütleri olarak kullanılacaktır. Tek-modelli ve çok kipli modeller arasındaki fark, uygun olduğunda istatistiksel testlerle (örneğin DeLong testi) sınanacaktır.

Yazılım geliştirme süreci boyunca:

- Tüm kodlar Git deposunda tutulacak, önemli kilometre taşları etiketlenerek (tag) işaretlenecektir.
- Veri sözlüğü, ön işleme adımları, model konfigürasyonları ve deney sonuçları, proje raporu ile uyumlu bir teknik dökümantasyonda özetlenecektir.
- Eğitilen tüm modeller ve kullanılan konfigürasyon dosyaları saklanacak; böylece hem proje ekibi hem de ileride aynı konuyu çalışmak isteyen araştırmacılar için yeniden üretilebilir bir altyapı sunulacaktır.

Bu bütüncül yöntem yaklaşımıyla, proje hem üveit alanında çok kipli ve açıklanabilir bir yapay zekâ prototipinin ilk örneklerinden birini geliştirmeyi hem de lisans düzeyinde bir yazılım projesi kapsamında veri toplama, modelleme, değerlendirme ve raporlama adımlarını uçtan uca deneyimlemeyi amaçlamaktadır.

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

3. PROJE YÖNETİMİ

3.1 Çalışma Takvimi

Araştırmada yer alacak başlıca faaliyetler, her bir faaliyetin hangi sürede gerçekleştirileceği, başarı ölçütü ve araştırmancının başarısına katkısı "Çalışma Takvimi" doldurularak sunulur.

ÇALIŞMA TAKVİMİ (*)

Tarih Aralığı	Faaliyetler**	Kim(ler) Tarafından Gerçekleştirileceği	Başarı Ölçütü ve Araştırmancının Başarısına Katkısı***
01/11/2025-31/12/2025	Projenin kapsamının ve iş paketlerinin netleştirilmesi; kullanılacak fundus, anterior segment ve OCT/OCTA veri kümelerinin belirlenmesi; açık veri kaynaklarından görüntülerin indirilmesi; ortak etiket sözlüğü ve klasör yapısının oluşturulması; ilk veri kalite kontrolünün yapılması.	Recep Öztürk	En az 3 farklı kaynaktan, toplamda ≥ 3.000 çok kipli görüntünün indirilip "Üveit Veri Havuzu v1" adıyla düzenlenmiş olması; veri setinin $\geq \%90$ 'ı için eksik/bozuk kayıtların işaretlenmiş olması. Projenin başarısına katkısı: $\%20$.
01/01/2026-28/02/2026	Tüm modaliteler için ön-işleme hattının geliştirilmesi (boyutlandırma, kontrast standardizasyonu, gürültü azaltma, hizalama); fundus ve OCT/OCTA için tek-kipli derin öğrenme modellerinin (baseline) eğitimi; bu modellerle pilot deneylerin yürütülmesi; elde edilen sonuçların Ara Rapor'un yöntem ve veri bölümlerine işlenmesi.	Recep Öztürk	Ön-işleme hattının veri setinin $\geq \%95$ 'inde hatasız çalışması; tek-kipli tanı model(ler)inin doğrulama kümesinde $AUC \geq 0,80$ düzeyine ulaşması; Ara Rapor v1'in tamamlanması. Projenin başarısına katkısı: $\%25$.
01/03/2026-31/03/2026	Fundus, anterior segment, OCT/OCTA ve temel klinik değişkenleri bütünleştiren çok-kipli derin öğrenme mimarisinin tasarımı ve eğitimi; tanı/alt tip sınıflandırma modülünün kurulması; 3-6 aylık nöks riski için zaman-bağımlı risk modelinin eklenmesi; Grad-CAM, entegre gradyanlar ve SHAP tabanlı açıklanabilirlik çıktılarının üretilmesi.	Recep Öztürk	Çok-kipli tanı modelinde doğrulama kümesinde $AUC \geq 0,85$, nöks modelinde C-index $\geq 0,70$ değerlerine ulaşılması; en az 20 örnek vaka için açıklanabilirlik haritalarının üretilip saklanması. Projenin başarısına katkısı: $\%25$.
01/04/2026-30/04/2026	Geliştirilen modellerin farklı veri kümeleri ve cihaz tipleri üzerinde değerlendirilmesi; eksik modalite, gürültü ekleme ve merkez farkı senaryolarında dayanıklılık analizlerinin yapılması; performans düşüşlerinin nicel olarak raporlanması; "Değerlendirme ve Dayanıklılık Raporu v1" in yazılması.	Recep Öztürk	Çapraz-küme testlerinde temel AUC'deki düşüşün $\Delta AUC \leq 0,05$ olacak şekilde gösterilmesi; tüm dayanıklılık senaryolarını içeren ayrıntılı değerlendirme raporunun tamamlanması. Projenin başarısına katkısı: $\%15$.
01/05/2026-30/06/2026	Çok-kipli modeli kullanan web tabanlı karar destek prototipinin geliştirilmesi (REST API uçları + basit klinik arayüz); örnek üveit olguları üzerinde sistemin entegrasyon ve işlevsellik testlerinin yapılması; danışman geri bildirimleri doğrultusunda son iyileştirmelerin gerçekleştirilmesi.	Recep Öztürk	Tanı, nöks skoru ve açıklanabilirlik çıktılarının tek arayüzde üretildiği, tüm temel fonksiyonları çalışan bir prototipin ortaya konması; en az 30 vaka üzerinde sorunsuz test edilmesi; danışman değerlendirmesinde kullanılabilirlik puanının $\geq 4/5$ olması; sonuç raporu ve sunumun tamamlanması. Projenin başarısına katkısı: $\%15$.

(*) Çizelgedeki satırlar ve sütunlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

(**) Literatür taraması, sonuç raporu hazırlama aşamaları, araştırma sonuçlarının paylaşımı ve malzeme alımı ayrı birer iş adımı olarak gösterilmemelidir.

(***) Başarı ölçütü, ölçülebilir ve izlenebilir nitelikte olacak şekilde nicel veya nitel ölçütlerle (ifade, sayı, yüzde, vb.) belirtilir. Bu sütundaki değerlerin toplamı 100 olmalıdır.

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

3.2 Risk Yönetimi

Araştırmanın başarısını olumsuz yönde etkileyebilecek riskler ve bu risklerle karşılaşıldığında araştırmanın başarıyla yürütülmesini sağlamak için alınacak tedbirler (B Planı) aşağıdaki Risk Yönetimi Tablosu'nda ifade edilir. B Plan(lar)ının uygulanması araştırmanın temel hedeflerinden sapmaya yol açmamalıdır. B Plan(lar)ına geçilmesi durumunda yöntem değişikliğine gidiliyor ise bu durum detaylandırılmalıdır.

RİSK YÖNETİMİ TABLOSU*

En Önemli Riskler	Alınacak Tedbirler (B Planı)
Açık erişimli fundus, anterior segment ve OCT/OCTA veri setlerinin beklenenden daha sınırlı olması; özellikle üveit alt tipleri ve 3–6 aylık nüks bilgisi içeren olgu sayısının az kalması, sınıf dengesizliğinin çok yüksek olması.	Ek veri setleri ve açık veri arşivlerinin literatür taramasıyla genişletilmesi; benzer tanı gruplarının birleştirilerek daha dengeli üst sınıflar altında toplanması; nüks modülünde olay sayısı yetersiz kalırsa, nüks riskinin ikili bir sonlanım (nüks var/yok) ve daha geniş zaman ufku ile modellenmesi; buna rağmen veri yetersizliği sürerse nüks modülünün “keşifsel sonuç” olarak raporlanıp tanı/alt tip sınıflandırma bileşeninin proje çıktısı olarak korunması.
Derin öğrenme modellerinin eğitimi için gerekli hesaplama kaynaklarının (GPU, bellek, depolama) kısıtlı olması; eğitim sürelerinin çok uzaması veya modeli tekrarlamının zorlaşması.	Öncelikle hafif mimarilerin (daha az katmanlı CNN'ler) ve transfer öğrenmenin kullanılması; giriş görüntülerinin çözünürlüğünün makul düzeyde tutulması; eğitimlerin mini-batch boyutu ve epoch sayısı optimize edilerek sürelerin kısaltılması; gerektiğinde üniversite laboratuvarındaki GPU'lar veya bulut tabanlı geçici çözümlerden yararlanılması; buna rağmen kısıt devam ederse en az iki modaliteyi içeren daha kompakt bir çok kipli modelle devam edilerek projenin temel amacının (üveit için çok kipli karar desteği) korunması.
Farklı merkez ve cihazlardan gelen görüntüler arasında ciddi heterojenlik bulunması; bu nedenle modelin bir veri kümesinde iyi performans gösterirken diğerinde belirgin performans kaybına uğraması (genellenebilirlik sorunu).	Tüm modaliteler için standart ön-işleme ve normalizasyon adımlarının uygulanması; eğitim/doğrulama/test kümelerinin merkez ve cihaz bakımından dengeli olacak şekilde ayrılması; mümkün olduğunda “veri kümesi bazlı” eğitim–test senaryoları ile domain farkının ayrı ayrı raporlanması; performans kaybı yüksek olursa, en kaliteli ve temsil gücü yüksek veri kümesi esas alınarak modelin bu küme için optimize edilmesi, diğer kümeler içinse elde edilen sonuçların “genellenebilirlik analizi” olarak sunulması; böylece projenin temel hedefinden (multimodal üveit karar destek prototipinin geliştirilmesi) sapmadan riskin kontrol altına alınması.

(*) Tablodaki satırlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

3.3.Araştırma Olanakları

Bu bölümde projenin yürütüleceği kurum ve kuruluşlarda var olan ve projede kullanılacak olan altyapı/ekipman (laboratuvar, araç, makine-teçhizat, vb.) olanakları belirtilir.

ARAŞTIRMA OLANAKLARI TABLOSU (*)

Kuruluşta Bulunan Altyapı/Ekipman Türü, Modeli (Laboratuvar, Araç, Makine-Teçhizat, vb.)	Projede Kullanım Amacı
Ankara Üniversitesi Mühendislik Fakültesi / Bilgisayar Laboratuvarları	Derin öğrenme modellerinin kodlanması, veri ön işleme ve deneysel çalışmaların yürütülmesi, model eğitimi ve değerlendirme deneylerinin gerçekleştirilmesi, prototip karar destek yazılımının geliştirilmesi ve test edilmesi.
Ankara Üniversitesi ağ altyapısı ve kurum içi sunucular	Açık erişimli görüntü veri setlerinin güvenli biçimde indirilmesi ve saklanması, proje kodlarının ve deney çıktılarının yedeklenmesi, gerektiğinde uzaktan erişimle eğitim deneylerinin sürdürülmesi.

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

Ankara Üniversitesi Kütüphanesi ve çevrimiçi bilimsel veri tabanları	Üveit, retina görüntüleme ve derin öğrenme alanlarındaki güncel literatürün taranması, kullanılacak yöntem ve veri setlerinin bilimsel olarak temellendirilmesi, proje raporu ve sonuçların akademik standartlara uygun biçimde yazılması.
--	--

(*) Tablodaki satırlar gerektiği kadar genişletilebilir ve çoğaltılabilir.


4. ARAŞTIRMA ÖNERİSİNİN YAYGIN ETKİSİ

Araştırma önerisi kapsamındaki çalışmadan elde edilmesi öngörülen çıktılar amaçlarına göre belirlenen kategorilere ayrılarak belirtilir; ölçülebilir ve gerçekçi hedeflere dayandırılır.

Çıktı, Etki ve Kazanımlar	Öngörülen Çıktı(lar), Etki(ler) ve Kazanım(lar)
Bilimsel/Akademik Çıktılar (Ulusal/Uluslararası Makale, Kitap Bölümü, Kitap, Bildiri vb.)	Proje sonuçlarının en az bir ulusal/uluslararası kongrede bildiri olarak sunulması ve hakemli bir dergide makale hazırlanması hedeflenmektedir. Geliştirilen yöntem ve deneysel sonuçlar bitirme tezi ve kod deposu aracılığıyla belgelenecek üveit alanında çok kipli yapay zekâ çalışmalarına referans oluşturacaktır.
Ekonomik/Ticari/Sosyal Çıktılar (Ürün, Prototip, Patent, Faydalı Model, Tescil, Görsel/İşitsel Arşiv, Envanter/Veri Tabanı, Çalıştay, Eğitim, Bilimsel Etkinlik vb.)	Geliştirilecek yazılım prototipi, üveit tanı ve nüks riskine yönelik karar desteği sağlayarak klinik süreçlerin hızlanmasına ve hata riskinin azalmasına katkı sunabilir. Orta vadede, uygun klinik iş birlikleriyle bu prototipin ticarileştirilebilir bir tıbbi yazılım ürünü hâline getirilmesi ve sağlık hizmeti kalitesine dolaylı ekonomik katkı sağlaması öngörülmektedir.
Yeni Proje(ler) Oluşturmasına Yönelik Çıktılar (Ulusal/Uluslararası Yeni Proje vb.)	Bu çalışma, daha geniş hasta sayısına sahip çok merkezli klinik çalışmalar ve TÜBİTAK 1001/1501 düzeyindeki projeler için pilot altyapı sağlayacaktır. Elde edilen veri havuzu ve model mimarisi, farklı inflamatuvar göz hastalıkları için benzer multimodal karar destek sistemlerini hedefleyen yeni lisansüstü tez ve araştırma projelerine temel oluşturacaktır.

5. BELİRTMEK İSTEDİĞİNİZ DİĞER KONULAR

Sadece araştırma önerisinin değerlendirilmesine katkı sağlayabilecek bilgi/veri (grafik, tablo, vb.) eklenebilir.



sağlanmasına yönelik olarak destekleyici araç şeklinde kullanılmıştır. Bilimsel içerik, araştırma soruları, yöntem tasarımı, literatür değerlendirmesi ve sonuçlara ilişkin yorumlar özgün akademik kaynaklar esas alınarak proje yürütücüsü tarafından üretilmiş, üretken yapay zekâdan gelen tüm metin önerileri içerik olarak kontrol edilip gerektiğinde yeniden yazılmıştır. Araştırma kapsamında gizli, kişisel veri veya ileride üretilecek özgün araştırma verisi herhangi bir üretken yapay zekâ aracına girilmemiştir.

Rapor içinde yer alan Şekil 1 ve Şekil 7, genel çalışma akışını görsel olarak özetlemek amacıyla çevrim içi bir otomatik diyagram aracı (napkin.ai) kullanılarak tasarlanmış, ancak bu görseller yalnızca kavramsal şema niteliğinde olup, bilimsel sonuç veya veri analizi içermemektedir. Şekillerin içerikleri ve açıklamaları proje yürütücüsü tarafından gözden geçirilmiş ve metinle uyumlu olacak şekilde düzenlenmiştir.

Bu beyan, TÜBİTAK tarafından yayımlanan ***Destek Süreçlerinde Üretken Yapay Zekânın (ÜYZ) Sorumlu ve Güvenilir Kullanımı Rehberi***nde belirtilen şeffaflık, sorumluluk, veri gizliliği ve etik ilkelere uygun olarak hazırlanmıştır [16].

6. EKLER

EK-1: KAYNAKLAR

- [1] T. Tsirouki *et al.*, “A Focus on the Epidemiology of Uveitis,” *Ocular Immunology and Inflammation*, vol. 26, no. 1, pp. 2–16, 2018, doi: 10.1080/09273948.2016.1196713.
- [2] J. H.-M. Chang and D. Wakefield, “Uveitis: a global perspective,” *Ocular Immunology and Inflammation*, vol. 10, no. 4, pp. 263–279, 2002, doi: 10.1076/ocii.10.4.263.15592.
- [3] K. A. Joltikov and A.-M. Lobo-Chan, “Epidemiology and Risk Factors in Non-infectious Uveitis: A Systematic Review,” *Frontiers in Medicine*, vol. 8, Art. no. 695904, 2021, doi: 10.3389/fmed.2021.695904.
- [4] F. Pichi *et al.*, “Automated quantification of uveitic keratic precipitates by use of anterior segment optical coherence tomography,” *Clinical and Experimental Ophthalmology*, vol. 51, no. 8, pp. 790–798, 2023, doi: 10.1111/ceo.14296.
- [5] Y. Mellak *et al.*, “A machine learning framework for the quantification of experimental uveitis in murine OCT,” *Biomedical Optics Express*, vol. 14, no. 7, pp. 3413–3432, 2023, doi: 10.1364/BOE.489271.
- [6] X. Wang *et al.*, “Automatic Detection of 30 Fundus Diseases Using Ultra-Widefield Fluorescein Angiography with Deep Experts Aggregation,” *Ophthalmology and Therapy*, vol. 13, pp. 1125–1144, 2024, doi: 10.1007/s40123-024-00900-7.
- [7] N. Lv *et al.*, “TCDDU-Net: combining transformer and convolutional dual-path decoding U-Net for retinal vessel segmentation,” *Scientific Reports*, vol. 14, Art. no. 77464, 2024, doi: 10.1038/s41598-024-77464-w.
- [8] S. R. B. Murugan *et al.*, “Artificial Intelligence in Uveitis: Innovations in Diagnosis and Therapeutic Strategies,” *Clinical Ophthalmology*, vol. 18, pp. 3753–3766, 2024, doi: 10.2147/OPHTH.S495307.
- [9] M. D. Abràmoff, M. K. Garvin, and M. Sonka, “Retinal Imaging and Image Analysis,” *IEEE Reviews in Biomedical Engineering*, vol. 3, pp. 169–208, 2010, doi: 10.1109/RBME.2010.2084567.
- [10] Y. Ma *et al.*, “ROSE: A Retinal OCT-Angiography Vessel Segmentation Dataset and New Model,” *IEEE Trans. Med. Imaging*, vol. 40, no. 12, pp. 3538–3551, 2021.
- [11] M. Li *et al.*, “OCTA-500: A Retinal Dataset for Optical Coherence Tomography Angiography Study,” *Med. Image Anal.*, vol. 88, Art. no. 102840, 2024.
- [12] L. Wang *et al.*, “MultiEYE: Dataset and Benchmark for OCT-Enhanced Retinal Disease Recognition from Fundus Images,” *IEEE Trans. Med. Imaging*, early access, 2024.
- [13] A. S. Abdi *et al.*, “A Comprehensive Review of Deep Learning in OCT Image Analysis,” *Comput. Med. Imaging Graph.*, vol. 112, Art. no. 102357, 2025.
- [14] F. M. Talaat and A. Ali, “Deep Attention for Enhanced OCT Image Analysis in Clinical Retinal Diagnosis,” *Neural Comput. Appl.*, early access, 2025.

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

[15] R. R. Selvaraju *et al.*, “Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization,” *Int. J. Comput. Vis.*, vol. 128, no. 2, pp. 336–359, 2020.

[16] TÜBİTAK, “Destek Süreçlerinde Üretken Yapay Zekânın (ÜYZ) Sorumlu ve Güvenilir Kullanımı Rehberi,” Eylül 2025. [Çevrim içi]. Erişim: 18 Kas. 2025. Erişim adresi: <https://tubitak.gov.tr/tr/kurumsal/hakkimizda/uretken-yapay-zeka-rehberi>

OpenAI, “ChatGPT,” OpenAI, 2025. [Çevrim içi]. Erişim: 18 Kas. 2025. Erişim adresi: <https://chat.openai.com>

Napkin AI, “Napkin – Visual thinking and diagramming tool,” 2025. [Çevrim içi]. Erişim: 18 Kas. 2025. Erişim adresi: <https://www.napkin.ai>